昇腾950 NPU架构白皮书深度解读

主讲：李艳华、顾宝成、刘锡明

Part 1

昇腾950的架构设计基于哪些重要思考?

昇腾950PR/DT系统架构：计算、访存、通信架构全面升级，更好的性能和易用性

统一接口设计

- 支持自研HBM
- 高容量低成本HiBL1.0
- 和兼容商业HBM的HiZQ2

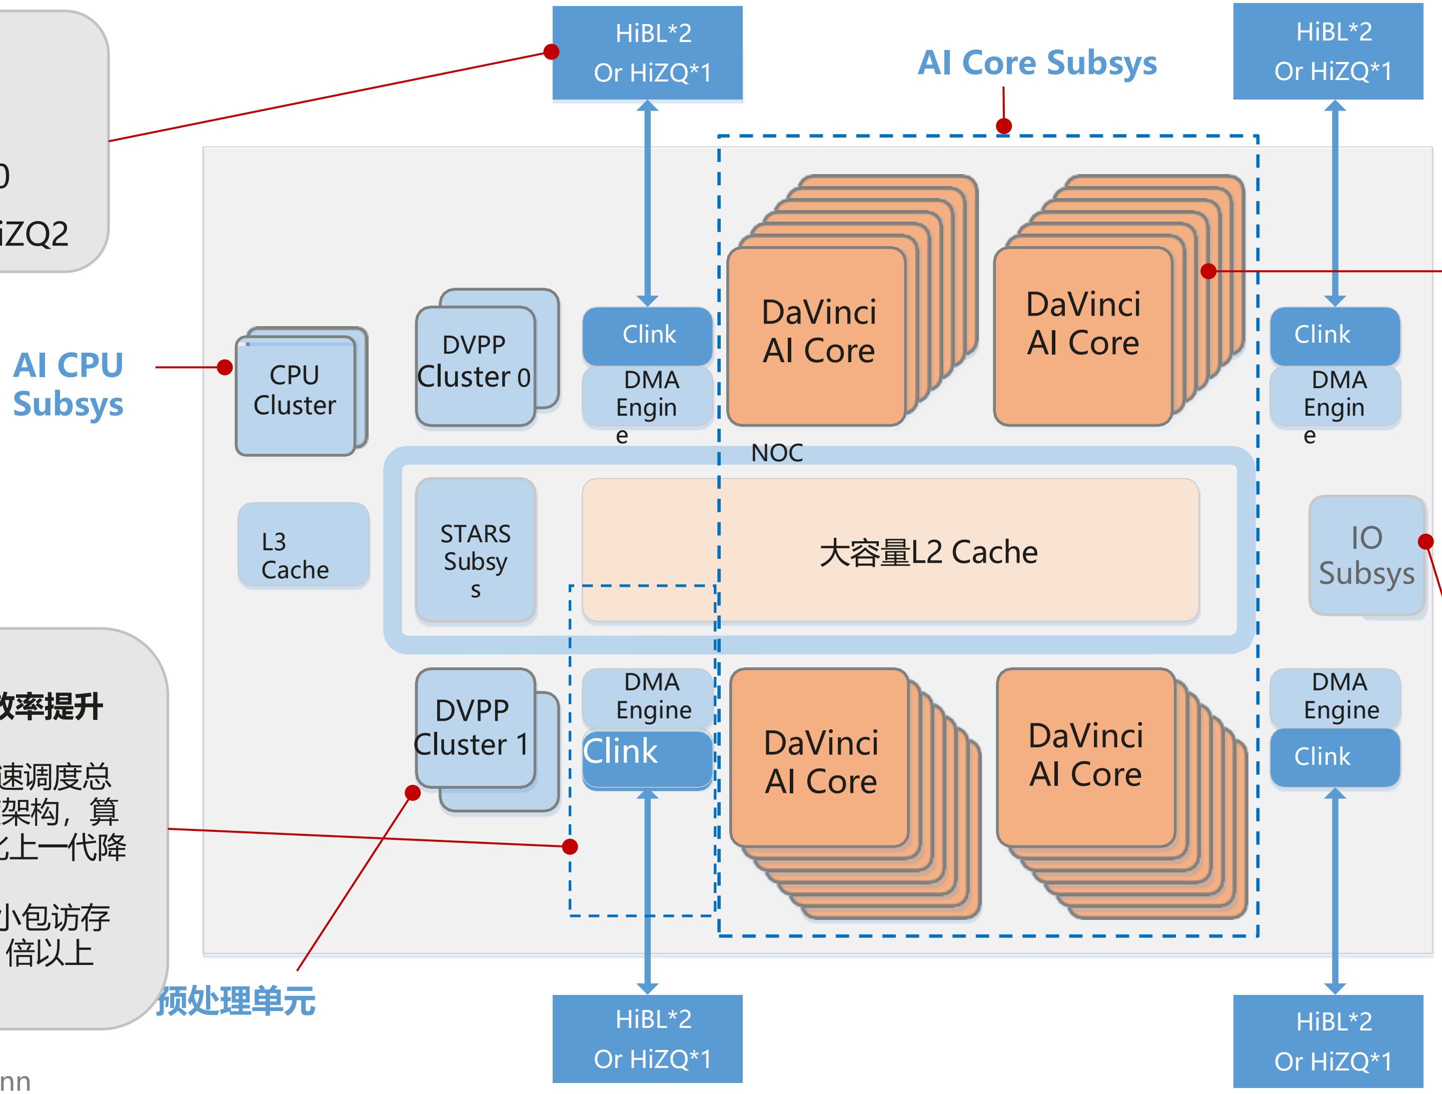

第三代Davinci架构

- 数据格式升级：支持FP4/FP6/FP8，自研HiF8
- SIMD+SIMT融合架构
- NDDMA高效数据访问
- 大模型亲和的Cube-Vector融合通路
- 软件易用性提升
- Cube-Vector多核同步性能提升

SOC：系统调度/访存效率提升

- STARS2.0：创新的高速调度总线+多加速器融合调度架构，算子端到端调度时间相比上一代降低50%+
- 访存效率提升：离散/小包访存效率相比A2/A3 提升1倍以上

灵衢2.0和UB落地

- 大互联带宽：112G Serdes* 72
- 多种IO模式：UB, PCIE,UBoE
- 支持LD/ST同步通信语义(UB Memory）和URMA 异步通信
- 支持CLOS和n-D Mesh组网
- 集合通信加速器(CCU1.0)：节约带宽、降低延迟，更高效的计算通信并发

https://gitcode.com/cann

CANN

昇腾950PR/DT 芯片规格

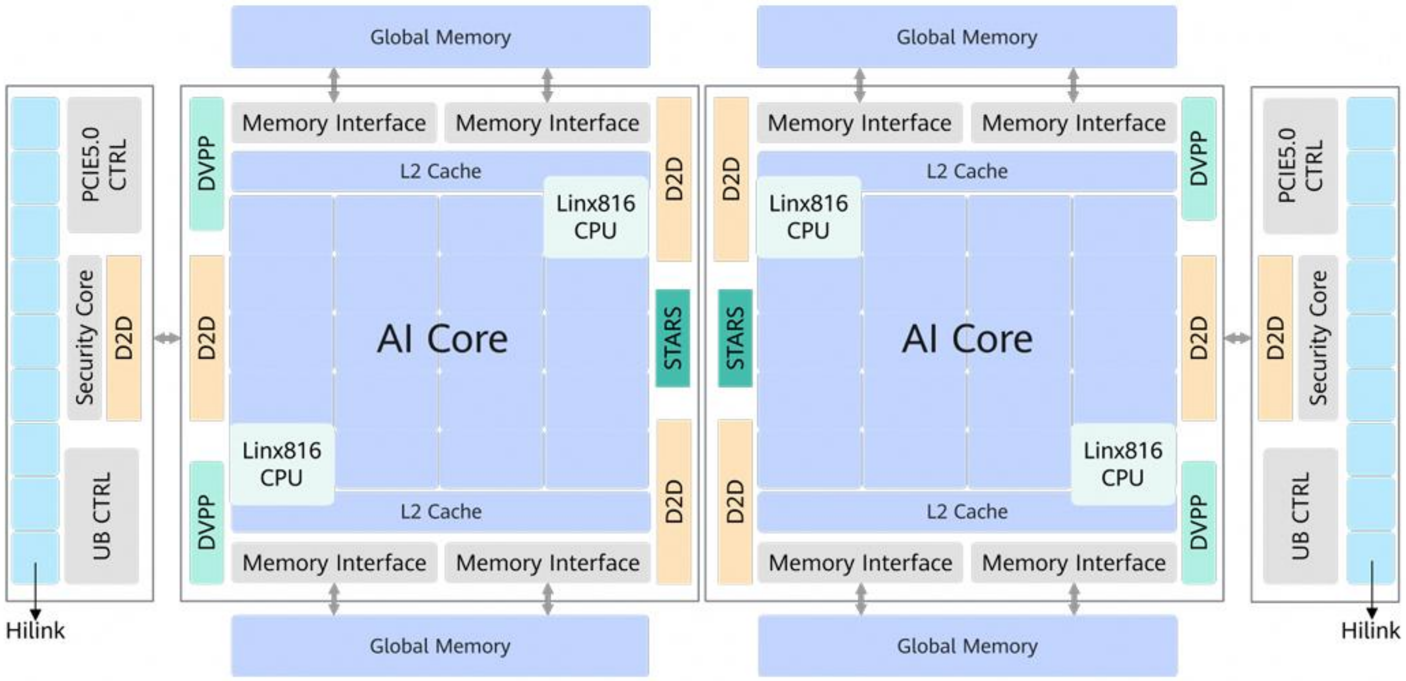

规格项		昇腾950PR	昇腾950DT
算力	Cube算力规格	378T (FP16/BF16)	432~486T (FP16/BF16)
		757T (MxFP8，HiF8，MxFP6)	864~972T (MxFP8，HiF8，MxFP6)
		1514T (MxFP4)	1728~1944T (MxFP4)
	Vector算力规格 (FP16/BF16)	47T	54~60.8T
	总算力规格 (FP16/BF16)	425T	486~547T
Memory	Memory容量 (GB)	**128**	**96/144**
	Memory带宽	1.6TB/s	**Up to 4TB/s**
IO规格	UB Link	Up to 2016GB/s	**2016GB/s**
	PCIE	128GB/s RC & EP	128GB/s RC & EP
	RoCE/UBoE	400Gbps	400Gbps

Part 2

昇腾950采用了第三代达芬奇架构，有哪些创新?

CANN

昇腾950采用了第三代达芬奇架构

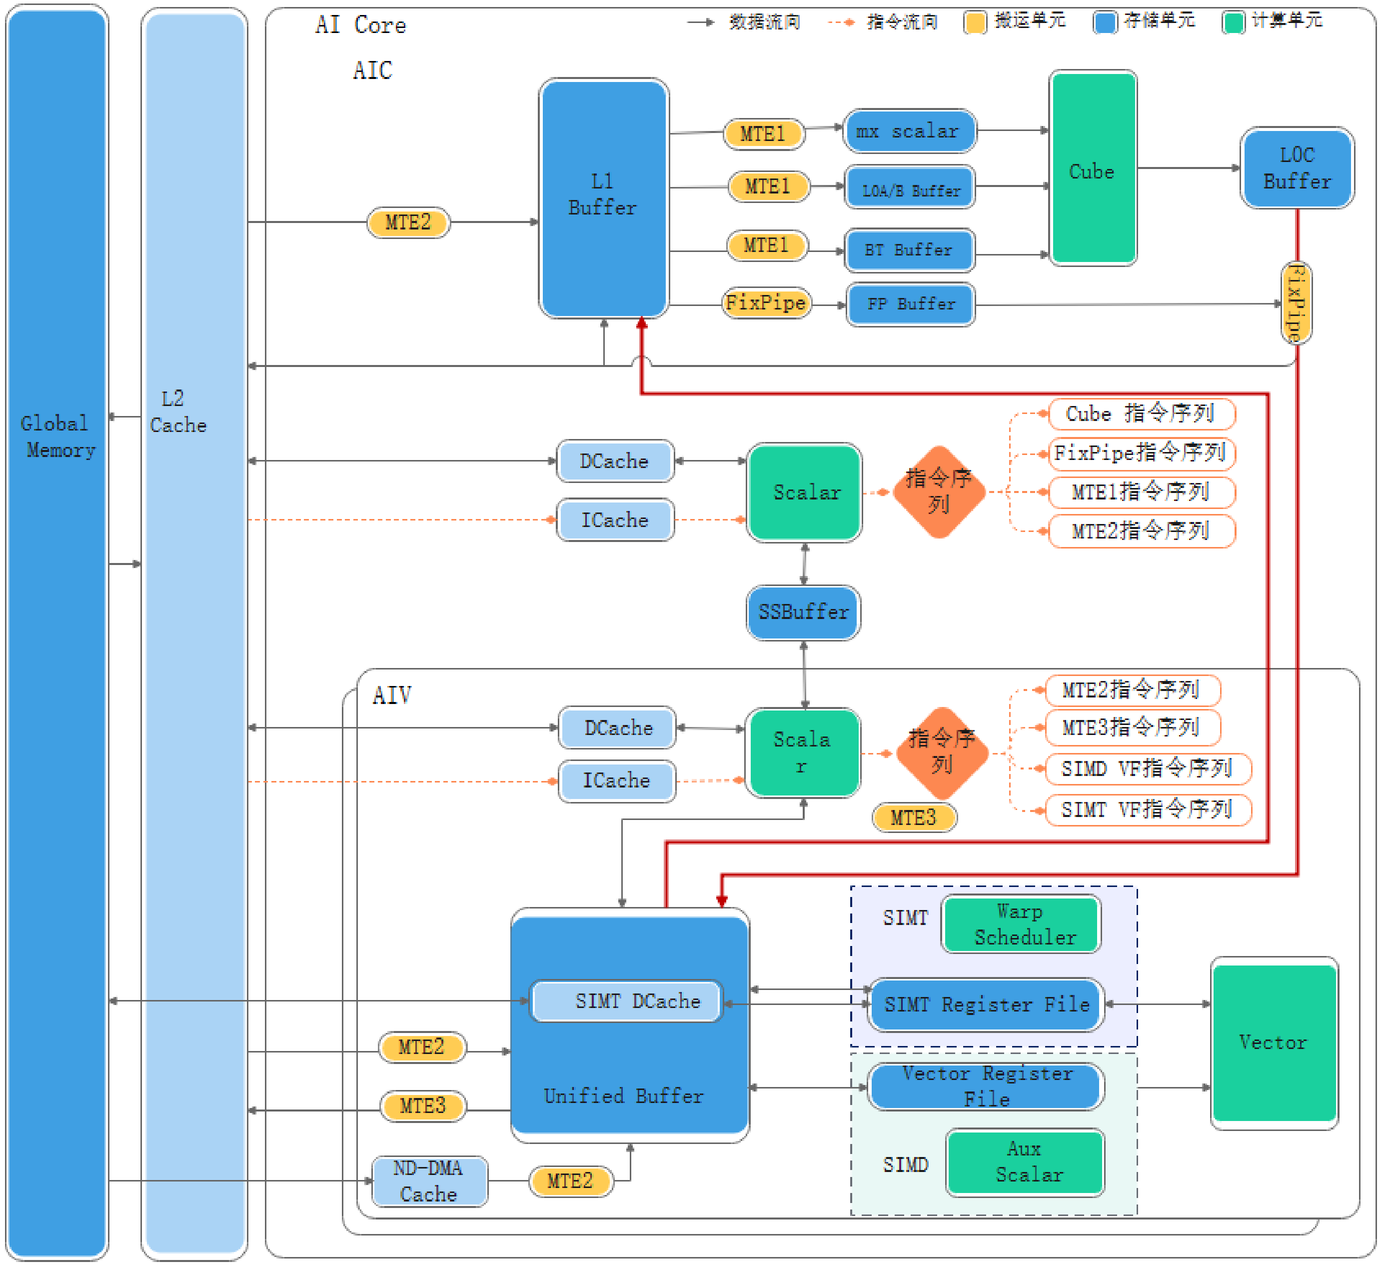

Cube MMAD计算支持的数据类型：

1. FP16/BF16/HF32/FP32/S8
2. FP8(E5M2/E4M3)
3. MXFP8(E5M2/E4M3)
4. MXFP4(E2M1/E1M2)
5. HiF8

950相比910系列数据通道主要改动点：

1. 增加L0C ->UBuffer数据通路
2. 增加UBuffer->L1数据通路
3. 增加SSBuf支持CV之间的消息通路

Part 3

昇腾950如何突破“内存墙”？

昇腾950 Memory内存层次

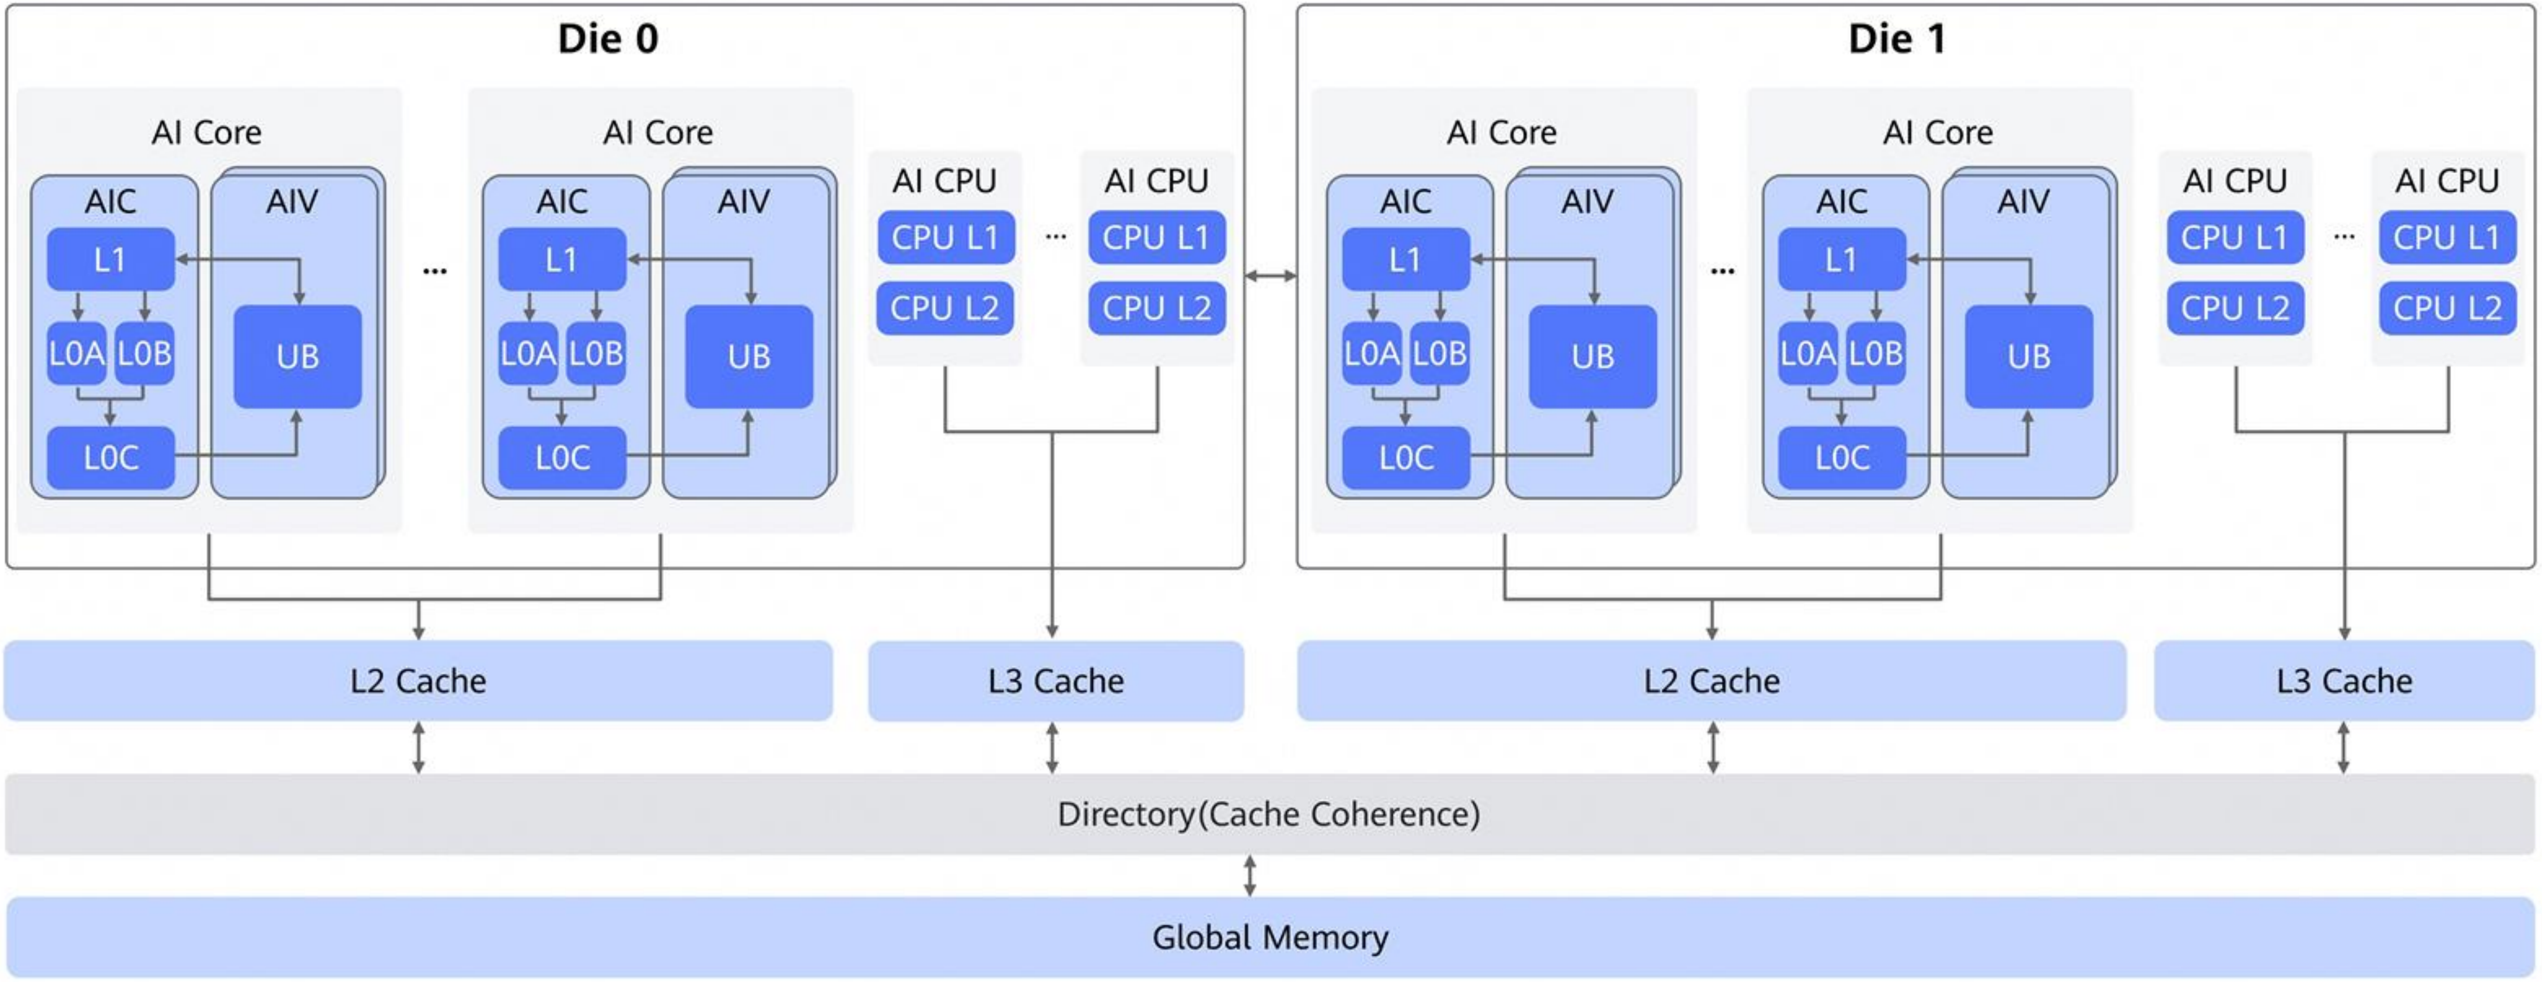

昇腾950 Memory层次中主要Memory及其大小

Memory	Memory size
L1 Buffer	512KB per AI Core
L0A Buffer	64KB per AI Core
L0B Buffer	64KB per AI Core
L0C Buffer	256KB per AI Core
Unified Buffer (UB)	512KB per AI Core
CPU L1 Cache	64KB per CPU Core
CPU L2 Cache	1MB per CPU Core
L3 Cache	4MB per CPU Cluster
L2 Cache	Up to 128MB
昇腾950PR片上内存	Up to 128GB
昇腾950DT片上内存	Up to 96/144GB

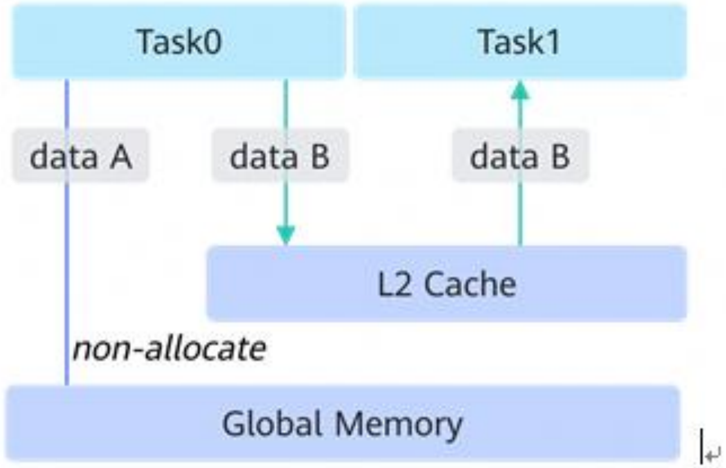

L2 hint 典型应用场景示意图

Part 4

从单芯片到超节点——互联、通信与集群调度

CANN

Ascend950超大互联带宽

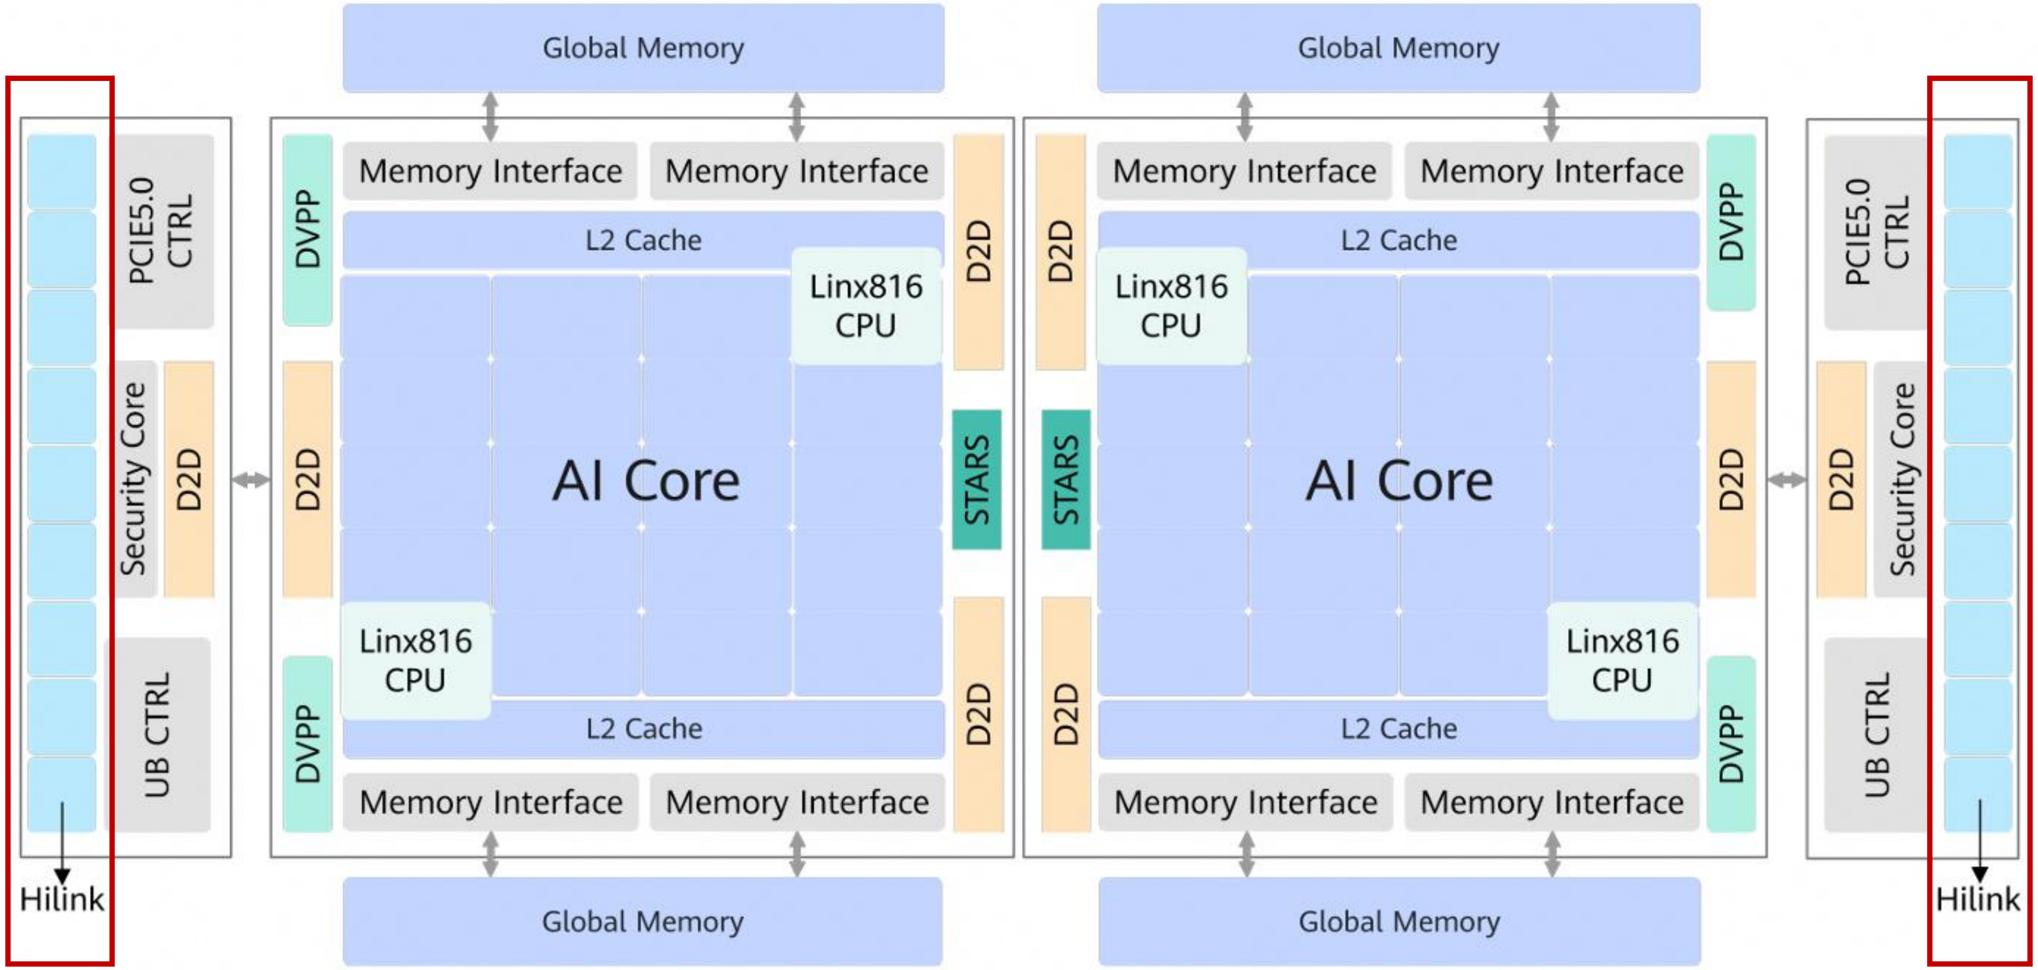

- 2 IO DIE
- 每IO DIE 9端口
- 每端口4 Lane
- 18个端口最大支持2016 GB/s带宽

Ascend950 ScaleUp网络互联

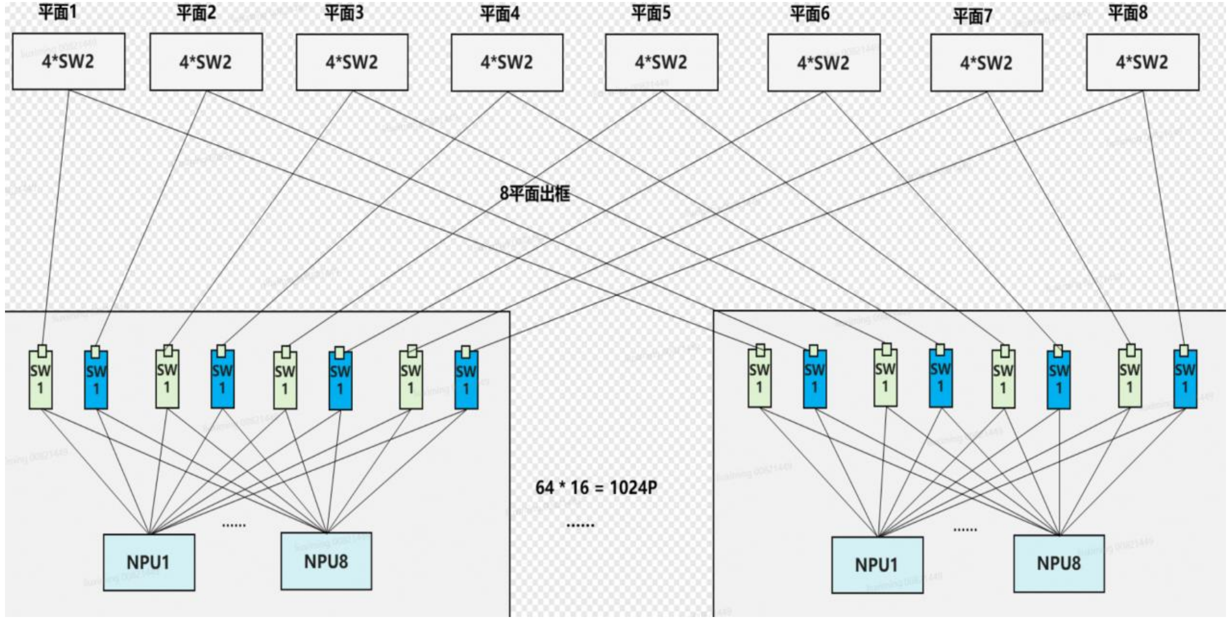

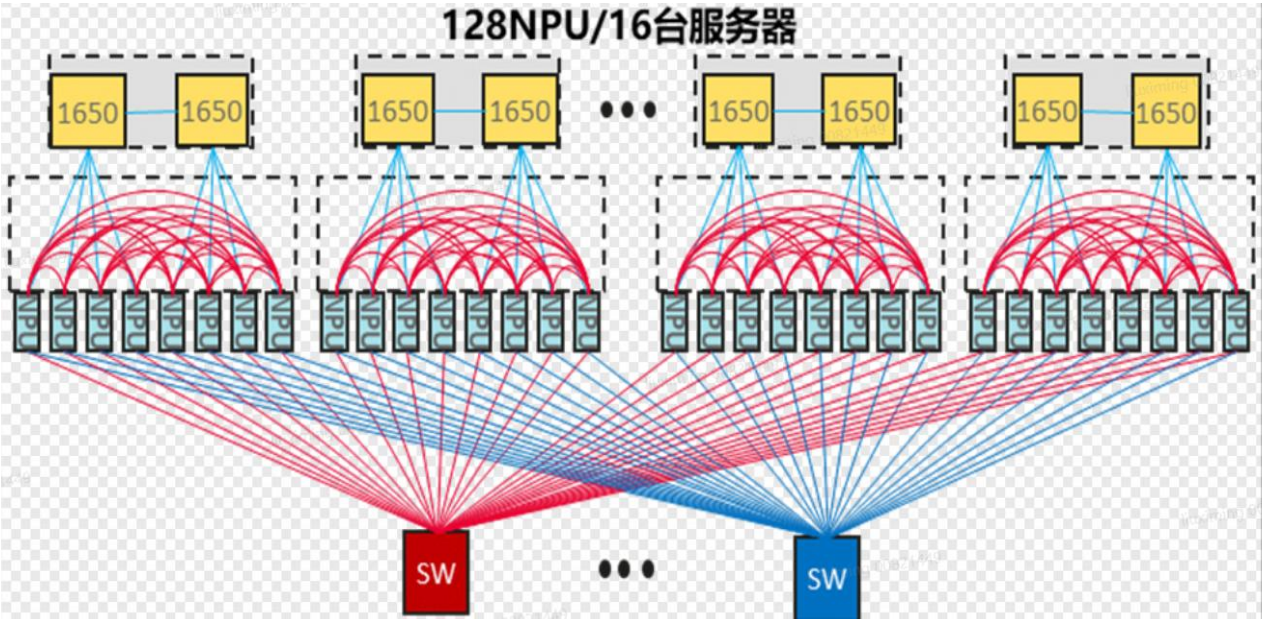

Ascend950 ScaleOut网络互联

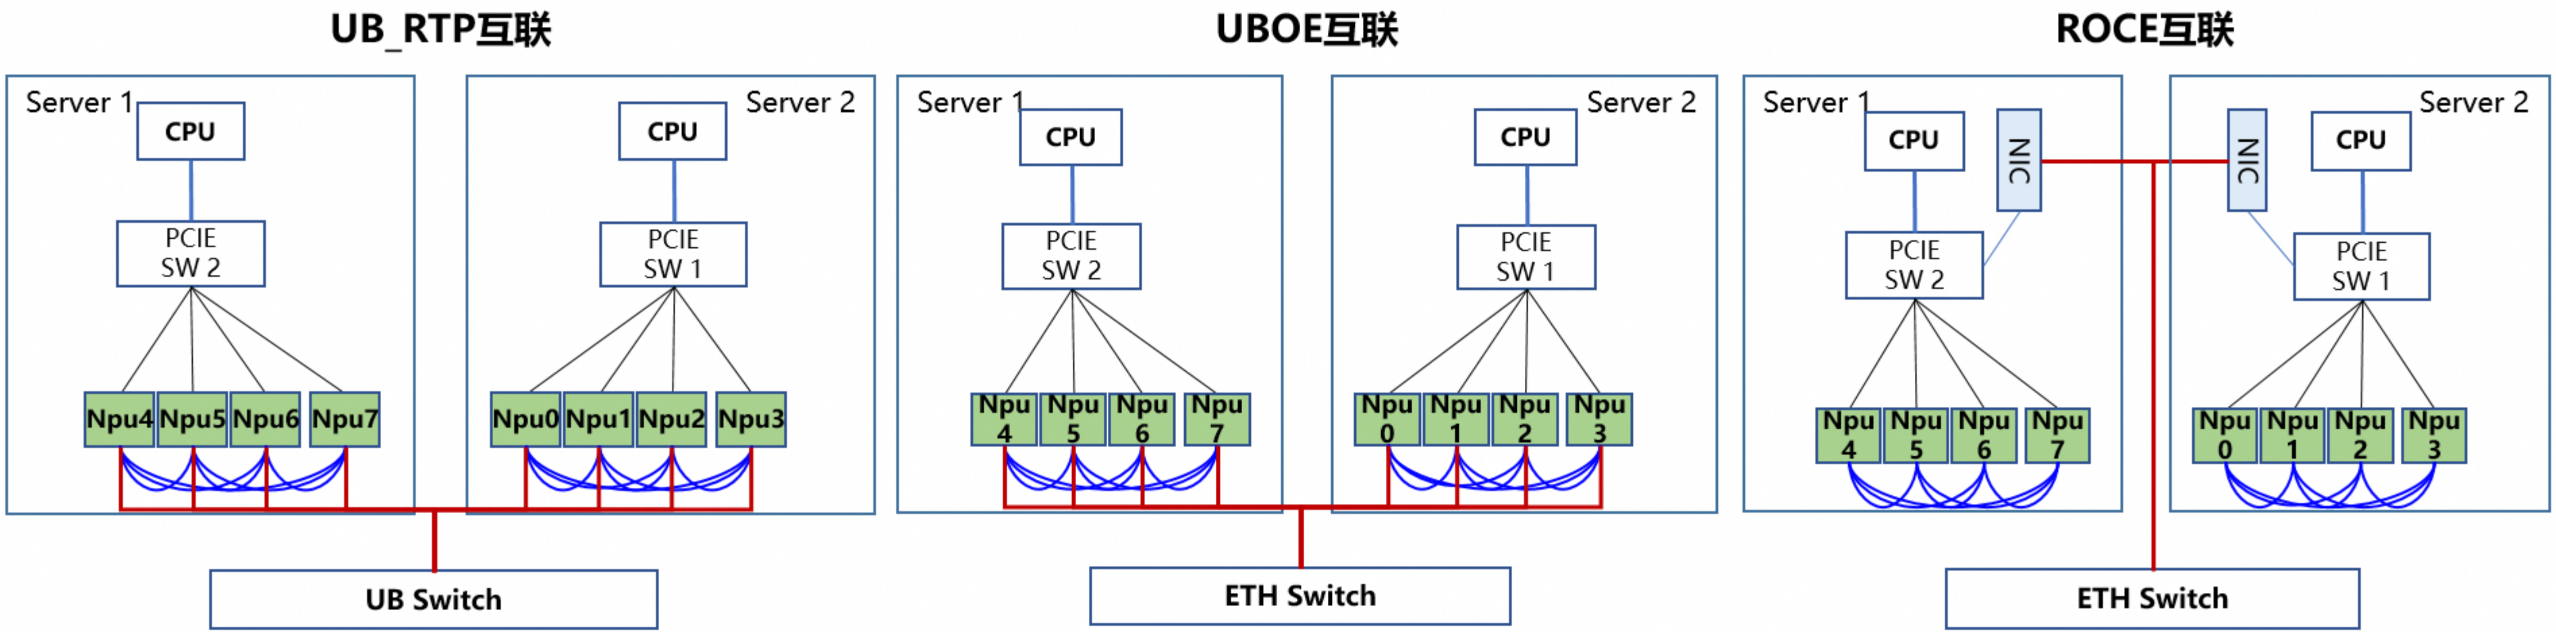

Ascend950 CCU加速

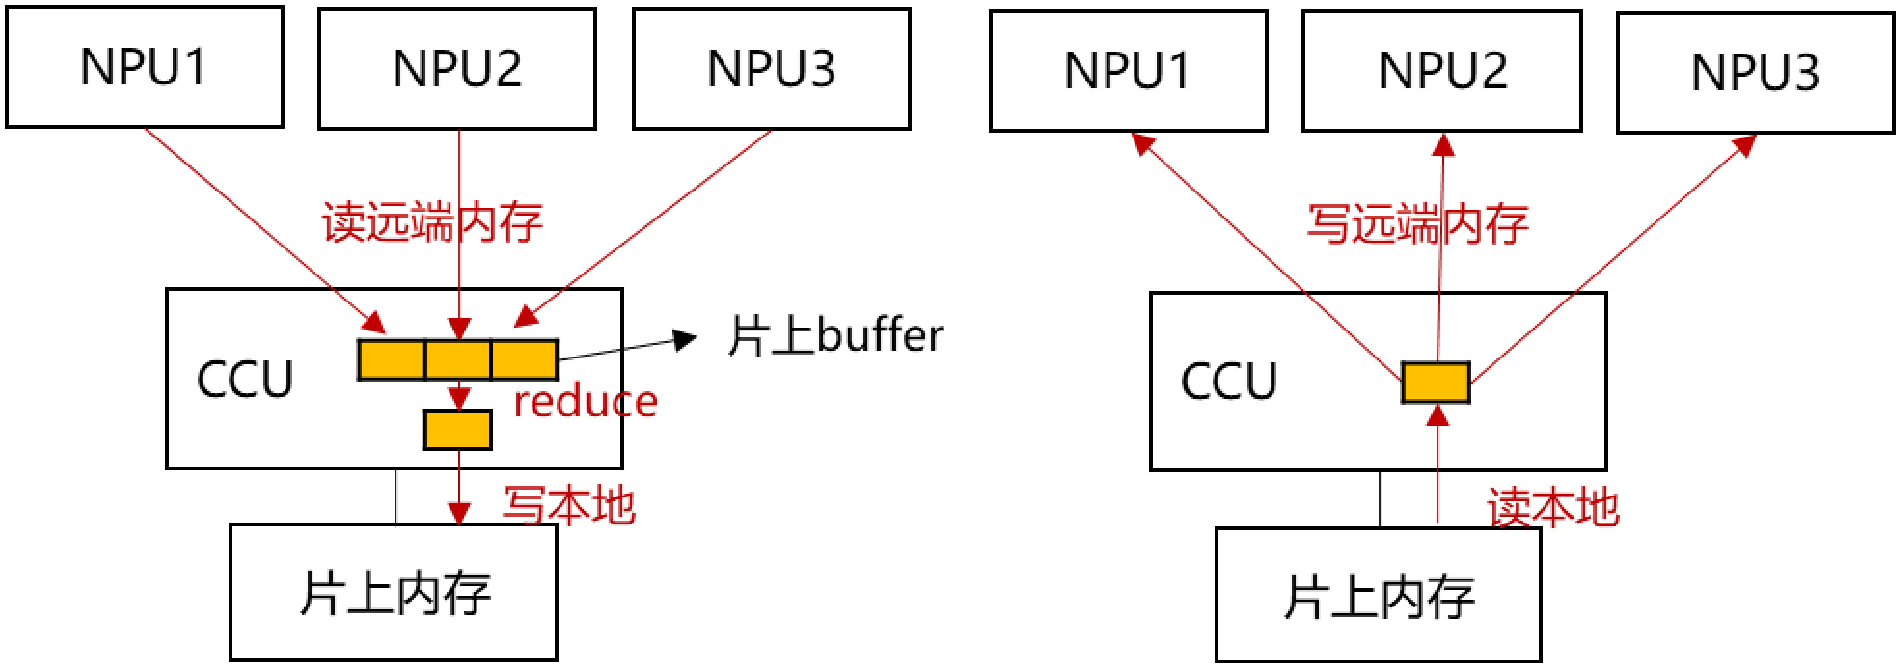

CCU 核心能力

扫码获取白皮书&
互动拿社区礼品

Thank you.

社区愿景：打造开放易用、技术领先的AI算力新生态

社区使命：使能开发者基于CANN社区自主研究创新，构筑根深叶茂、跨产业协同共享共赢的CANN生态

Vision: Building an Open, Easy-to-Use, and Technology-leading AI Computing Ecosystem

Mission: Enable developers to independently research and innovate based on the CANN community and build a win-win CANN ecosystem with deep roots and cross-industry collaboration and sharing.

上CANN社区获取干货

关注CANN公众号获取资讯

https://gitcode.com/cann