

低精度不迷路： 昇腾950四大格式选型+MXFP4补偿算法实践

昇腾 950 低精度选型

HiF8

38

自研 · 8-bit · 锥形精度

动态范围达到38个二进制指数

变长前缀码 Dot 域实现锥形精度，综合阶码范围 [-22, 15] 共 38 个，逼近 FP16 的 40 个；中心区高保真，激活 per-tensor + 权重 per-channel 即可达精度。

✓ 优势与实证

- 多模态训练 / 推理 —— Wan2.1-14B@950PR 端到端 $1.43 \times \text{BF16}$ 精度达标
- 大动态范围支撑 Delayed Scaling —— OLMo-1B 预训练 loss gap $\approx 0.25\%$
- KV 合一 / 稀疏 Attention —— LongCat、DSv3.1 IFA $1.7\text{--}2.6 \times \text{BF16}$

⚠ 自研格式/生态

MXFP8

32

OCP 标准 · 8-bit microscaling

个元素E4M3共享一个scale

32 个 FP8 元素共享一个 scale，局部分布适配能力明显优于 per-tensor FP8，在结构规整的 GEMM 上可充分释放性能。

✓ 优势与实证

- 语言模型推理 Prefill —— 精度无损，性能与 HiF8 相当
- Decode · GQA —— 结构规整，精度与性能均可达最优
- 训练精度达标 —— DSv3 / 盘古v3-34B / DSv4 裁剪版@950DT 实测

⚠ KV 合一/训练反传等场景存在二次量化

FP8

18

固定 E4M3 / E5M2

E4M3 仅 18 个二进制指数

固定指数 / 尾数划分。E4M3 精度优先但动态范围窄，E5M2 范围宽但精度过低；业界训练普遍只用 E4M3，靠极端细粒度 scaling 换精度。

✓ 优势与实证

- 业界验证充分 —— DeepSeek-V3 以 E4M3 per-block 完成训练
- 数据流简单，硬件与生态支持最广
- 已有 FP8 存量方案可直接复用、平滑迁移

⚠ per-tensor 遇 outlier 易溢出；细粒度 scaling 拖累性能 (Ling-1T E2E 仅 +15%)

MXFP4

32

4-bit microscaling · 极致压缩

个元素E2M1共享一个scale

32 个 FP4 元素共享一个 scale。4-bit 表示空间有限，不宜无差别铺开，定位于带宽极敏感且结构规整的大规模计算。


✓ 优势与实证

- MoE 推理 / 后训练 —— W4A8 (MXFP4 权重 + MXFP8 激活) 精度达标
- 相比 W8A8 收益 $1.7 \times$ ，大幅降低 expert 权重访存
- 部分场景 W4A4 精度亦达标，性能进一步提升

⚠ 4-bit 表达空间有限，预训练暂无案例；精度敏感模块不宜覆盖

DSv4 HiF8性能和精度验证

DSv4 HiF8性能和精度验证



这次我们围绕DeepSeek V4做了一次比较完整的HiF8推理实践，思路也从“单个低精度算子加速”逐步走向“整网统一低精度数据流优化”：
Sparse Attention中的离散访存和Scalar Bound；KV Cache与长上下文带来的带宽压力；
Quant/DeQuant、Cast等低精度附加开销；中间Tensor反复写回；
小算子与Kernel Launch；不同低精度算子之间的数据流衔接

DSv4 HiF8性能和精度验证

DSv4-Flash

Benchmark	Baseline	HiF8	Acc Drop
World Knowledge			
MMLU-Pro	83.0	82.7	-0.3
CMMLU	88.8	90.2	+1.4
GPQA-diamond	71.9	72.1	+0.2
Code & Math			
Math500	92.6	92.8	+0.2
LiveCodeBench	70.7	70.0	-0.7
Humanevalplus	86.8	87.6	+0.8
Long Context			
LongBenchV2(1M)	52.9	52.0	-0.9

DSv4-Pro

Benchmark	Baseline	HiF8	Acc Drop
World Knowledge			
MMLU-Pro	82.7	81.9	-0.8
CMMLU	87.6	87.5	-0.1
GPQA-diamond	71.2	73.7	+2.5
Code & Math			
Math500	95.4	94.4	-1.0
LiveCodeBench	69.2	69.0	-0.2
Humanevalplus	92.1	92.1	0.0

精度方面，HiF8在权重、激活和KV Cache上均表现出较好的数值保真度，主要Benchmark与高精度基线基本持平；

DSv4 HiF8性能和精度验证

优化阶段	阶段一优化(单模块带来的相对基线整网收益)	阶段二优化(单模块带来的相对基线整网收益)	相对MXFP8累计收益
MXFP8基线	-	-	1.00x
HiF8量化+MatMul	1.05x (HiF8 matmul初步优化/fixpipe直出HiF8/量化融合)	1.07x (HiF8 matmul在阶段一基础上进一步优化)	1.07x
SparseMLA HiF8	-	1.04x	1.11x
QuantCompressor HiF8	-	1.03x	1.14x
QuantLightningIndexer HiF8	-	1.02x	1.16x
最终方案	-	-	1.16x

SparseMLA方面，HiF8不只是节省带宽，而是通过QKPV全量化、紧凑数据表示、Scale复用以及访存/计算流水重构，进一步缓解了原有SparseMLA中明显的Scalar Bound。

长上下文场景收益更加突出，1M Decode下单算子最高达到约 1.39× 加速。

融合方面，通过RmsNorm+Quant、Rotary+Quant等融合，将中间结果尽可能留在片上，减少完整Tensor写回和Kernel Launch，部分模块可达到2.31×加速。

整网方面，HiF8不再只是MatMul的输入格式，而是尽量形成：HiF8输入 → HiF8计算 → HiF8输出的连续运行路径，减少HiF8 ↔ BF16之间反复Quant/DeQuant和数据搬运。

DSv4 HiF8性能和精度验证

cann-recipes-infer

🚀 Latest News

模型	序列	GBS	推理阶段	部署卡数	MXFP8(ms)	HiF8(ms)	HiF8提升
DSV4 Flash	8K	16	decode	16	17.39	15.96	8.22%
		256	decode	16	23.64	21.59	8.67%
		1536	decode	16	34.73	28.83	16.99%
	128K	16	decode	16	17.82	16	10.21%
		256	decode	16	33.96	23.48	30.86%
	1M	16	decode	16	24.73	17.93	27.5%

模型	序列	GBS	推理阶段	部署卡数	MXFP8(ms)	HiF8(ms)	HiF8提升
DSv4 Pro	8K	16	decode	16	43.04	39.85	7.4%
		64	decode	16	46.43	42.01	9.5%
		128	decode	16	50.29	45.57	9.4%
	128K	1	decode	16	47.48	40.37	15%
		4	decode	16	51.80	44.45	14.2%

在当前方案下：DeepSeek V4 Flash 相比 MXFP8 获得约 8%–30% 的整网性能收益；DeepSeek V4 Pro 获得约 7%–15% 的整网性能收益。这次实践给我们的一个核心体会是：低精度的下一阶段竞争，可能不再只是“谁的 MatMul 更快”，而是谁能够把数据格式、算子融合、片上数据流和整网执行真正协同起来。

https://gitcode.com/cann/cann-recipes-infer/blob/master/docs/models/deepseek_v4/deepseek_v4_inference_guide.md

FP4时代的格式竞争与问题定义

目标：在昇腾950仅原生支持MXFP4计算的条件下，通过软件和算法补偿提升精度表现，同时保持MXFP4硬件高吞吐优势

背景判断

W4A4 正成为降低计算、带宽与部署成本的关键方向

当前业界4bit数据格式：

- OCP MXFP4
- 友商 xxFP4

MXFP4 vs xxFP4：精度差异来自Group与Scale

对比项	MXFP4	xxFP4	影响
Data Format	E2M1/E1M2	E2M1	基本一致
Group Size	32	16	更细粒度适配局部分布
Scale Format	E8M0	E4M3	Scale有Mantissa

研究问题

在保持MXFP4高吞吐优势的前提下，提升4bit量化的模型精度

重点验证网络覆盖

- DeepSeek-V4-Flash
- Qwen3-235B
- Pangu-90B-Flash
- Wan2.2-14B
- Hunyuan3

MXFP4精度短板：两个根因

同为E2M1，真正造成差距的是 Group Size=32 的Outlier污染，以及E8M0 Scale缺少Mantissa造成的尺度误差

A. Group Size = 32：局部异常值污染

本质：Group内部动态范围过大

E2M1有效表示点极少，Scale高度受Group内amax主导
少量Outlier拉大Scale，使正常值落入低值粗量化区间，甚至量化为0

XXFP4将Group从32降至16，异常值影响范围缩小
公开分析显示：Block 32→16可降低flush-to-zero，并带来约1dB QSNR改善



outlier主导Scale → 正常值分辨率下降

B. E8M0 Scale：尺度量化误差


本质：Scale Resolution不足

E8M0没有Mantissa，Scale只能表达2的整数次幂

最优Scale落在两个Power-of-Two之间时，会产生系统性Scale Error

XXFP4采用E4M3 Scale，可在同一指数区间内进一步细分

公开实验显示：提升Scale Mantissa精度可带来约3–4dB QSNR收益



最优Scale被迫映射到2的指数幂 Scale

MXFP4精度补偿技术路线

两类补偿：Scale精度补偿解决E8M0缺Mantissa；数据分布整形解决Group Size=32的Outlier污染



路线A：Scale精度补偿

解决 E8M0 没有 Mantissa 的问题

- 引入高精度二级Scale / Scale校正机制
- 补偿Power-of-Two Scale造成的系统性Scale Error
- 特点: 优先作为基础增强能力，模型无关性强、工程改造较小
- 代表技术：二级量化

关键词：E8M0 → E8M0 + low-cost correction

路线B：数据分布整形

解决 Group Size=32 的Outlier污染



- 通过量化算法降低Group内数值分布
- 将异常值影响从“污染整个Group”转为“更均匀分摊”
- 代表技术：Hadamard Quantization、FlatQuant、BATQuant、RotQuant

关键词：reshape distribution before MXFP4 quantization

结论：MXFP4的精度差距并非来自E2M1本身，而主要来自Group Size与Scale Resolution；因此软件补偿具备明确空间。

二级量化算法




二级量化（Two-Level Quantization）是将量化尺度拆分为两层（块级 + 子块级）的轻量高精度方案，核心是在极低额外开销下提升低比特量化的精度，适配大模型权重 / 激活、KV 缓存等场景，常见于 MX 系列格式实现。



性能：在GroupSize=512，Matmul在CubeBound场景性能平均达到纯mxfp4的90+%

Hadamard量化算法


- Hadamard 量化（常称 Hadamard Quantization, HQ）是基于块对角哈达玛变换的低比特量化算法，Hadamard矩阵是一种特殊的**正交矩阵**，其元素主要为 ± 1 （归一化后为 $\pm 1/\sqrt{d}$ ）。
- 在LLM量化中，导致精度损失的核心原因是：**权重和激活值（尤其是激活）存在显著的异常值（outlier）**，导致低精度量化时误差大、模型性能急剧下降。
- Hadamard变换作为一种等价的旋转/变换（不改变整体L2范数，能量守恒），能将异常值“扩散”到其他维度，使数据分布更接近高斯分布、更均匀，对量化更加友好，从而大幅降低量化误差。



RotQuant量化算法

关键优化点:

- (1) 联合MXFP4优化的LHT(Learnable Hadamard Transform)学习技术: 针对MXFP Group Size=32的特点, 设计**小尺寸旋转矩阵**, 完成同一个Group内或不同Group间的数据平滑操作, 并使用正交保持优化器学习局部最优的正交旋转矩阵, 从而最小化每个Block的MXFP4量化损失。
- (2) 增加**可学习Clipping**技术: 针对数据的动态范围过大和Outlier问题, 同步学习数据上下界截断极大值, 收窄数据动态范围, 缓解极大值对MXFP4精度损失过大的问题;



FlatQuant量化算法

- FlatQuant 是华为诺亚方舟实验室、清华大学和香港中文大学联合提出的大模型后训练量化（PTQ）方法，核心是通过为**每个线性层定制快速可学习仿射变换，提升权重与激活分布的平坦度以降低低比特量化误差**，在 W4A4@INT4 低精量化场景下实现近无损精度与显著推理加速。全称 Fast and Learnable Affine Transformation，同时强调 “平坦（flat）分布” 的核心目标，适配 LLaMA、Qwen、DeepSeek 等主流模型，兼容权重量化、KV 缓存量化等多种场景。
- 解决痛点：LLM 权重 / 激活常存在离群值，导致低比特量化误差大；传统预量化变换（如逐通道缩放、哈达玛变换）难以实现最优平坦分布，而 FlatQuant 通过轻量学习型变换填补这一空白。






图1: FlatQuant 整体框架 (Q/Q^{-1} 为量化/反量化, P 为仿射变换矩阵)


$$\boxed{\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \otimes \begin{bmatrix} 0 & 5 \\ 6 & 7 \end{bmatrix}} = \begin{bmatrix} 1 \begin{bmatrix} 0 & 5 \\ 6 & 7 \end{bmatrix} & 2 \begin{bmatrix} 0 & 5 \\ 6 & 7 \end{bmatrix} \\ 3 \begin{bmatrix} 0 & 5 \\ 6 & 7 \end{bmatrix} & 4 \begin{bmatrix} 0 & 5 \\ 6 & 7 \end{bmatrix} \end{bmatrix} = \begin{bmatrix} 1 \times 0 & 1 \times 5 & 2 \times 0 & 2 \times 5 \\ 1 \times 6 & 1 \times 7 & 2 \times 6 & 2 \times 7 \\ \hline 3 \times 0 & 3 \times 5 & 4 \times 0 & 4 \times 5 \\ 3 \times 6 & 3 \times 7 & 4 \times 6 & 4 \times 7 \end{bmatrix} = \begin{bmatrix} 0 & 5 & 0 & 10 \\ 6 & 7 & 12 & 14 \\ \hline 0 & 15 & 0 & 20 \\ 18 & 21 & 24 & 28 \end{bmatrix}$$

图3: Kronecker Product 示意图, 参与学习训练参数为最左侧开始的两个小矩阵




BATQuant量化算法 (算子可以复用hadamard离线校准, 针对MX)

- 解决痛点问题: 全局正交旋转 (QuaRot/SpinQuant 类方法) 在 MXFP4 下会把异常值能量转移到相邻量化块, 扰乱 group 缩放因子估计, 甚至精度劣化。
- **BATQuant 把变换矩阵限制为与 MXFP 量化粒度** (group_size = 32) 变换粒度与量化粒度严格对齐: 从根本上阻断异常值跨block转移, 专为MXFP格式设计, 而非直接套用INT格式的旋转方案, 同时支持引入 block 级可学习裁剪压制残留异常值。
- BATQuant 运用了过 **GPK 分解** (全局共享矩阵 **A** + block 私有矩阵 **B_i**) 大幅降低校准参数量。比 FlatQuant 的 Kronecker 分解减少 74%+ 参数。



GPK 分解: $P_i = B_i \otimes A$



参数量: 全局 $A(8 \times 8)$ + 每block私有 $B_i(4 \times 4)$, 比 FlatQuant 的 Kronecker 方案减少 74%+

MXFP4精度补偿技术： Qwen3-235B-A22B 实验结果

方案	math500	gpqa	humaneval+	longbench	cmmlu	mmlupro	livecodebench	平均 drop
BF16（基线）	90.6	60.6	89.2	43.8	87.6	80.5	35.3	—
量化方案1	90.3	60.8	88.1	44.6	86.5	79.8	35.3	
acc drop	-0.3	+0.2	-1.1	+0.8	-1.1	-0.7	0.0	-0.3
量化方案1 + 二级量化	90.4	60.8	87.2	51.3	87.0	79.6	35.6	
acc drop	-0.2	+0.2	-2.0	+7.5	-0.6	-0.9	+0.3	+0.6
量化方案1 + Hadamard	90.9	62.6	87.0	44.3	87.1	80.2	35.6	
acc drop	+0.3	+2.0	-2.2	+0.5	-0.5	-0.3	+0.3	0.0
量化方案1 + BATQuant	90.3	58.9	87.4	46.8	86.8	79.8	37.1	
acc drop	-0.3	-1.7	-1.8	+3.0	-0.8	-0.7	+1.8	-0.1
量化方案1 + FlatQuant	90.7	59.3	88.3	52.6	87.0	79.5	35.9	
acc drop	+0.1	-1.3	-0.9	+8.8	-0.6	-1.0	+0.6	+0.8

1.

相比于基线方案，将moe直转为mxfp4 w4a4时，出现多个数据集掉点大于1的情况；
2.

分别尝试hadamard, BAT, FlatQuant, 二级量化后，各下游任务精度有不同情况的变化，平均精度相比与校准前均有提升；
3.

综合比较，flatquant校准后精度最好；

Acc drop 说明： ■ > 1.0 pp（显著掉点）

注： 量化方案1： MoE GMM采用mxfp4 w4a4量化， linear projections采用mxfp8 w8a8量化

MXFP4精度补偿技术： Wan2.2实验结果

- Wan2.2的评测分为两个大的群组，分别为 Quality Score 和 Semantic Score ；
- moe w4a4直转时，多个下游任务出现大幅掉点的情况；

Benchmark	Quality Score					
	subject_consistency	background_consistency	temporal_flickering	motion_smoothness	aesthetic_quality	imaging_quality
Baseline	94.5	94.7	98.1	97.8	66.6	71.9
量化方案1	95.1	94.6	97.7	97.6	67.5	71.3
acc drop	+0.6	-0.1	-0.4	-0.2	+0.9	-0.6
量化方案1 + 二级量化	94.7	94.3	97.5	97.4	67.9	71.3
acc drop	+0.2	-0.4	-0.6	-0.4	+1.3	-0.6
量化方案1 + Hadamard	94.9	94.3	97.7	97.5	67.4	71.6
acc drop	+0.4	-0.4	-0.4	-0.3	+0.8	-0.3
量化方案1 + FlatQuant	94.7	93.8	97.7	97.4	67.7	70.6
acc drop	+0.2	-0.9	-0.4	-0.4	+1.1	-1.3
量化方案1 + BATquant	94.5	94.4	97.7	97.6	67.4	70.6
acc drop	0.0	-0.3	-0.4	-0.2	+0.8	-1.3

Benchmark	Semantic Score								
	object_class	multiple_objects	human_action	color	spatial_relationship	scene	temporal_style	appearance_style	overall_consistency
Baseline	84.6	67.1	83.3	90.0	89.4	27.7	22.9	19.9	25.6
量化方案1	94.2	71.3	86.7	87.8	82.8	26.5	23.0	20.6	25.2
acc drop	+9.6	+4.2	+3.4	-2.2	-6.6	-1.2	+0.1	+1.3	-0.4
量化方案1 + 二级量化	82.5	70.0	83.3	88.7	87.3	25.8	22.9	20.7	25.4
acc drop	-2.1	+2.9	0.0	-1.3	-2.1	-1.9	0.0	+0.8	-0.2
量化方案1 + Hadamard	85.6	73.3	86.7	89.6	79.4	24.6	22.9	20.6	25.3
acc drop	+1.0	+6.2	+3.4	-0.4	-10.0	-3.1	0.0	+0.7	-0.3
量化方案1 + FlatQuant	87.5	66.9	80.0	90.2	88.6	27.3	22.4	20.5	25.8
acc drop	+2.9	-0.2	-3.3	+0.2	-0.8	-0.4	-0.5	+0.6	+0.2
量化方案1+ BATquant	87.7	69.4	83.3	90.2	91.5	29.4	22.9	20.9	25.0
acc drop	+3.1	+2.3	0.0	+0.2	+2.1	+1.7	0.0	+1.0	-0.6

Acc drop 说明: ■ > 1.0 pp (显著掉点)

注：量化方案1: MoE GMM采用mxfp4 w4a4量化，linear projections采用mxfp8 w8a8量化

MXFP4精度补偿技术： Wan2.2实验结果(精度汇总)

多种方案精度比较后，BATQuant效果最好

	综合质量(Quality)	综合语义(Semantic)	综合得分
Baseline	85.3	72.3	82.7
量化方案1	84.7	73.2	82.4
acc drop	-0.6	+0.9	-0.3
量化方案1+二级量化	84.7	72.0	82.1
acc drop	-0.6	-0.3	-0.6
量化方案1+Hadamard	84.3	72.1	81.9
acc drop	-1.0	-0.2	-0.8
量化方案1+FlatQuant	84.5	72.3	82.1
acc drop	-0.8	0.0	-0.6
量化方案1+BATquant	84.7	73.6	82.5
acc drop	-0.6	+1.3	-0.2

注： 量化方案1： MoE GMM采用mxfp4 w4a4量化， linear projections采用mxfp8 w8a8量化

Acc drop 说明： ■ > 1.0 pp（显著掉点）

MXFP4精度补偿技术：OpenPangu-V2 Flash/DeepSeek-V4 Flash/Hy3 实验结果

OpenPangu V2 Flash 92B moe直转mxfp4 w4a4即可实现精度无损

Benchmark	GPQA-diamond	Math500	Livecodebench	Humaneval+	LongBenchv2 (400K)	Average Acc Drop
Baseline	82.8	95.8	79.9	91.7	59.7	
量化方案1	84.3	96.0	79.2	90.9	58.9	
acc drop	+1.5	+0.2	-0.7	-0.8	-0.8	-0.1

DeepSeek-V4-Flash moe直转mxfp4 w4a4即可实现精度无损

Benchmark	MMLU-Pro	CMMLU	Math500	GPQA-diamond	Humaneval+	LiveCodeBench	LongBenchv2	Average Acc Drop
Baseline	82.68	89.41	94.4	72.2	87.2	64.55	54.87	
量化方案1	82.41	89.21	93.8	73.23	87.2	64.55	54.76	
acc drop	-0.27	-0.2	-0.6	+1.03	0	0	-0.11	-0.02

Hunyuan3 moe直转mxfp4 w4a4多个任务掉点严重；FlatQuant校准后可实现精度无损

Benchmark	MMLU-Pro	CMMLU	Math500	GPQA-diamond	Humaneval+	LiveCodeBench	LongBenchv2	Average Acc Drop
Baseline	82.46	89.87	96.4	75.25	86.59	60	61.11	
量化方案1	81.6	89.5	95.2	73.2	84.76	44.36	60.6	
acc drop	-0.86	-0.37	-1.2	-2.05	-1.83	-15.64	-0.51	-3.21
量化方案1 + FlatQuant	81.57	89.61	95.8	74.75	86.59	60.19	61.67	
acc drop	-0.89	-0.26	-0.6	-0.5	0	0.19	0.56	-0.21
量化方案1 + Hadamard	81.6	89.4	95.6	74.2	86.59	54.12	62.2	
acc drop	-0.86	-0.47	-0.8	-1.05	0	-5.88	1.09	-1.14

注：量化方案1：MoE GMM采用mxfp4 w4a4量化，linear projections采用mxfp8 w8a8量化

Acc drop 说明： ■ > 1.0 pp（显著掉点）

CANN

MXFP4精度补偿技术：各精度补偿方案综合比较

技术方案	主要解决问题	精度潜力	Runtime开销	Calibration成本
Native MXFP4	Baseline	中	最低	无
二级量化算法	E8M0 Scale精度。	高	低	低
可学习Hadamard	Group Outlier + Dynamic Range	高	低-中	中
FlatQuant	Weight/Activation整体分布	很高	中	高
BATQuant	MX Group Outlier	很高	中	中~高

MXFP4精度补偿技术：技术结论与昇腾950建议

从当前分析和实验方向看，MXFP4精度劣势主要来自：

- ① Group Size 为 32偏大，存在Outlier时精度损失严重；
- ② E8M0 格式的Group Scale缺少Mantissa，可表达精细化程度低，导致出现Scale Quantization Error。

推荐的精度补偿路线

第一层：基础能力——直转 / GPTQ

第二层：低成本PTQ——可学习Hadamard / 二级量化

第三层：高精度PTQ——FlatQuant / BATQuant

AMCT: 端到端大模型量化部署工具

仓库定位

面向 Ascend 推理的大模型量化，支持模型精度测评、算法训练与权重导出。

数据格式

当前已支持INT、MXFP、HiFloat

量化算法

当前已支持LWC、LAC、Autoround、AWQ、Omniquant、Flatquant，短期内计划加入BATQuant、SVDQuant

模型适配

当前已支持Qwen系列、DeepSeek系列、GLM系列、Longcat系列、Kimi系列等多个模型

主流程

01

原生精度

测量 BF16，作为后续量化的精度基准

02

直转评测

未使能量化算法的直转精度评估

03

数据提取

提取量化校准数据，用于 PTQ

04

PTQ 优化

提供量化算法，优化量化带来的精度损失

05

结果评测

使能量化算法后的精度评估

06

权重导出

导出可以在 cann-recipes-infer 仓库部署的量化权重

获取更多模型在A2 / A3 / Ascend 950的部署实践



<https://gitcode.com/cann/cann-recipes-infer>

获取更多模型量化实践和量化算法



<https://gitcode.com/cann/amct>

完成社区任务可获得定制礼品



<https://gitcode.com/cann/amct/discussions/4>

昇腾 950 低精度选型

HiF8

38

自研 · 8-bit · 锥形精度

动态范围达到38个二进制指数

变长前缀码 Dot 域实现锥形精度，综合阶码范围 $[-22, 15]$ 共 38 个，逼近 FP16 的 40 个；中心区高保真，激活 per-tensor + 权重 per-channel 即可达精度。

✓ 优势与实证

- 多模态训练 / 推理 —— Wan2.1-14B@950PR 端到端 $1.43 \times \text{BF16}$ 精度达标
- 大动态范围支撑 Delayed Scaling —— OLMo-1B 预训练 loss gap $\approx 0.25\%$
- KV 合一 / 稀疏 Attention —— LongCat、DSv3.1 IFA $1.7\text{--}2.6 \times \text{BF16}$

⚠ 自研格式/生态

FP8

18

固定 E4M3 / E5M2

E4M3 仅 18 个二进制指数

固定指数 / 尾数划分。E4M3 精度优先但动态范围窄，E5M2 范围宽但精度过低；业界训练普遍只用 E4M3，靠极端细粒度 scaling 换精度。

✓ 优势与实证

- 业界验证充分 —— DeepSeek-V3 以 E4M3 per-block 完成训练
- 数据流简单，硬件与生态支持最广
- 已有 FP8 存量方案可直接复用、平滑迁移

⚠ per-tensor 遇 outlier 易溢出；细粒度 scaling 拖累性能 (Ling-1T E2E 仅 +15%)

MXFP8

32

OCP 标准 · 8-bit microscaling

个元素E4M3共享一个scale

32 个 FP8 元素共享一个 scale，局部分布适配能力明显优于 per-tensor FP8，在结构规整的 GEMM 上可充分释放性能。

✓ 优势与实证

- 语言模型推理 Prefill —— 精度无损，性能与 HiF8 相当
- Decode · GQA —— 结构规整，精度与性能均可达最优
- 训练精度达标 —— DSv3 / 盘古v3-34B / DSv4 裁剪版@950DT 实测

⚠ KV 合一/训练反传等场景存在二次量化

MXFP4

32

4-bit microscaling · 极致压缩

个元素E2M1共享一个scale

32 个 FP4 元素共享一个 scale。4-bit 表示空间有限，不宜无差别铺开，定位于带宽极敏感且结构规整的大规模计算。

✓ 优势与实证

- MoE 推理 / 后训练 —— W4A8 (MXFP4 权重 + MXFP8 激活) 精度达标
- 相比 W8A8 收益 $1.7 \times$ ，大幅降低 expert 权重访存
- 部分场景 W4A4 精度亦达标，性能进一步提升

⚠ 4-bit 表达空间有限，预训练暂无案例；精度敏感模块不宜覆盖

Thank you.

社区愿景：打造开放易用、技术领先的AI算力新生态

社区使命：使能开发者基于CANN社区自主研究创新，构筑根深叶茂、跨产业协同共享共赢的CANN生态

Vision: Building an Open, Easy-to-Use, and Technology-leading AI Computing Ecosystem

Mission: Enable developers to independently research and innovate based on the CANN community and build a win-win CANN ecosystem with deep roots and cross-industry collaboration and sharing.



上CANN社区获取干货



关注CANN公众号获取资讯