

CANN 算子天梯赛

6月赛题评析与7月赛题解析

作者：张鑫/胡邵娟

时间：2026/07/21

目录

Part 1 天梯赛6月冠军代码解析

Part 2 天梯赛7月赛题思路解析

CANN算子天梯赛

● 进行中

2026年CANN算子天梯赛

CANN 算子天梯赛，是面向全社会 AI 算子工程师的长期算子性能极限挑战赛，基于昇腾平台对算子进行长期优化打榜，按月度结算奖励性能榜首，为每一位算子开发者提供绝佳的实践平台。

主办方: CANN开源社区

💡 总奖金池

¥66,000

168

已报名

154

参赛队伍

345

距截止 / 天

立即报名 →

赛事介绍

赛题发布

实时榜单

晋级榜单

作品展览

获奖名单

1

报名开始时间

>

2

比赛开始时间

>

3

报名截止时间

>

4

比赛结束时间

2026/05/21 00:00:00

2026/06/01 00:00:00

2027/06/30 17:00:00

2027/06/30 17:00:00



2026 CANN 算子天梯赛

三

“**大赛简介** CANN 算子天梯赛，是面向全社会 AI 算子工程师的长期算子性能极限挑战赛，基于昇腾平台对算子进行长期优化打榜，按月度结算奖励性能榜首，为每一位算子开发者提供绝佳的实践平台。”

“天梯赛的算子题目来源于真实的场景需求，目的是让参赛者持续优化的算子可以合入CANN算子库并在真实场景发挥作用。因此天梯赛算子禁止只针对特定shape进行编程，需要参赛者实现泛化的算子以满足实际场景不同算子规格的要求。”

报名链接: <https://competition.gitcode.com/competition/2057085957316272129/intro>

CANN算子天梯赛6月算子题目答题情况

答题情况概览

算子	类型	难度系数	尝试人数	通过人数	月度冠军奖品
Celu	vector	1	53	28	HUAWEI MatePad 11.5 柔光版 WIFI 8
Selu	vector	1	31	20	HUAWEI MatePad 11.5 柔光版 WIFI 8
HardSwish	vector	1	28	19	HUAWEI MatePad 11.5 柔光版 WIFI 8
QuantBatchMatmulV3的K-C 量化场景末维上限约束消除	cube	4	23	9	HUAWEI Mate80ProMax 16GB+512GB 极 昼金 双卡 全网通版
QuantBatchMatmulV3的K-C 量化场景性能优化	cube	4	60	31	HUAWEI Mate80ProMax 16GB+512GB 极 昼金 双卡 全网通版
Conv2D	cube	4	28	1	HUAWEI Mate80ProMax 16GB+512GB 极 昼金 双卡 全网通版

奖品展示



CANN算子天梯赛6月冠军代码解析

Celu/Selu/HardSwish

6月冠军实现解析:

- ① 开Double Buffer
- ② 均匀分块
- ③ 自适应分核
- ④ 计算方式优化
- ⑤ 其中Hardswish是面向case编程, 每个case优化基本到上限, 其他泛化场景未处理

3个elementwise算子实现分支细致, 基本已经达到极限

Conv2D

6月冠军实现解析:

- ① 使用for循环遍历, 实现单点的卷积乘累加操作
- ② 针对case规格进行了分支处理, 后续考虑泛化性

下一步性能优化思路解析:

- ① 使用Cube核和支持指令完成Conv, VCV组合实现
- ② 利用Img2Col和SIMD指令, 高效完成乘累加
- ③ 考虑vec与Cube间数据依赖, 通过Tiling和kernel配合, 实现CV并行能力
- ④ 参考资料:

https://www.hiascend.com/document/detail/zh/canncommercial/latest/API/ascendcopapi/atlasascendc_api_07_0249.html

QuantBatchMatmulV3的K-C 量化场景末维上限约束消除

6月冠军实现解析:

- ① 使用vec cube串行实现: C核→ GetTensorC(L0C→GM) → V核累加 → 下一K块C核 → ... → 最终V核量化输出
- ② AIC-AIV串行: MAC利用率8%
- ③ tiling策略层面: 硬编码baseM= singleCoreM = 7, 可考虑进一步调整tiling策略

下一步性能优化思路解析:

- ① 优化流水排布: 使用cv并行实现
- ② 调整tiling策略: 针对shape约束范围内泛化策略
- ③ 尝试K轴错峰加载缓解bank冲突
- ④ 尝试MTE2 preload优化数据搬运流水

新增赛制约束:

- ① 跨月赛题当月性能最佳提交且超过历史最佳性能3%以上成为月度冠军获奖, 计算方式为所有测试用例耗时总和提升比例大于3%。
- ② 要求具备泛化性, 满足赛题中的范围, 禁止针对用例白盒编程。
- ③ 每月封榜后会对算子进行泛化性验收测试, 通过验收才奖励。
- ④ 每月单人最多获奖三道赛题, 优先奖金级别最高的三道题。

优化思路参考:

- ① 开源算子仓:
<https://gitcode.com/cann/ops-math>, <https://gitcode.com/cann/ops-cv>,
<https://gitcode.com/cann/ops-nn>, <https://gitcode.com/cann/ops-transformer>
- ② samples样例仓: <https://gitcode.com/cann/cann-samples>
- ③ CANN微信公众号: 微信扫描右侧二维码



CANN算子天梯赛7月算子题目解读

赛题概览

算子	类型	难度系数	难点	月度冠军奖品
causal_conv1d_update	vector	2	Tiling分核、负载均衡	4000元等值奖品
confusion_matrix	vector	3	Tiling分核、负载均衡、数据搬运	6000元等值奖品
inplace_update	vector	3	数据搬运, DoubleBuffer	6000元等值奖品
recompute_w_u	fusion	2	Matmul API, CV同步、流水排布	4000元等值奖品
chunk_scaled_dot_kkt	fusion	3	Matmul API, CV同步、流水排布	6000元等值奖品
chunk_gated_delta_rule_fwd_h	fusion	5	Matmul API, CV同步、流水排布、负载均衡	10000元等值奖品

CANN算子天梯赛7月算子题目解读

causal_conv1d_update

算子功能描述:

对序列执行因果一维卷积，沿序列维度使用缓存数据（长度为卷积核宽减1）对各序列头部进行padding，确保输出依赖当前及历史输入。对每个dim，每个时间步t，执行以下计算：

$$y(t, dim) = \sum_{j=0}^{K-1} weight(t, dim) \cdot x'[t-j, dim]$$

$K = weight$ 卷积核宽度，通常为 2/3/4

x' 为扩展后输入：当 $t-j < 0$ 时，从conv_state 读取历史；若无历史则为 0

可选融合算子SiLu

优化策略:

- ① decode阶段使用，序列长度较小，优先使用dim进行分核，负载均衡
- ② 减少重复数据搬运，优化MTE2

注意:

- ① 当前序列计算完后，conv_state需要原地更新，用于下一个序列的计算
- ② 支持MTP时，cache_state的计算需要用到num_accepted_tokens

参考资料:

- ① A5实现: https://gitcode.com/cann/ops-transformer/tree/master/attention/fused_causal_conv1d
- ② triton实现: https://github.com/vllm-project/vllm-ascend/blob/main/vllm_ascend/ops/triton/mamba/causal_conv1d.py

chunk_gated_delta_rule_fwdh

算子功能描述:

线性注意力的GDN模块中的一个部分，主要是在前向传播阶段，沿着序列块(chunk)推进隐状态(hidden state)，结合门控衰减g和delta规则，完成每一个chunk h_{t+1} 的计算，输出前向递推的最终状态。

每个chunk计算过程:

C1: $w @ h_t$

V1: $v_{new} = u - w @ h_t$, $v_{new_decay} = v_{new} \cdot \exp(g_{last} - g)$

C2: $h'_t = k^T @ v_{new_decay}$

V2: $h_{t+1} = h_t \cdot \exp(g_{last}) + h'_t$

优化策略:

- ① Tiling方式: chunk之前有依赖，只能通过h * batch进行切分
- ② 考虑在变长序列场景下，不同的batch，序列长度不同，注意核间负载均衡
- ③ CV并行，充分考虑CV依赖，优化流水排布
- ④ CV核间优先使用硬同步，Matmul低阶API使用

注意:

- ① shape的转置

参考资料:

- ① 融合算子实现: https://gitcode.com/cann/ops-transformer/tree/master/attention/chunk_gated_delta_rule
- ② Matmul API使用: https://gitcode.com/cann/ascend/devkit/blob/master/examples/01_simd_cpp_api/04_advanced_api/00_matmul/README.md
https://gitcode.com/cann/ascend/devkit/blob/master/examples/01_simd_cpp_api/03_basic_api/03_matrix_compute/README.md

Thank you.

社区愿景：打造开放易用、技术领先的AI算力新生态

社区使命：使能开发者基于CANN社区自主研究创新，构筑根深叶茂、跨产业协同共享共赢的CANN生态

Vision: Building an Open, Easy-to-Use, and Technology-leading AI Computing Ecosystem

Mission: Enable developers to independently research and innovate based on the CANN community and build a win-win CANN ecosystem with deep roots and cross-industry collaboration and sharing.



上CANN社区获取干货



关注CANN公众号获取资讯