

CANN 挑战赛赛题解析

作者：宋恺 分享嘉宾：田起光、陈思、陈书剑

时间：2026年9月

目录

Part 1 赛事介绍

Part 2 赛题解读

CANN是什么

CANN（Compute Architecture for Neural Networks）是华为针对AI场景推出的**异构计算架构**，对上支持多种AI框架，对下服务AI处理器与编程，发挥承上启下的关键作用，是提升昇腾AI处理器计算效率的关键平台。



<https://gitcode.com/cann>

大赛简介及日程

CANN挑战赛是由 CANN开源社区 主办的赛事。大赛依托华为算法挑战赛，围绕昇腾AI算子开发、功能实现与性能优化设置竞赛任务，并提供配套学习资源和在线实践环境，帮助参赛选手了解算子开发流程，提升编程实践和性能优化能力。本届赛事设置 **杭厦、上合、京津东北、西北、西南**五大赛区，面向全国相关区域高校学生开放报名。欢迎高校学子参与挑战。


注：各个**赛区时间**以赛事**卡片**、社区**通知**为准。

初赛



前**32强**队伍晋级复赛

决赛



现场决出**一等奖、二等奖、三等奖**

一等奖、二等奖获奖队伍邀请参与 **12月5日** 的全国总决赛

赛事规则

1.

参赛对象：

高校在校学生。

2.

参赛要求：

参赛选手需要根据赛题赛规要求，在指定时间内完成报名、赛区选择、组队、作品提交，方为有效参赛。报名资料提交后将无法修改。每支队伍仅允许队长申请算力资源，申请算力资源后不能更换团队名称、队伍成员，请参赛者注意在申请算力资源前完成队伍组建。

3.

组队要求：

先报名后组队，**每支队伍1-3人**，要求队伍成员在同一赛区（同一赛区不同学校可跨学校组队，不同赛区不可跨赛区组队）；报名后选手需要在PC端登录大赛官网并进入赛区页面组队。

4.

比赛规则：


- 区域比赛分两个阶段：**线上初赛**和**线下决赛**，每个阶段都需要参赛队伍至少提交一次作品，才能准确计算有效成绩。大赛将选取各参赛队伍正式赛中的**最后提交的成绩**，作为本团队最终成绩进行排名，请各位选手做好版本管理。

5.

公平参赛：

每个阶段比赛结束后大赛组委会将进行代码查验，如发现代码重复或违规等情况，将取消该队伍参赛资格和现有成绩。

2026赛区介绍



比赛地点：初赛线上、决赛分布在6个研究所。

上合赛区（上研所）：上海、安徽

杭厦赛区（杭研所）：浙江、福建、江西

京津东北（北研所）：北京、天津、黑龙江、吉林、辽宁、河北、内蒙古

西北（西研所）：陕西、甘肃、河南、山西、新疆、青海、宁夏

西南（成研所）：四川、重庆、云南、贵州

已结束

江山（南研所）：江苏、山东

国内学生：选按照学校所在城市选择对应赛区报名，赛区内可多校学生组队参加，每队人数1~3人

海外中国籍留学生：需按照国内居住地所在城市选择对应赛区报名

CANN

奖项设置

— 决赛（每个赛区） —



一等奖（团队1支）
奖金 ¥20,000
机考绿卡 面试绿卡 荣誉证书



二等奖（团队5支）
奖金 ¥10,000
机考绿卡 面试绿卡 荣誉证书



三等奖（团队15支）
奖金 ¥2,000
机考绿卡 荣誉证书

— 初赛 —

每个赛区初赛前 **32** 强团队获得



荣誉证书

HUAWEI FreeBuds SE 4 无线耳机 / 每人

*机考绿卡：竞赛人才quick pass通道，应届生招聘可**免机考**；

*面试绿卡：竞赛人才quick pass通道，应届生招聘可**免机考和一轮专业面试**。

报名方式

10月16日23:59截止



扫码报名参赛



官方交流入口（内置5个赛区QQ群）

目录

Part 1 赛事介绍

Part 2 赛题解读

赛题应用-申请算力、答题步骤介绍


赛题解读-判题过程与得分介绍

判题过程介绍

- 完成赛题要求的一个文件并点击提交代码。



- 平台会自动跳转到提交界面，后台Case验证完成后返回结果。



注意：编译错误可在执行结果界面查看具体报错

得分规则

- 提交完成后可查看提交排名。

The screenshot shows the 'Addcmul' submission ranking table. The table lists the top 7 submissions, including the rank, submitter, submission time, score, and test point results.

排名	提交人	提交时间	分数	测试点 1	测试点 2	测试点 3	测试点 4	测试点 5
1	fuyangchenghu	2026/04/25 18:41:56	97.88	5μs	6μs	5μs	16μs	21μs
2	Huang51966	2026/04/07 12:37:33	94.43	5μs	6μs	6μs	16μs	22μs
3	mlewis	2026/03/30 17:57:34	0.00	-	-	-	-	-
4	desperateW	2026/03/31 10:30:43	0.00	-	-	-	-	-
5	imuu	2026/03/31 14:48:28	0.00	-	-	-	-	-
6	judge18566622897	2026/04/02 16:24:16	0.00	-	-	-	-	-
7	15138093583	2026/04/02 16:39:20	0.00	-	-	-	-	-

- 本次比赛共15个测试点，所有case点精度全部通过才会计分。
- 每个测试点单独计分，逻辑如下（T为最优性能，t为当前提交性能）：

$$\frac{100}{1 + \log_{1.5} \frac{t}{T}}$$

- 排行榜显示的最终分数为所有case得分的均值。若得分计算一致，则以提交时间进行排序，提交越早，排名越高。



注意：排行榜仅针对最后一次提交呈现，请确保比赛结束前提交的是最优实现

京津东北赛题解读-赛题背景

■ 赛题背景：

① 旋转位置编码（Rotary Position Embedding, RoPE）是现代大语言模型注入位置信息的核心机制，被 Llama、Qwen、DeepSeek、GLM 等主流模型广泛采用。RoPE 将 token 向量的维度两两配对为二维平面上的点，按"频率 × 位置"的角度对每对维度做旋转，在不引入可学习参数的前提下编码相对位置关系。公式为：

$$\text{inv_freq}[i] = \theta^{-2i/d}, \theta_i = p \cdot \text{inv_freq}[i]$$


$$y_i = x_i \cos \theta_i - x_{i+d/2} \sin \theta_i, y_{i+d/2} = x_{i+d/2} \cos \theta_i + x_i \sin \theta_i$$

■ 赛题特点

- ① 本次比赛要求使用Ascend C编程语言完成RotaryPosEmb算子开发
- ② 在满足精度的基础上，比拼算子性能

<https://gitcode.com/cann>

RoPE 二维旋转示意




京津东北赛题解读-题目概述：RotaryPosEmb算子开发

■ 题目概述：

实现的RotaryPosEmb算子需对输入张量执行旋转位置编码计算，计算公式为： $y = \text{RoPE}(x, \text{positions}; \text{theta})$ 。算子由若干小算子逻辑拼接完成，输入输出要求如下：

类型	参数名	类型	维度形状	支持数据类型	数据格式	备注
INPUT（必选）	x	tensor	(B, S, H, rope_dim)	float16, float32	ND	待旋转的rope子维度张量
INPUT（必选）	positions	tensor	(B, S)	int32	ND	每个token的位置索引
ATTR（属性）	theta	float	-	-	-	RoPE基础频率基数，默认10000.0
OUTPUT（输出）	y	tensor	与x一致	与x一致	与x一致	旋转位置编码后的输出

■ 算子功能分解（小算子拼接）：



■ 约束说明：

芯片类型：Atlas A2（910B）
维度范围：固定4维输入（B, S, H, rope_dim）； $B \in [1, 128]$ ， $S \in [1, 8192]$ ， $H \in [1, 256]$ ， $\text{rope_dim} \in [16, 1024]$ 且必须为偶数
张量大小：内存范围内的任意大小，因芯片UB大小的约束需进行切分，支持大数据量的计算；非对齐组合需正确处理
中间精度要求：逆频率与cos/sin计算必须使用FP32精度，避免长序列下角度误差累积



西北赛题解读-赛题背景

■ 赛题背景:

① Mixture-of-Experts (MoE) 是当前大语言模型的主流扩展架构，模型由大量专家子网络构成，每个token在推理时只激活其中少量专家，从而在保持大参数量容量的同时控制推理成本。MoE路由（gating）是决定每个token激活哪些专家的关键算子，DeepSeek V4 采用 $\text{sqrt}(\text{softplus}(\text{logits}))$ 作为专家评分函数，为每个token选出top-k个专家。公式为：

$$\text{score}[t, e] = \sqrt{\text{softplus}(x[t, e])} = \sqrt{\ln(1 + e^{x[t, e]})}$$


$$\text{scores_out}[t, j] = \text{score}[t, \text{ids}[t, j]], \text{ids} = \text{top} - k(\text{score})$$

■ 赛题特点

- ① 本次比赛要求使用Ascend C编程语言完成SqrtSoftplusTopK算子开发
- ② 在满足精度的基础上，比拼算子性能

<https://gitcode.com/cann>

MoE 路由评分函数




西北赛题解读-题目概述： SqrtSoftplusTopK算子开发

■ 题目概述：

实现的SqrtSoftplusTopK算子需对路由logits逐元素计算 $\text{sqrt}(\text{softplus}(x))$ 评分，并依据评分为每个token选出top-k个专家，输出选中专家的评分（不输出专家Id）。计算公式为： $\text{topk_scores} = \text{TopK}(\text{sqrt}(\text{softplus}(\text{router_logits})), k)$ ，输入输出要求如下：

类型	参数名	类型	维度形状	支持数据类型	数据格式	备注
INPUT（必选）	router_logits	tensor	(T, E)	float16, float32	ND	路由logits
ATTR（属性）	k	int	-	-	-	top-k的k，默认6
OUTPUT（输出）	topk_scores	tensor	(T, k)	与router_logits一致	ND	选中专家的评分（未归一化）

■ 算子功能分解（小算子拼接）：



■ 约束说明：

- 芯片类型：Atlas A2 (910B)
- 维度范围：2维输入 (T, E) ； $T \in [1, 131072]$ ， $E \in [64, 1024]$ 可为非2的幂， $k \in [1, 64]$ 且 $k \leq E$
- 张量大小：内存范围内的任意大小，因芯片UB大小的约束需进行切分；E非2的幂等非对齐场景需正确处理
- 中间精度要求：softplus与sqrt计算必须使用FP32精度，避免大logits下exp溢出 ($x > 20$ 时 $\text{softplus}(x) \approx x$)



西南赛题解读-赛题背景

■ 赛题背景：

① AddRmsNormBias是大语言模型推理场景中的重要融合算子，在AddRmsNorm（残差加法+RMS归一化）的基础上进一步融合逐通道偏置加法（Channel Bias）。部分模型（如Gemma、某些Qwen变体）在RMS归一化后会额外加上可学习偏置（bias），而非纯缩放。公式为：

$$y_i = x_i + residual_i$$


$$z_i = \frac{y_i}{\sqrt{\frac{1}{D} \sum_i^D y_i^2 + \epsilon}} \cdot \gamma_i$$

$$output_i = z_i + bias_i$$

■ 赛题特点

- ① 本次比赛要求使用Ascend C编程语言完成AddRmsNormBias融合算子开发
- ② 在满足精度的基础上，比拼算子性能

RMS 归一化前后分布示意




西南赛题解读-题目概述：AddRmsNormBias算子开发

■ 题目概述：

实现的AddRmsNormBias算子需融合三项操作：残差加法、RMS归一化、偏置加法。计算公式为： $output = RMSNorm(x + residual, gamma, epsilon) + bias$ ，输入输出要求如下：

类型	参数名	类型	维度形状	支持数据类型	数据格式	备注
INPUT（必选）	x	tensor	(..., D)	float16, bfloat16, float32	ND	主输入张量
INPUT（必选）	residual	tensor	(..., D)	与x一致	ND	残差输入，shape与x一致
INPUT（必选）	gamma	tensor	(D,)	与x一致	ND	RMS归一化缩放系数
INPUT（必选）	bias	tensor	(D,)	与x一致	ND	逐通道偏置
ATTR（属性）	epsilon	float	-	-	-	RMS平滑项，默认1e-5
OUTPUT（输出）	output	tensor	(..., D)	与x一致	ND	融合计算结果

■ 算子功能分解（小算子拼接）：



■ 约束说明：

芯片类型：Atlas A2 (910B) ；数据类型：float16、bfloat16、float32
维度范围：2维 (batch, D)、3维 (batch, seq, D)、4维 (batch, seq, heads, D)；batch∈[1,8192]，seq_len∈[1,32768]，D∈[64,32768]
形状约束：residual与x的shape完全一致；gamma和bias的shape均为(D,)
张量大小：内存范围内任意大小，因芯片UB大小的约束需进行切分；D可能为非32整倍数（如192、576），非对齐场景需正确处理



杭厦赛题解读-赛题背景

■ 赛题背景：


① 在大语言模型推理场景中，矩阵乘法是计算量最大的操作。为降低显存占用和计算延迟，业界广泛采用INT8量化技术。典型INT8量化推理前向中，单层计算需依次经历"量化矩阵乘→激活函数→动态再量化"三个阶段，分别对应不同Kernel；将三个阶段融合为单个算子，可显著减少kernel launch开销和中间数据搬运。公式为：

$$matmulOut[m,n] = cast_{fp32}(\sum_{i=1}^k x1[m,i] \cdot x2[i,n]) \cdot x1Scale[m] \cdot x2Scale[n]$$

$$y[m,n] = clamp(rint(max(0, matmulOut[m,n]) / yScale[m]), -128, 127)$$

■ 赛题特点

- ① 本次比赛要求使用Ascend C编程语言完成QuantMatmulReluQuant融合算子开发
- ② 在满足精度的基础上，比拼算子性能（按相对拆分实现基线的加速比评分）




杭厦赛题解读-题目概述：QuantMatmulReluQuant算子开发

■ 题目概述：

实现的QuantMatmulReluQuant算子需融合三阶段计算：INT8量化矩阵乘（INT32累加+反量化）、ReLU激活、动态per-token量化，输入输出要求如下：

类型	参数名	类型	维度形状	支持数据类型	数据格式	备注
INPUT（必选）	x1	tensor	(M, K)	INT8	ND	矩阵乘左矩阵（激活），不转置
INPUT（必选）	x2	tensor	(N, K)	INT8	ND	矩阵乘右矩阵（权重，已转置）
INPUT（必选）	x1Scale	tensor	(M,)	FLOAT32	ND	x1反量化因子
INPUT（必选）	x2Scale	tensor	(N,)	FLOAT32	ND	x2反量化因子
OUTPUT（输出）	y	tensor	(M, N)	INT8	ND	动态量化后的最终结果
OUTPUT（输出）	yScale	tensor	(M,)	FLOAT32	ND	每行的动态量化因子

■ 算子功能分解（小算子拼接）：



■ 约束说明：

芯片类型：Atlas A2 (910B)
维度范围：2维输入，M≥1、N≥1、K≥1；x1固定不转置(M,K)，x2固定已转置(N,K)；不支持空Tensor，仅支持连续Tensor
数据类型：x1、x2为INT8，x1Scale、x2Scale为FLOAT32；输出y为INT8、yScale为FLOAT32
舍入规则：就近偶数舍入 (rint) ，先round后clamp到[-128,127]；rowMax=0时yScale=1.0、对应行y全为0



上合赛题解读-赛题背景

■ 赛题背景:


① 在神经信息检索和RAG重排场景中，ColBERT使用Late Interaction计算query与document的相关性：先计算token级点积相似度，再对每个query token执行MaxSim，最后求和得到query-document分数。该流程由BatchMatMul、ReduceMax和ReduceSum组成，融合后可减少Kernel Launch与中间数据搬运。公式为：

$$A[b, m, n] = \sum_{i=1}^k X_1[b, m, i] \times X_2[b, i, n], A \in \mathbb{R}^{B \times M \times N}$$

$$y[b] = \sum_{i=1}^m \left(\max_n A[b, i, n] \right), y \in \mathbb{R}^B$$

■ 赛题特点

- ① 本次比赛要求使用Ascend C编程语言完成BatchMatmulMaxSum融合算子开发
- ② 在满足精度的基础上，比拼算子性能（按相对拆分实现基线的加速比评分）




上合赛题解读-题目概述：BatchMatmulMaxSum算子开发

■ 题目概述：

实现的BatchMatmulMaxSum算子需融合三阶段计算：批量矩阵乘、MaxSim归约（沿N取最大值）、求和归约（沿M求和），输出每个query-document pair的相关性分数，输入输出要求如下：

类型	参数名	类型	维度形状	支持数据类型	数据格式	备注
INPUT（必选）	x1	tensor	逻辑(B,M,K)；storage为(B,M,K)或(B,K,M)	FLOAT16, BFLOAT16	ND	Query token embedding
INPUT（必选）	x2	tensor	逻辑(B,K,N)；storage为(B,K,N)或(B,N,K)	FLOAT16, BFLOAT16	ND	Document token embedding
ATTR（可选）	transposeX1	bool	-	-	-	声明x1的storage shape
ATTR（可选）	transposeX2	bool	-	-	-	声明x2的storage shape
OUTPUT（输出）	y	tensor	(B,)	FLOAT32	ND	每个query-document pair的分数

■ 算子功能分解（小算子拼接）：



■ 约束说明：

芯片类型：Atlas A2 (910B)
维度范围： $B \in [1,64]$ ， $M \in [1,8192]$ ， $N \in [1,8192]$ ， $K \in [32,8192]$ 且为8的整数倍； $B \times M \times K \leq 2^{26}$ ， $B \times N \times K \leq 2^{26}$
存储布局：四种组合均需正确支持，transposeX1、transposeX2默认为false；M、N非16整数倍时需正确处理尾块
归约顺序：必须先沿N取最大值、再沿M求和；K维点积与两级归约采用FP32累加或等效精度实现



交流答疑 讨论贴

Thank you.

社区愿景：打造开放易用、技术领先的AI算力新生态

社区使命：使能开发者基于CANN社区自主研究创新，构筑根深叶茂、跨产业协同共享共赢的CANN生态

Vision: Building an Open, Easy-to-Use, and Technology-leading AI Computing Ecosystem

Mission: Enable developers to independently research and innovate based on the CANN community and build a win-win CANN ecosystem with deep roots and cross-industry collaboration and sharing.



上CANN社区获取干货



关注CANN公众号获取资讯

<https://gitcode.com/cann>

CANN