

CANN 算子天梯赛8-9月赛题解析

作者：三金/赵润田

时间：2026/09/15

目录

Part 1 天梯赛8月冠军代码解析

Part 2 8月获奖代表优化思路分享

Part 3 天梯赛9月赛题思路解析

CANN算子天梯赛

● 进行中

2026年CANN算子天梯赛

CANN 算子天梯赛，是面向全社会 AI 算子工程师的长期算子性能极限挑战赛，基于昇腾平台对算子进行长期优化打榜，按月度结算奖励性能榜首，为每一位算子开发者提供绝佳的实践平台。

C 主办方: CANN开源社区

💡 总奖金池
¥174,000

571
已报名

528
参赛队伍

294
距截止 / 天

已完成报名

赛事介绍 赛题发布 团队管理 实时榜单 晋级榜单 作品展览 获奖名单

①

报名开始时间

2026/05/21 00:00:00

>

②

比赛开始时间

2026/06/01 00:00:00

>

③

报名截止时间

2027/06/30 17:00:00

>

④

比赛结束时间

2027/06/30 17:00:00



2026 CANN 算子天梯赛

≡

“**大赛简介** CANN 算子天梯赛，是面向全社会 AI 算子工程师的长期算子性能极限挑战赛，基于昇腾平台对算子进行长期优化打榜，按月度结算奖励性能榜首，为每一位算子开发者提供绝佳的实践平台。”


“天梯赛的算子题目来源于真实的场景需求，目的是让参赛者持续优化的算子可以合入CANN算子库并在真实场景发挥作用。因此天梯赛算子禁止只针对特定shape进行编程，需要参赛者实现泛化的算子以满足实际场景不同算子规格的要求。”

报名链接: <https://competition.gitcode.com/competition/2057085957316272129/intro>

CANN算子天梯赛8月算子题目答题情况

序号	算子	类型	难度系数	尝试人数	通过人数	较上月提升比例	获奖团队	月度冠军奖品
1	HardSwish	vector	1	82	73	12.59%	Susnaa-sa	20w积分，可兑换2000元等值奖品
2	TopK	vector	1	42	19	/	蒜子批发	20w积分，可兑换2000元等值奖品
3	recompute_w_u	fusion	2	28	20	17.33%	jiaoxinyue	40w积分，可兑换4000元等值奖品
4	index	vector	2	40	19	/	All in AI	40w积分，可兑换4000元等值奖品
5	CTCLoss	vector	2	23	17	/	sohnkee	40w积分，可兑换4000元等值奖品
6	GroupNorm	vector	2	29	23	/	sohnkee	40w积分，可兑换4000元等值奖品
7	chunk_scaled_dot_kkt	fusion	3	29	15	7.41%	Lesem	60w积分，可兑换6000元等值奖品
8	confusion_matrix	vector	3	34	26	19.26%	sohnkee	60w积分，可兑换6000元等值奖品
9	inplace_update	vector	3	22	17	4.4%	黄毛哥	60w积分，可兑换6000元等值奖品
10	Conv2D	cube	4	84	13	99.9%	qq_52724865	80w积分，可兑换8000元等值奖品
11	QuantBatchMatmulV3的K-C量化场景末维上限约束消除	cube	4	50	28	85.57%	sohnkee	80w积分，可兑换8000元等值奖品
12	QuantBatchMatmulV3的K-C量化场景性能优化	cube	4	54	31	46.54%	葱头	80w积分，可兑换8000元等值奖品
13	chunk_gated_delta_rule_fwd_h	fusion	5	51	10	64.64%	ventus	100w积分，可兑换10000元等值奖品
合计		/	/	568	311	/	/	72000元等值奖品

积分可兑换奖品展示



CANN算子天梯赛8月冠军代码解析

HardSwish

8月冠军实现解析:

- ① 开Double Buffer
- ② 均匀分块
- ③ 自适应分核
- ④ 计算方式优化
- ⑤ L2 cache策略管理
- ⑥ Bank Conflict消除

elementwise算子实现分支细致，基本已经达到极限

Conv2D

8月冠军实现解析:

- ① 使用多个模板，tiling侧根据case大小，数据类型决策模板
- ② kernel分了多个模板实现，分别包含纯V实现、V+C实现等，Cube模板使用了高效的Load3D指令完成img2col

下一步性能优化思路解析:

- ① img2col和mmad部分还是考虑cube实现为主
- ② TransFormat的V流水可以和C的Img2Col/MMAD考虑pipe流水
- ③ 参考资料

https://www.hiascend.com/document/detail/zh/canncommercial/latest/API/ascendcopapi/atlasascendc_api_07_0249.html

QuantBatchMatmulV3的K-C 量化场景性能优化

8月冠军实现解析:

- ① 使用基本块，并针对基本块的计算过程进行一定的抽象
- ② 特定场景下做了K轴的多核切分，重复利用核数

下一步性能优化思路解析:

- ① 对于某些特定的shape，可以考虑优化tiling和搬运流程，将左矩阵或者右矩阵驻留在L1 buffer，减少重复搬运数据量
- ② 优化流水排布：使用cv并行实现
- ③ 尝试K轴错峰加载缓解bank冲突
- ④ 尝试MTE2 preload优化数据搬运流水

赛制约束:

禁止利用以下手段进行作弊，包括但不限于:

- 1) 针对case编程，不具备泛化性;
- 2) host侧进行算子逻辑计算降低kernel侧耗时;
- 3) 针对平台多轮运行取平均原则，首次计算后利用指纹存 workspace，除了首轮均直接跳device运算

优化思路参考:

- ① 开源算子仓:
<https://gitcode.com/cann/ops-math>, <https://gitcode.com/cann/ops-cv>,
<https://gitcode.com/cann/ops-nn>, <https://gitcode.com/cann/ops-transformer>
- ② samples样例仓: <https://gitcode.com/cann/cann-samples>
- ③ CANN微信公众号: 微信扫描右侧二维码



CANN算子天梯赛8月冠军代表分享-赵润田

Chunk_Scaled_Dot_KKt 算子开发和优化分享

Part 1 算子功能和公式

Part 2 算子实现

Part 3 算子性能优化

Part 4 算子瓶颈分析

CANN算子天梯赛9月新增算子题目解读

赛题概览

算子	类型	难度系数	难点	月度冠军奖品
BNTrainingUpdate	vector	1	Tiling分核	2000元等值奖品
BatchNorm3D	vector	2	Tiling分核、规约&广播计算	4000元等值奖品
GroupNormSiluQuant	fusion	2	Tiling分核、规约&广播计算	4000元等值奖品
MseLoss	vector	2	Tiling分核、规约计算	4000元等值奖品
CompressorGrad	fusion	4	CV同步、数据搬运、尾块处理	8000元等值奖品
DepthwiseConv2D	cube	5	对角阵优化、CV并行	10000元等值奖品

CANN算子天梯赛9月算子题目解读

DepthwiseConv2D

3.2 数学公式

3.2.1 输出尺寸计算

卷积输出在空间维度上的尺寸由输入尺寸 H/W 、卷积核尺寸 k_H/k_W 、步长 $stride$ 、填充量 pad 和膨胀率 $dilation$ 共同决定：

$$H_{out} = \left\lfloor \frac{H + 2 \cdot pad - dilation \cdot (k_H - 1) - 1}{stride} \right\rfloor + 1$$
$$W_{out} = \left\lfloor \frac{W + 2 \cdot pad - dilation \cdot (k_W - 1) - 1}{stride} \right\rfloor + 1$$

其中 $\lfloor \cdot \rfloor$ 为向下取整。公式含义：填充后的有效输入尺寸为 $H + 2 \cdot pad$ ，膨胀卷积核的实际感受野为 $dilation \cdot (k_H - 1) + 1$ （膨胀率 > 1 时卷积核元素之间插入 $dilation - 1$ 个间隔），滑动窗口需在有效输入范围内每次前进 $stride$ 步，能滑动的次数即为 $H_{out} - 1$ 。

3.2.2 零填充定义

对输入张量 $x \in \mathbb{R}^{N \times C \times H \times W}$ ，在空间维度 H, W 的上下左右各填充 pad 行/列零值，得到填充后张量 $x^{pad} \in \mathbb{R}^{N \times C \times (H+2 \cdot pad) \times (W+2 \cdot pad)}$ ；

$$x_{n,c,h,w}^{pad} = \begin{cases} x_{n,c,h-pad,w-pad} & \text{若 } pad \leq h < H+pad \text{ 且 } pad \leq w < W+pad \\ 0 & \text{否则 (填充区域)} \end{cases}$$

3.2.3 深度卷积计算


深度卷积的核心特征是每个通道独立卷积，不跨通道加权。对于输出张量 $y \in \mathbb{R}^{N \times C \times H_{out} \times W_{out}}$ 中的任何一个元素 $y_{n,c,i,j}$ ，其计算过程为：

$$y_{n,c,i,j} = b_c + \sum_{kh=0}^{k_H-1} \sum_{kw=0}^{k_W-1} x_{n,c,h_i,w_j}^{pad} \cdot w_{c,0,kh,kw}$$

其中采样位置由滑动窗口位置 (i, j) 、卷积核偏移 (kh, kw) 、步长与膨胀率共同确定：

$$h_s = i \cdot stride + kh \cdot dilation$$

$$w_s = j \cdot stride + kw \cdot dilation$$



算子优化功能描述：

利用对角阵计算原理，将Weight转换为对角阵，实现每个Group内的Fmap和Weight的成对卷积。右图是im2col后的卷积矩阵乘示意图。假设不考虑分形格式对齐引入的开销，显然Cube的计算数据中只有1 / Groups是有效数据，其余全部是左矩阵和0的计算，因此Cube利用率是1 / Groups。而Depthwise场景由于Groups = Cin = Cout，Groups最大，利用率也就最低。在此基础上，我们通过重新分组减少非对角线部分的0的计算，提升Cube利用率。

原理：计算单Group内卷积最大的问题是分形对齐，如果在拼凑对角阵的过程中，正好找到Enlarge组Weight，使得拼凑出的对角阵满足K方向K0对齐，N方向N0对齐，则既可满足Cube计算要求，又能减少非对角阵0的计算，从而提升Cube利用率。

参考链接： <https://gitcode.com/cann/ops-nn/wiki/Conv2D%E7%AE%97%E5%AD%90Depthwise%E5%8D%B7%E7%A7%AF%E5%BC%80%E5%8F%91%E4%B8%8E%E4%BC%98%E5%8C%96%E5%AE%9E%E8%B7%B5>

Thank you.

社区愿景：打造开放易用、技术领先的AI算力新生态

社区使命：使能开发者基于CANN社区自主研究创新，构筑根深叶茂、跨产业协同共享共赢的CANN生态

Vision: Building an Open, Easy-to-Use, and Technology-leading AI Computing Ecosystem

Mission: Enable developers to independently research and innovate based on the CANN community and build a win-win CANN ecosystem with deep roots and cross-industry collaboration and sharing.



上CANN社区获取干货



关注CANN公众号获取资讯