CANN开发者说

-TileLang-Ascend是如何诞生的?

解文浩　TileAI 社区

邢静远/杨犇　CANN社区

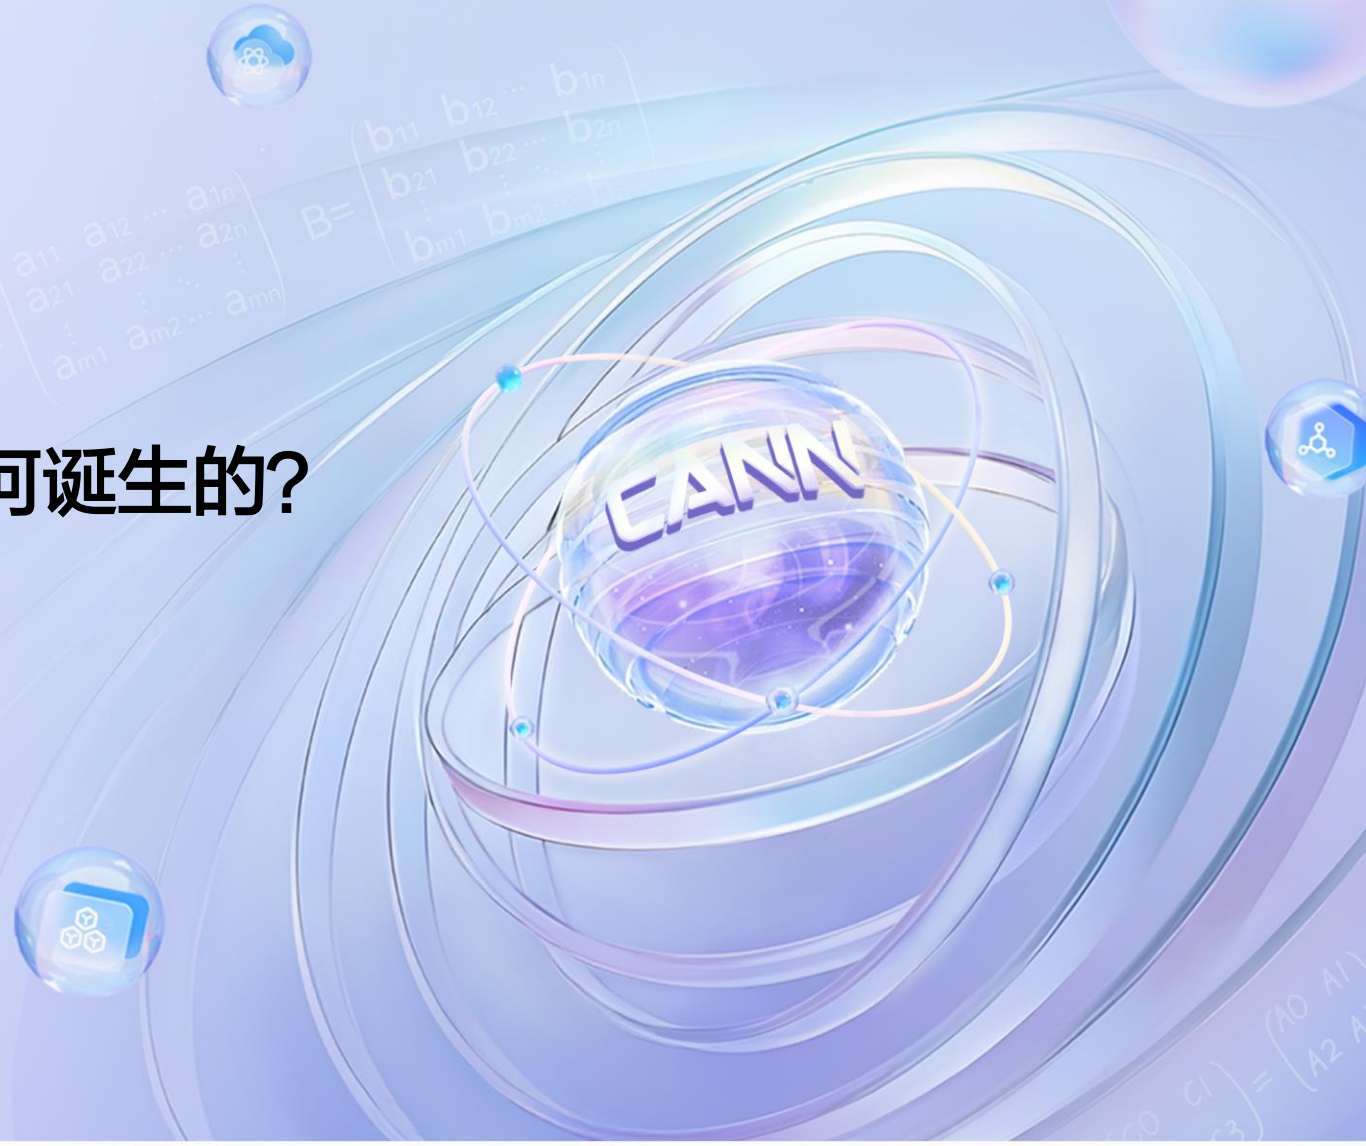

CANN

目录

趋势与机遇：基于Tile的软硬件协同

AI加速器发展的新趋势使得基于Tile编程语言变得越来越重要。

Tile-AI加速硬件

- 更高的数据传输和计算效率
- 本地大容量SRAM，再结合3D DRAM，片上互联，提供超高计算带宽
- 要求以更大的Tile粒度来进行指令集设计和体系结构设计

新一代Tile-based AI加速

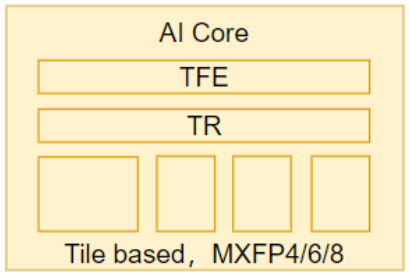

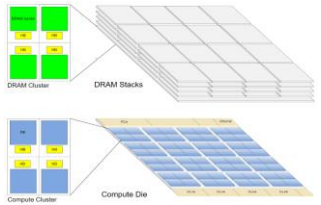

3D先进封装存储

片上网络

推动

Tile-编程语言

- 在更大的Tile粒度上进行编程和编译，可以更方便和高效地优化模型算子
- 实现Tile编程计算抽象和Tile硬件抽象一致，高效协同

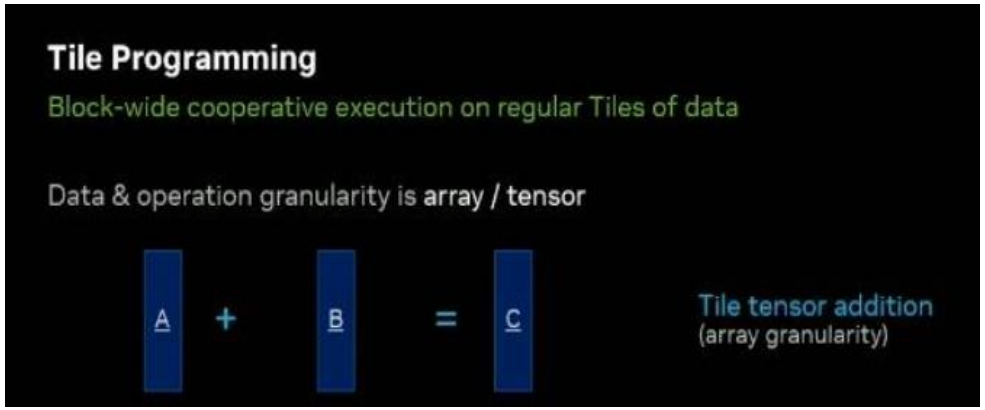

CANN

TileLang： Tile编程语言

- Tile-level的类Python的AI编程语言（DSL）
  - 开发更简单
  - 提供了更好的性能
  - 可以更加细粒度地控制计算调度

- 面对 Tile 硬件趋势的兴起，推出Tile编程语言TileLan
  主要核心技术团队来自北京大学tileAI项目

- 2025-01-20开源，现已获得超过3.9K stars
  https://github.com/tile-ai/tilelang

- 支持多硬件后端
  GPU、NPU、TPU、CPUs

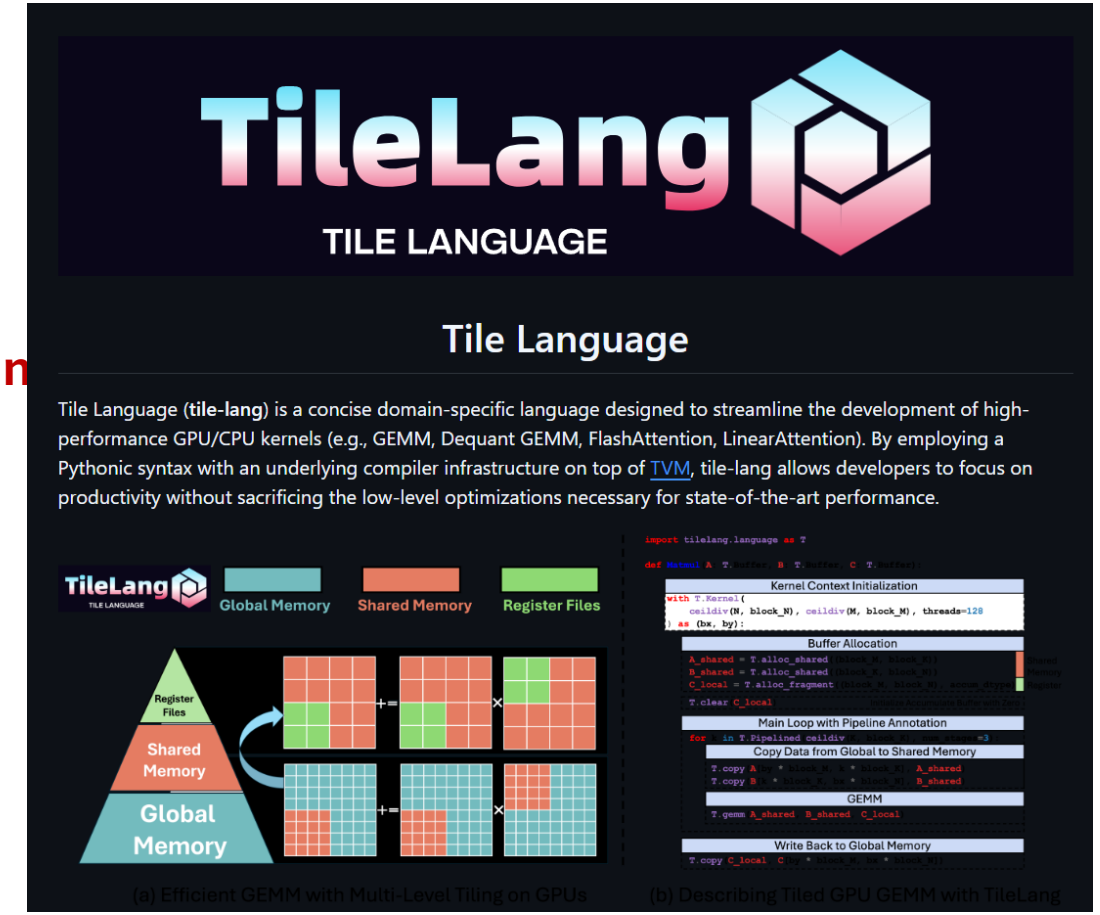

CANN

TileAI系统和生态

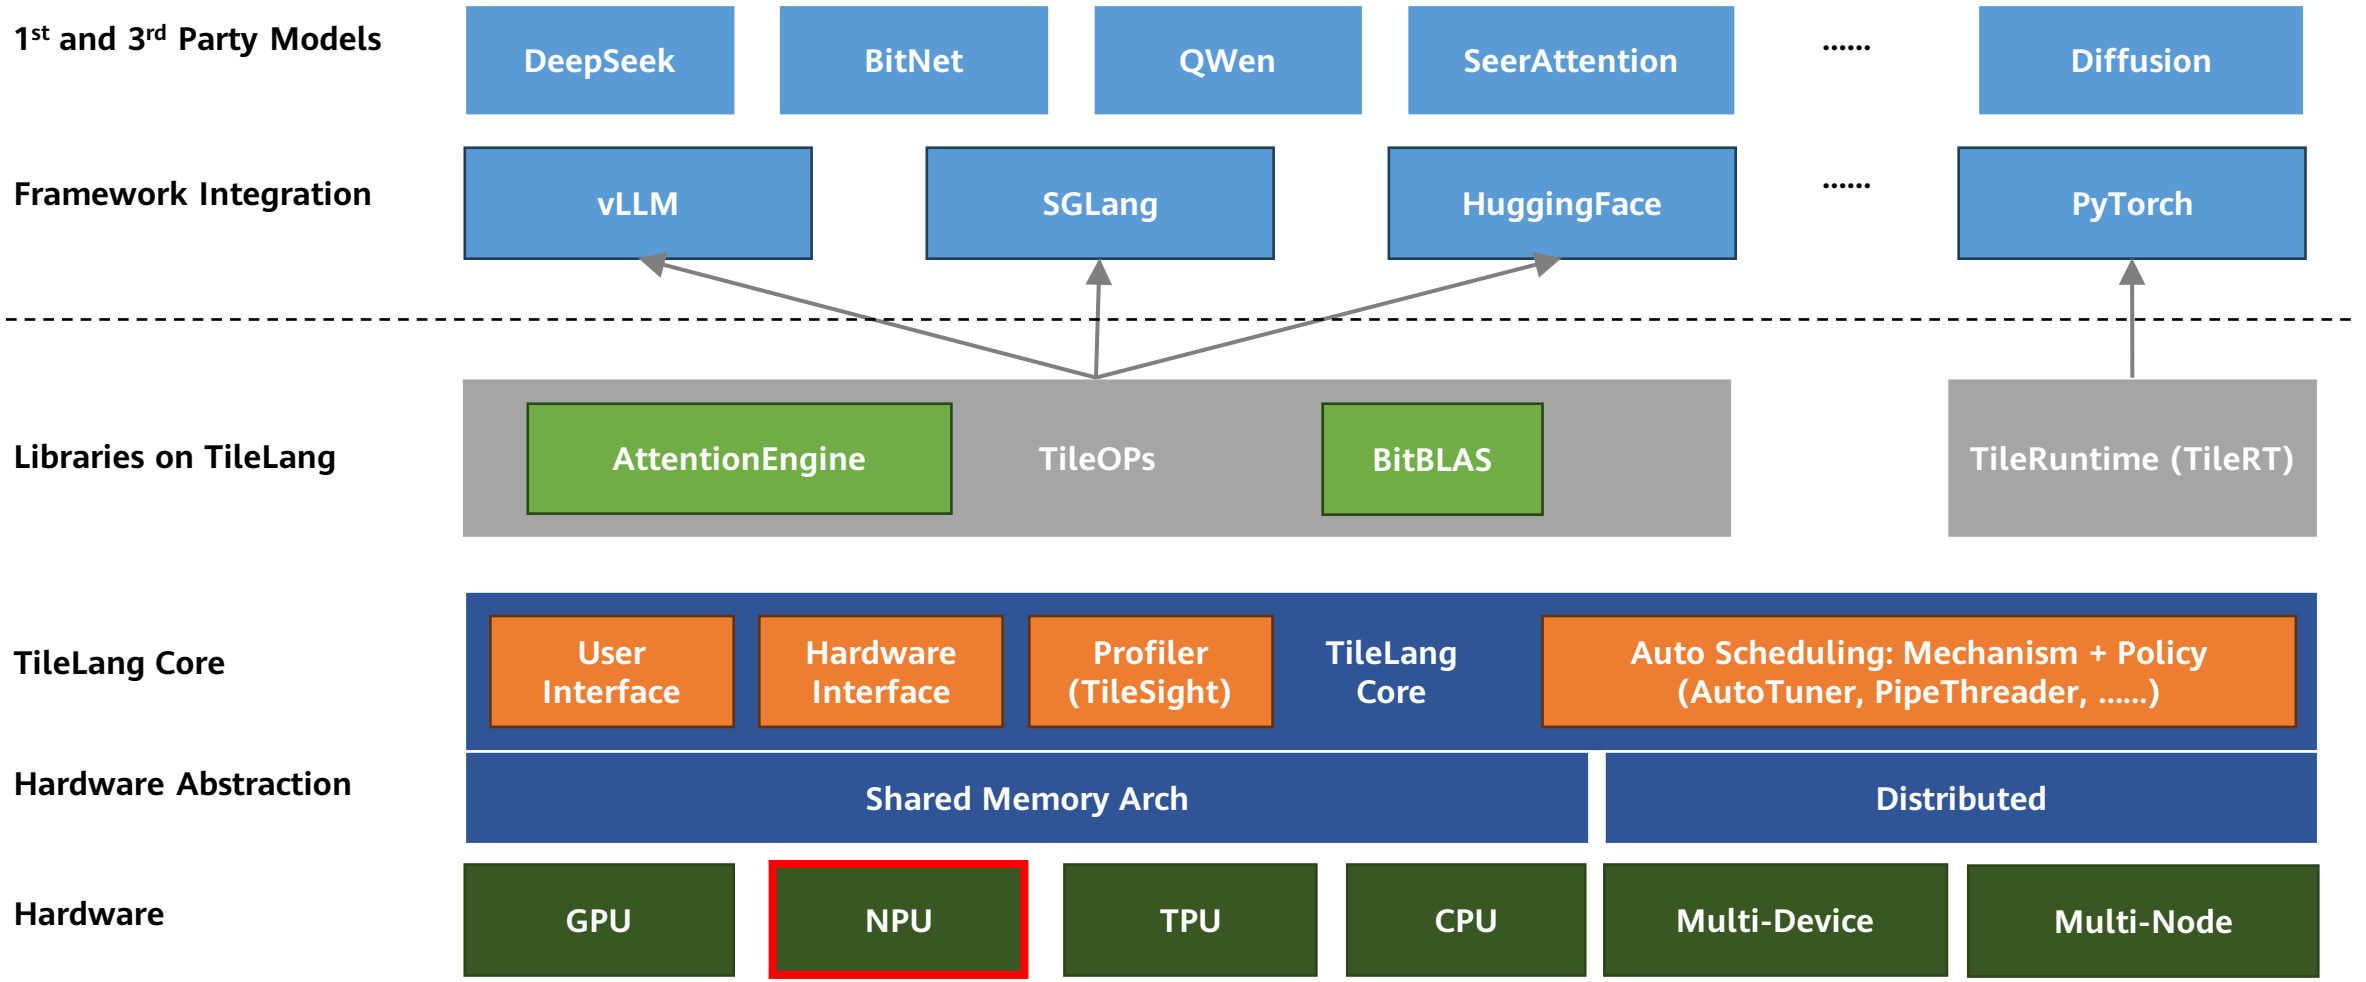

https://gitcode.com/cann

CANN

目录

TileLang-Ascend合作——适配NPU

Ascend适配TileLang：基于**Tile**的统一硬件表达的抽象，提供轻量级的底层装换，并提供扩展接口提供**Ascend**专属能力。

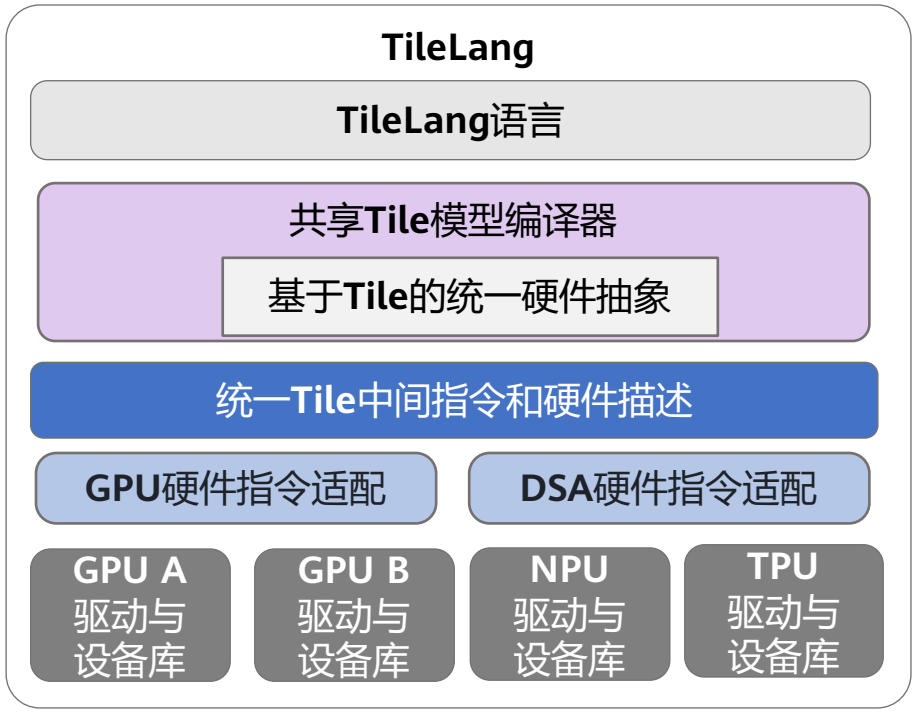

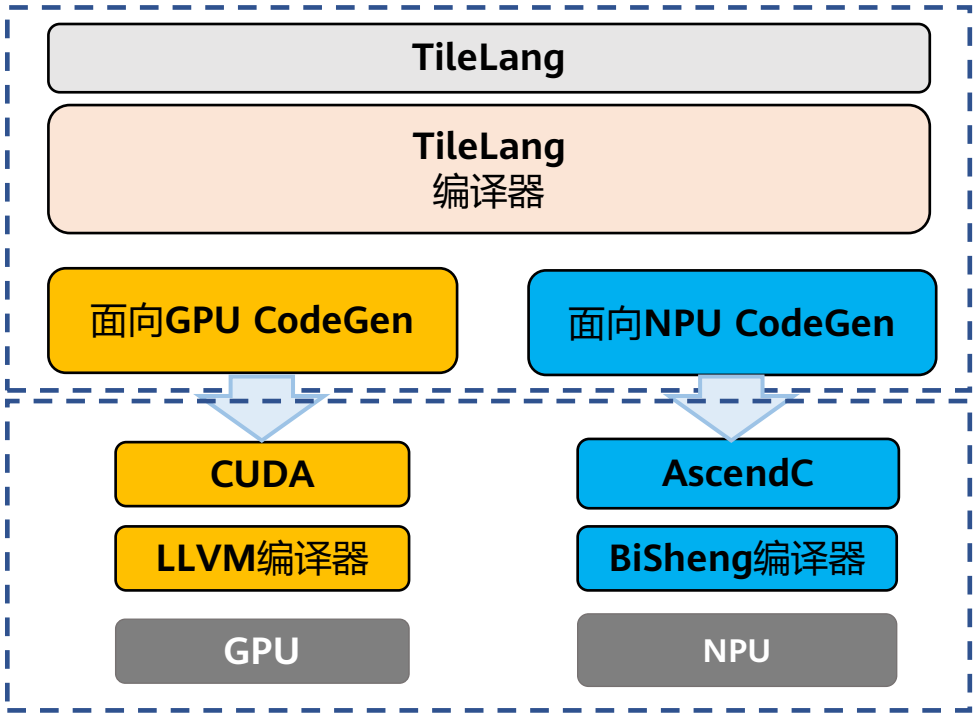

TileLang-Ascend合作——原语

原语类型	原语名称	用法示例	功能介绍
内核原语	kernel	T.kernel(block_num, is_npu=True) as (cid, vid)	该原语对应到Ascend C的kernel调用处，其中block_num对应于<<< >>>中的第一个参数，表示这个kernel开启多少个子任务数量。cid的范围为 [0,block_num) [0, block_num) [0,*block_num*), vid的范围为0或1。因为A2的cv核默认配比为1:2, 可以通过vid指定当前vector的索引。
内存分配原语	alloc_L1/L0A/L0B/L0C/UB	T.alloc_L1/L0A/L0B/L0C/UB(shape, dtype)	用于分配位于片上内存的buffer；通过指定shape和数据类型标记buffer的信息。
数据搬运原语	copy	T.copy(src, dst)	将src上的buffer拷贝到dst上，注意buffer可以通过BufferLoad或者BufferRegion指定一小块区域。
计算原语	gemm, add, mul, reduce_max...	T.reduce_max(dst, src, tmp, dim)	其中dim指定为对应规约的维度，目前只支持二维的规约。
同步原语	set_flag, wait_flag, set_cross_flag, wait_cross_flag, pipe_barrier	T.set_cross_flag(pipe: str, eventId: int)	其中pipe为需要同步的流水线，eventId为同步事件编号。

CANN

TileLang-Ascend合作——RoadMap

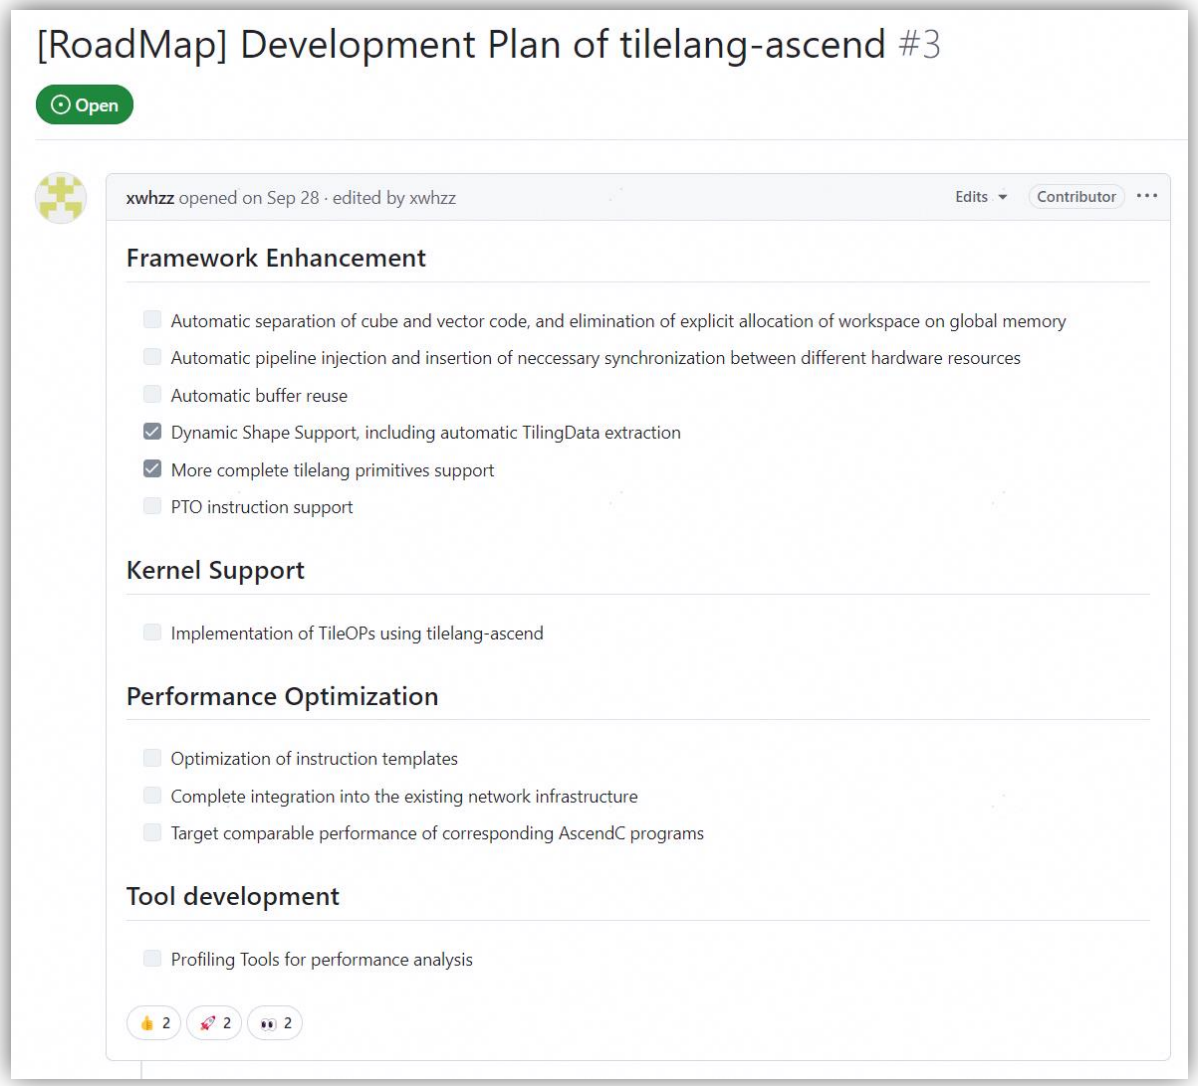

[RoadMap] Development Plan of tilelang-ascend #3

Open

xwhzz opened on Sep 28 · edited by xwhzz Edits Contributor

Framework Enhancement

- [ ] Automatic separation of cube and vector code, and elimination of explicit allocation of workspace on global memory
- [ ] Automatic pipeline injection and insertion of neccessary synchronization between different hardware resources
- [ ] Automatic buffer reuse
- [x] Dynamic Shape Support, including automatic TilingData extraction
- [x] More complete tilelang primitives support
- [ ] PTO instruction support

Kernel Support

- [ ] Implementation of TileOPs using tilelang-ascend

Performance Optimization

- [ ] Optimization of instruction templates
- [ ] Complete integration into the existing network infrastructure
- [ ] Target comparable performance of corresponding AscendC programs

Tool development

- [ ] Profiling Tools for performance analysis

👍 2 🚀 2 👀 2

目录

欢迎大家和我们交流、合作！

群聊：CANN社区交流2群

该二维码7天内(11月21日前)有效，重新进入将更新

扫码联系项目经理

扫一扫上面的二维码图案，加我为朋友。

扫码关注项目-github

https://github.com/tile-ai/tilelang-ascend

扫码关注项目-gitcode

https://gitcode.com/cann/cann-recipes-infer/tree/master/ops/tilelang