

CANN 开源社区MeetUp—深圳站



CANN全面开源开放社区介绍

分享嘉宾：邓春生
2025.12.6 中国·深圳



content

目录

01 CANN开源社区介绍

02 CANN社区开源进展

CANN开源社区介绍

01

content

目录

01 CANN社区是什么？


02 CANN治理架构

03 CANN技术架构

04 CANN开源开放

05 加入CANN社区

CANN社区是什么？




CANN (Compute Architecture for Neural Networks) 是AI异构计算架构，对上支持多种AI框架，对下服务AI处理器与编程，发挥承上启下的关键作用，是提升华为AI处理器计算效率的关键平台

CANN 社区是围绕CANN构建的开源协作平台，提供环境部署指导、开源代码获取、协作开发、技术问答、社区互动、赋能培训等服务，促进成员协作

打造开放易用、技术领先的AI算力新生态，成为国内开发者首选的AI开发平台

使能开发者基于CANN社区自主研究创新，构筑根深叶茂、跨产业协同共享共赢的AI生态

CANN 治理架构



CANN技术架构：打造极致性能、极简易用的AI算力使能层，释放昇腾澎湃算力

① 使能大模型并行计算加速

提供高性能算子及通信算法，释放澎湃算力

② 高效开发与生态迁移

提供多种算子开发，使能高效开发

③ 开源开放，生态兼容

提供丰富参考实践，使能自主创新

AI框架

全面支持业界AI框架，适配PyTorch社区版本



PyTorch



MindSpore



TensorFlow



Paddle



Caffe



Jittor

.....

CANN

异构计算架构

算子库

大模型融合算子
NN/CV/Math基础算子

通信库

集合通信算法
分布式通信

图引擎

图编译优化
图执行加速

领域加速库

覆盖不同开发场景加速套件

工具

算子编程 Ascend C | pyPTO

BiSheng Compiler 毕昇编译器 虚拟指令PTO instruction | 异构编译优化 | AscendNPU IR

支持算子调试，性能调优，
提供可视化能力

Runtime 运行时 控制流 | 内存管理 | 任务调度

Driver 驱动 设备管理 | 加速器驱动 | 板级驱动

昇腾硬件




昇腾系列AI处理器



CANN

CANN开源开放、分层解耦，满足各层级灵活开发需求



从模型、算子、内核、底层资源等多层次级优化和开发，兼顾性能与开发易用性

图模式开发

模型整图下发，降低 Host 调度开销，提升整图执行性能

单算子API调用

框架直调领域加速库或算子库，平滑迁移、高效开发

自定义算子开发

提供 C、C++、Python 等编程方式，匹配不同开发习惯

直调底层Runtime接口

细粒度控制硬件资源，释放硬件性能，支持极致创新

加入CANN社区



Start

1 体验CANN社区

[ops-math](#)

数学类计算算子库

[ops-transformer](#)Transformer类
大模型计算子库[ops-nn](#)

神经网络算子库

[ops-cv](#)

图像处理算子库

您可以根据实际场景，在对应的项目中拉取代码修改、编译，提交issue和PR等：

社区	应用场景
ops-math	CANN算子库提供数学类计算的基础算子库，包括math类、conversion类等算子。
ops-transformer	CANN算子库提供transformer类大模型计算的进阶算子库，包括attention类、moe类等算子。
ops-nn	CANN算子库提供神经网络计算能力的高阶算子库，包括matmul类、activation类等算子。
ops-cv	CANN算子库提供图像处理、目标检测等能力的高阶算子库，涵盖常见的图像处理操作，包括image类、objdetect类。
...	...

2 了解行为准则

在参与贡献前，请了解[CANN社区行为准则](#)，后续您在CANN社区的活动（包括但不限于发表评论、提交Issue、发表wiki等）都请遵循此行为准则。

3 签署CLA

在参与项目贡献前，您需要签署CANN社区贡献者许可协议（CLA）。请根据您的参与身份，选择签署个人CLA、公司CLA或企业CLA，请点击[这里签署](#)；

个人CLA：以个人身份参与贡献，请签署个人CLA；

企业管理员：以企业管理员的身份参与贡献，请签署企业管理员CLA。

STEP1

STEP2

STEP3



STEP5

STEP4

STEP3

STEP2

STEP1

5 一起成长

欢迎广大开发者体验并参与贡献，您可以通过积极贡献，不断积累提升个人的经验与影响力。请参见[Contributing](#)了解行为准则，进行CLA协议签署，以及参与源码仓贡献的详细流程。

目前社区正在积极建设中，欢迎各社区伙伴积极参与社区共建，若您有意，请发送邮件至cann@cann.team

4 参与共建

在签署了CLA协议，就可以开始您的贡献之旅啦！贡献的方式有很多种，每一种贡献都将受到欢迎和重视

- 提交Issue/处理Issue任务

找到Issue
列表提交Issue
请参考[Issue 提交指南](#)参与
Issue讨论找到愿意处
理的Issue

- 贡献编码

- 1) 准备CANN开发环境
- 2) 了解CANN社区内的开发注意事项
- 3) 代码下载与贡献流程



关于GitCode工作流的详细操作可参见[GitCode工作流说明](#)；
当您在提交PR过程中遇到问题，常见问题的解决方法可参见[FAQs](#)。

CANN

CANN社区开源进展

02

回顾：CANN全面开源开放规划

2025

- 解耦并开源算子库
- 开源CATLASS模版库
- 开放AscendNPU IR支持，支持Triton
- 1230 910B/910C 全面开源开放


2026

- 950系列上市即开源
- Ascend C使能下一代处理器950编程特性
- 支持多代际昇腾产品开发和创新

2027

持续迭代期：
未来每代际产品配套
软件持续迭代


CANN开源进展：已开源全量算子库、集合通信、编程语言及图引擎



技术领域	主要代码仓	对客户的帮助
算子	ops-transformer	融合算子库，将多个独立的“小算子”融合成一个“大算子”，常用于加速大模型，典型的例子如FlashAttention、以及各种计算通信融合算子
	ops-nn	加速神经网络计算的高阶算子库，涵盖常见的张量matmul、activation、loss计算等操作
	ops-math	提供数学类基础计算的加速，包括math类、conversion类等算子
	ops-cv	图像处理、目标检测等高阶算子库，涵盖常见的图像处理操作，包括image类、objdetect类
	opbase	提供算子公共能力的基础框架库，涵盖aclnn基础框架和公共依赖项
集合通信	hccl	集合通信库，用户可以参考和实现自有集合通信算子/算法
	hcomm	集合通信控制面&数据面，用户可以自行修改通信框架和通信机制，进行维测增强
	hixl	灵活、高效的昇腾单边通信库，面向集群场景提供简单、可靠、高效的点对点数据传输能力
GE图引擎	ge	图引擎，1、图模式实现参考2、增强开放能力，供用户定制图编译行为
	graph-autofusion	面向昇腾(Ascend)芯片的轻量级、解耦式组件集合，旨在通过自动融合技术加速模型执行。目前已开源 SuperKernel 组件，未来将持续开放更多自动融合相关模块
	metadef	cann 算子以及图引擎相关的元数据定义，即相关数据结构以及对外接口定义
Ascend C 编程	asc-devkit	Ascend C API和模板库，用户可以自行修改API和模板库的实现，按需封装，提高开发效率。
	asc-tools	Ascend C开发工具，用户可以自行修改和扩展相关工具
	pyasc	Ascend C python前端，支持用户扩展python编程API和优化能力
工具	oam-tools	提供支持典型维测问题的辅助定位工具，包括一键收集npu维测信息、aic error辅助分析和集合通信性能/正确性测试
运行时	npu-runtime	运行时/DFx采集能力，并支持acl Graph图捕获和重放，用户可以自主开展维测，探索运行时和资源管理创新
驱动	driver	HAL/OS适配/设备管理/资源管理等host侧驱动，支撑客户自主创新

930开源开放：支持算子分包独立构建、独立安装升级，提升开发者体验

930社区尝鲜版：支持子包**独立安装、独立升级**，**295个算子**完成开源



295个

开源算子数

50%

构建时长优化

85%

升级包按需部署

CANN

开源试运营完成首个社区外部贡献 & 社区开发者联创case上线

AsNumpy: CANN社区首个完全由社区贡献者开发的代码仓



项目介绍

哈尔滨工业大学计算学部苏统华、王甜甜老师团队联合华为CANN团队开发的华为昇腾NPU原生Numpy仓库

<https://gitcode.com/cann/asnumpy>

Apache-2.0 C++ 41 提交数

CANN 昇腾 CANN 4 天前

哈工大 X CANN 团队联合
开源昇腾原生Numpy
AsNumpy正式发布！

哈工大 x CANN团队联合开源昇腾原生 Numpy，首位GitCode社区贡献者已加入！

CANN 昇腾 CANN 4 天前

哈工大 X CANN 团队联合
开源昇腾原生Numpy
AsNumpy正式发布！

哈工大 x CANN团队联合开源昇腾原生 Numpy，首位GitCode社区贡献者已加入！

AsNumpy repository details:

- 文件: gitcode, numpy, docs, examples, include, python, src, test, third_party
- issues: Add PULL_REQUEST_TEMPLATE.md Co-authored-by: wutongjing... (7天前), better make and add exit function Co-authored-by: hyolee-lihong... (2天前), docs: Optimize document structure and API documentation Co-auth... (2小时前), add Apache-2.0 license header to many files Co-authored-by: wut... (3天前), better make and add exit function Co-authored-by: hyolee-lihong... (2天前), better make and add exit function Co-authored-by: hyolee-lihong... (2天前), better make and add exit function Co-authored-by: hyolee-lihong... (2天前), add Apache-2.0 license header to many files Co-authored-by: wut... (3天前), initialize the CANN/Numpy repository. (13天前)
- Pull Requests: Initialize the CANN/Numpy repository. (13天前), Initialize the CANN/Numpy repository. (13天前), better make and add exit function Co-authored-by: hyolee-lihong... (2天前)

CANN-HIXL: 联合社区开发者共建

MoonCake项目组 + CANN-HIXL协同完成TTFT优化40%，并反哺相关优化至社区

- 与Mooncake社区基于HIXL完成NPU对接
- 协同HIXL完成批量小Buffer多级流水传输方案在CANN的落地
- 贡献昇腾亲和的BatchPut/BatchGet接口至开发者社区

[与 CANN 联合共创 HIXL 组件：开放昇腾底层高速互联，提供简易 API](#)

Prefill Instance

vLLM Inference Engine

Multi Connector

Mem Pool
Connector

TE Connector

put/get
MoonCake

MoonCake Stroe
Instance

Transfer Engine

(Logic) Memory Pool

HIXL-transport

Decode Instance

vLLM Inference Engine

Multi Connector

Mem Pool
Connector

TE Connector

transfer_syn
MoonCake

MoonCake Stroe
Instance

Transfer Engine

(Logic) Memory Pool

HIXL-
transport

批量小buffer多级流水传输

CANN-HIXL

CANN

0day 支持DeepSeek-V3.2-Exp / Kimi-K2-Thinking模型

[2025/09] CANN社区0day支持昇腾推理部署DeepSeek-V3.2-Exp

- 低比特量化深度优化**：支持 W8A8C8 量化格式，显存占用降低 50% 且精度损失 < 1%；
- 长序列稀疏计算加速**：适配 DSA 稀疏注意力机制，64卡128K 长序列推理 TTFT<2 秒，TPOT<20ms, 吞吐量提升 3 倍；
- 算子融合与硬件适配**：基于 AscendC 实现 LI+SFA 融合 Kernel，释放稀疏计算潜力，配套技术文档与代码已开源；
- 自研PyPTO框架**：依托 PyPTO 框架实现 NPU DSA，提升融合算子编程易用性并扩展 Decode Attention 融合，文档与代码同步开源；

- **0day支持DeepSeek-V3.2-Exp**

关键事件



2025.09



2025.10



2025.11



2025.12 (now)

- Qwen3-MoE支持
- DeepSeek-V3.2-Exp支持W8A8C8量化
- HunyuanVideo支持Ulysses SP/ RingAttention SP / TeaCache加速
- Wan2.2-I2V支持Ulysses SP、CFG并行、VAE并行
- DeepSeek-R1/Kimi-K2支持
- DeepSeek-R1、Qwen2.5模型训练样例上线


[2025.11] CANN社区0day支持Kimi-K2-Thinking，支持256K长序列

- Flash Decode加速**：针对小 batch、长序列负载降低时延、提升算力利用率
- INT4 量化适配**：完成 A16W4 (pergroup=32) 量化格式适配，配套 GMM 算子开源，平衡速度与精度
- 分布式传输优化**：HIXL 组件开源，与 Mooncake 社区全面适配，支持多种底层通信链路
- 部署模式升级**：支持大 EP 专家并行 + PD 分离部署，进一步提升系统吞吐性能

- **0day支持Kimi-K2-ThinkingAtlas A3, 支持256K序列推理部署，原生W4A16量化**

- Qwen3-Next推理支持
- Longcat推理支持
- GPT-OSS推理支持
- Qwen-235B/32B长序列RL训练样例
- VGGT推理支持
- Hunyuan3D推理支持
- Pi0推理支持

CANN开源的下一步计划



快速响应社区Issue， 跟踪用户问题解决闭环

问题类型	问题描述	问题状态	处理内容
需求建议	[Requirement 需求建议]: 建议FA/FAG算子kernel代码继续提高可读性	进行中	开发已回复
需求建议	[Requirement 需求建议]: MC2 通信 slow 轻量级诊断方案	进行中	开发已回复
需求建议	缺少allgathermatmul的example	已关闭	开发已回复, 使用pull跟踪
需求建议	MC2 Distribute Combine Add Rms Norm算子静态图built in功能放开	已关闭	
需求建议	[Documentation 文档反馈]: readme问题整改	进行中	开发已回复
文档反馈	[Documentation 文档反馈]: 算子列表显示有quant_grouped_matmul_inplace_add算子, 但实际没有找到	已关闭	问题解决关闭
文档反馈	[Documentation 文档反馈]: 算子列表显示有grouped_mat_mul_all_reduce算子, 但实际没有	已关闭	问题解决关闭
文档反馈	[Bug-Report 缺陷反馈]: 按照官方指导安装完之后执行算子example出现Segmentation fault	进行中	开发已回复, 但用户未回复
文档反馈	[Documentation 文档反馈]: NSA相关算子用例缺失	已关闭	开发已回复, 使用pull跟踪
缺陷反馈	[Bug-Report 缺陷反馈]: Failed when build the project	进行中	开发已回复
缺陷反馈	[Bug-Report 缺陷反馈]: 脚本install_deps.sh的检查操作系统detec_os的通用性有问题	已关闭	问题解决关闭
缺陷反馈	[Bug-Report 缺陷反馈]: libopgraph_transformer.so中缺失符号	已关闭	开发已回复, 使用pull跟踪
缺陷反馈	[Bug-Report 缺陷反馈]: 使用官方文档 编译fused_infer_attention_score 以及他的example, 测试时卡住	进行中	需要用户继续提供场景, 但用户未回复
缺陷反馈	[Bug-Report 缺陷反馈]: 执行moe_distribute_dispatch算子测试例时报错	进行中	开发已回复
技术问题	[Question 问题咨询]: 与ATB算子库有什么不同	已关闭	问题解决关闭
技术问题	[Question 问题咨询]: 文档提供的cann-toolkit无法使用ATC命令	进行中	已经给出解决方案 (解答), 但用户未反馈
技术问题	[Question 问题咨询]: 编译报错	进行中	已经给出解决方案 (解答), 但用户未反馈



快速加入CANN社区

CANN (Compute Architecture for Neural Networks) 是华为针对AI场景推出的异构计算架构，对上支持多种AI框架，对下服务AI处理器与编程，发挥承上启下的关键作用，是提升昇腾AI处理器计算效率的关键平台。

1243 关注者

【入门必看】算子开发环境快速搭建手册 9月25日

成就感 ②
3.63 K 1.55 K 266.43 K
Star Fork Download
27 > 1.08 K > 4.28 K >
项目 Issue PR

常用语言
C++ Shell Python CMake C

社区动态
【重磅大奖来袭】25年CANN训练营第二季社区任务...
开放讨论 · QQ 75 10月28日
【社区任务】流程及注意事项
开放讨论 · QQ 1 22 天前
基于算子开源仓进行算子开发常见问题及解决方案
开放讨论 · QQ 2 11月5日
算子开源仓开发者贡献流程
开放讨论 · QQ 0 11月5日
昇腾AI算法挑战赛进阶赛启动!
开放讨论 · QQ 0 11月5日
更多动态 >

CANN

README

开源项目

组件	描述	源码仓
算子库	提供了丰富的深度优化、硬件亲和的高性能算子，为神经网络在昇腾硬件上加速计算提供基础。	ops-nn ops-math ops-transformer ops-cv atvoss
通信库	基于昇腾硬件的高性能通信库，提供单机多卡及多机多卡间的数据并行、模型并行通信方案。	hixl hccl hcomm
图引擎	计算图编译和运行的控制中心，提供图优化、图编译管理以及图执行控制等功能。	graph-autofusion ge(建设中)
编程语言	CANN针对算子开发场景推出的编程语言，最大化匹配用户开发习惯，提供算子模板库，支持算子极简编程。	asc-devkit pyasc pyproto(建设中)
运行时	提供了高效的硬件资源管理、媒体数据预处理、单算子加载执行、模型推理等开发接口。供开发者轻松构建高性能人工智能应用。	建设中

关于社区

社区治理架构及章程

CANN 社区采用分层协作的治理模式，当前架构主要包括以下组织：

- [技术指导委员会 \(TSC-Technical Steering Committee\)](#)
- [项目管理委员会 \(PMC-Project Management Committee\)](#)
- [特别兴趣小组 \(SIG-Special Interest Group\)](#)

更多社区治理内容，详见：[社区治理章程](#)

参与贡献

- [基础贡献](#)：包含参与社区会议、社区邮件讨论、提交 Issue 、处理 Issue 任务、提交PR等。
- [进阶贡献](#)：包含新建 SIG、成为核心贡献者、组织会议、新建仓库、引入开源软件、发布新版本或新仓库等。

快速体验

若您希望快速体验CANN算子的调用和开发过程，请访问如下文档获取简易教程。

- [算子调用](#)：介绍调用算子的基本步骤、快速搭建环境，实现算子编译执行。
- [算子开发](#)：介绍开发算子的基本流程，一键创建算子工程目录，实现Tiling、Kernel核心交付件。

CANN

CANN Be X 计划启动

CANN社区邀您共建▶



<https://gitcode.com/cann>

CANN社区(深圳)邀您共建▶



can be

can do

首席体验官

代码&文档的bug hunting

赏金猎人

揭榜社区任务

城市主理人

成立并运营CANN城市开发者俱乐部

校园合伙人

成立并运营CANN校园开发者俱乐部

布道师

项目推广，技术与经验分享

金牌讲师

基础课程建设与授课

社区建筑师

代码贡献

CANN

Thanks !



访问CANN开源社区



关注昇腾CANN公众号

