Ascend 950 HiF8模型量化技术的训推实践

分享嘉宾：余子伟

2026.4.18　中国·北京

01 HiFloat8格式介绍

02 推理场景实践

03 训练场景实践

content

目录

HiFloat8格式介绍

01

HiFloat8：兼顾精度和动态范围

HiF8 (HiFloat8) 是一种新型的 8 位浮点格式，它旨在通过优化格式本身的动态范围和精度平衡，来摆脱对复杂细粒度缩放的依赖，从而实现更高效的推理。

点位域Dot: 变长前缀码，编码阶码存储的位宽，和Denormal标志

HiF8 Normal编码

$$X = (-1)^S \times 2^E \times 1.M$$

										阶码值
Dot = 0	S	0	0	0	1	0	M	M	M	E = 0
Dot = 1	S	0	0	1	SE	1	M	M	M	E = ± 1
Dot = 2	S	0	1	SE	1	E	M	M	M	E = ± [2,3]
Dot = 3	S	1	0	SE	1	E	E	M	M	E = ± [4,7]
Dot = 4	S	1	1	SE	1	E	E	E	M	E = ± [8,15]

阶码：原码编码，含1-bit隐藏位不存储(红色数字表示)
SE：Sign of Exponent

HiF8 Denormal编码

$$X = (-1)^S \times 2^{M-23} \times 1.0$$

Dot = Denormal	S	0	0	0	0	M	M	M	E = [-22,-16]

HiF8介绍：

1. HiF8利用即时可译的变长前缀码编码点位域Dot，显示指示阶码存储的位宽和Denormal标志，实现符合AI数据分布特征的锥形精度格式。
2. 同时阶码采用原码编码，并隐藏了1-bit固定值不存储，确保了不同位宽的阶码表达范围不重复，进而实现无冗余编码。
3. 最后通过特殊的Denromal设计，将综合阶码范围从[-15, 15]提升到了[-22, 15], 共38个阶码，接近FP16的40个阶码值表达。

综上，HiF8兼顾精度和动态范围，为神经网络的训练和推理，提供了能力更全面的8-bit单数据格式表达

量化粒度介绍

量化粒度是模型压缩中精度与硬件效率的权衡点：粒度越细(如逐组或分块），对数值分布的覆盖越精准，越能减小量化噪声，但也会带来更多的缩放因子存储开销和计算复杂度。

HiF8锥形精度图

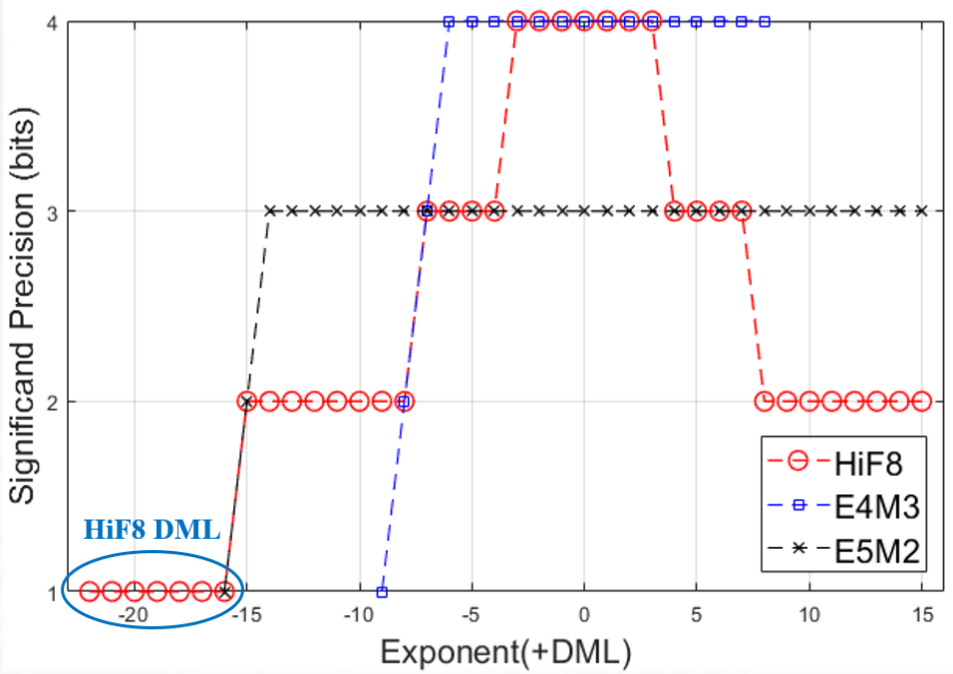

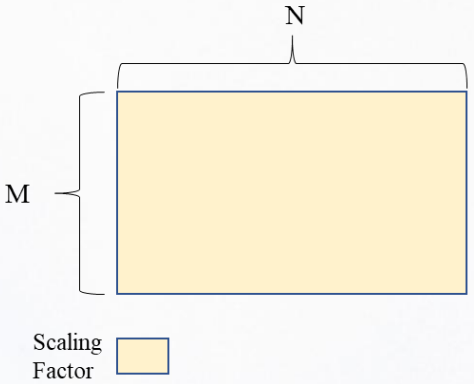

(a) Per-Tensor Scaling

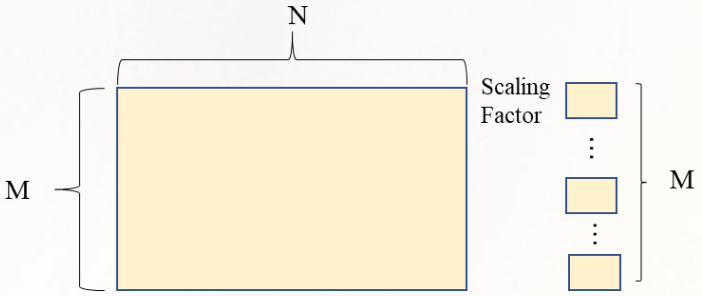

(b) Per-Token Scaling

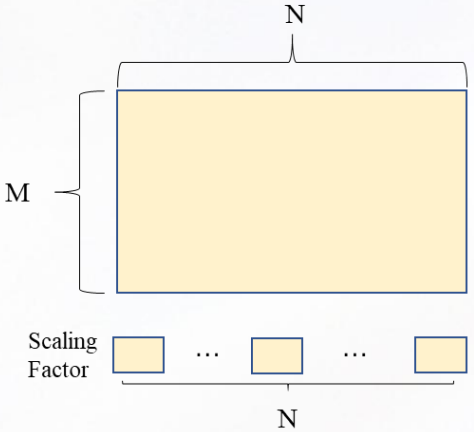

(c) Per-Channel Scaling

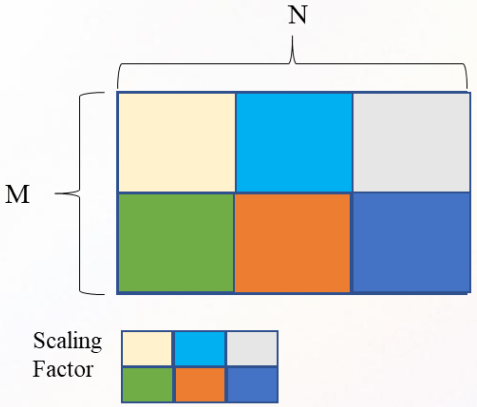

(d) Per-Block Scaling

模型推理的Scaling策略：将大部分数据静态缩放到高精度区间中

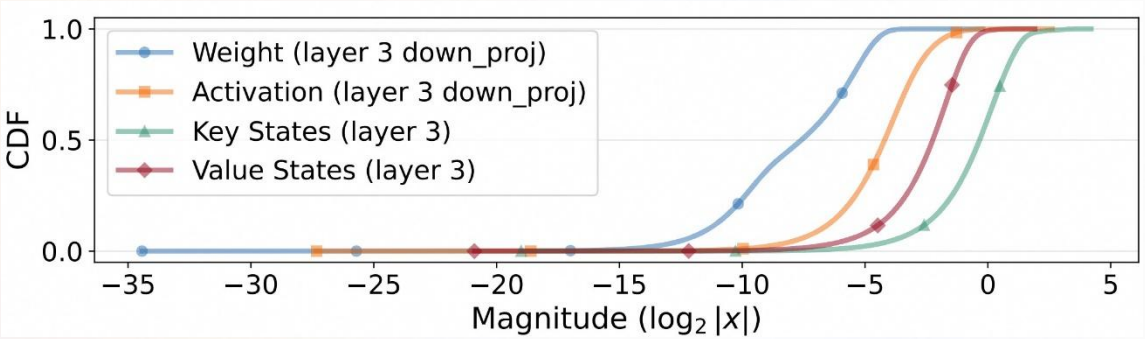

以Qwen3-8B Layer3为例，累积概率图显示：

- 权重：阶码集中在[-12，-5]，直接转HiF8数据基本都落在了中精度区间(保真度和E5M2基本一致)。Per-Tensor/Per-Channel地把最大幅值Amax静态缩放到2^4，保真度可以和MXFP8-E4M3一致。
- 激活：阶码集中在[-7, -2]，通过PTQ统计校准集激活值特征，1）Per-tensor /Per-Token地把最大幅值静态缩放到2^2~2^4 (或者97%~99%分位幅值缩放到2^2), 2）或者通过MSE最小化离散搜索，确定静态缩放系数。基于以上策略保真度可以和MXFP8-E4M3一致，或者略优于MXFP-E4M3(保留了更多小值)。

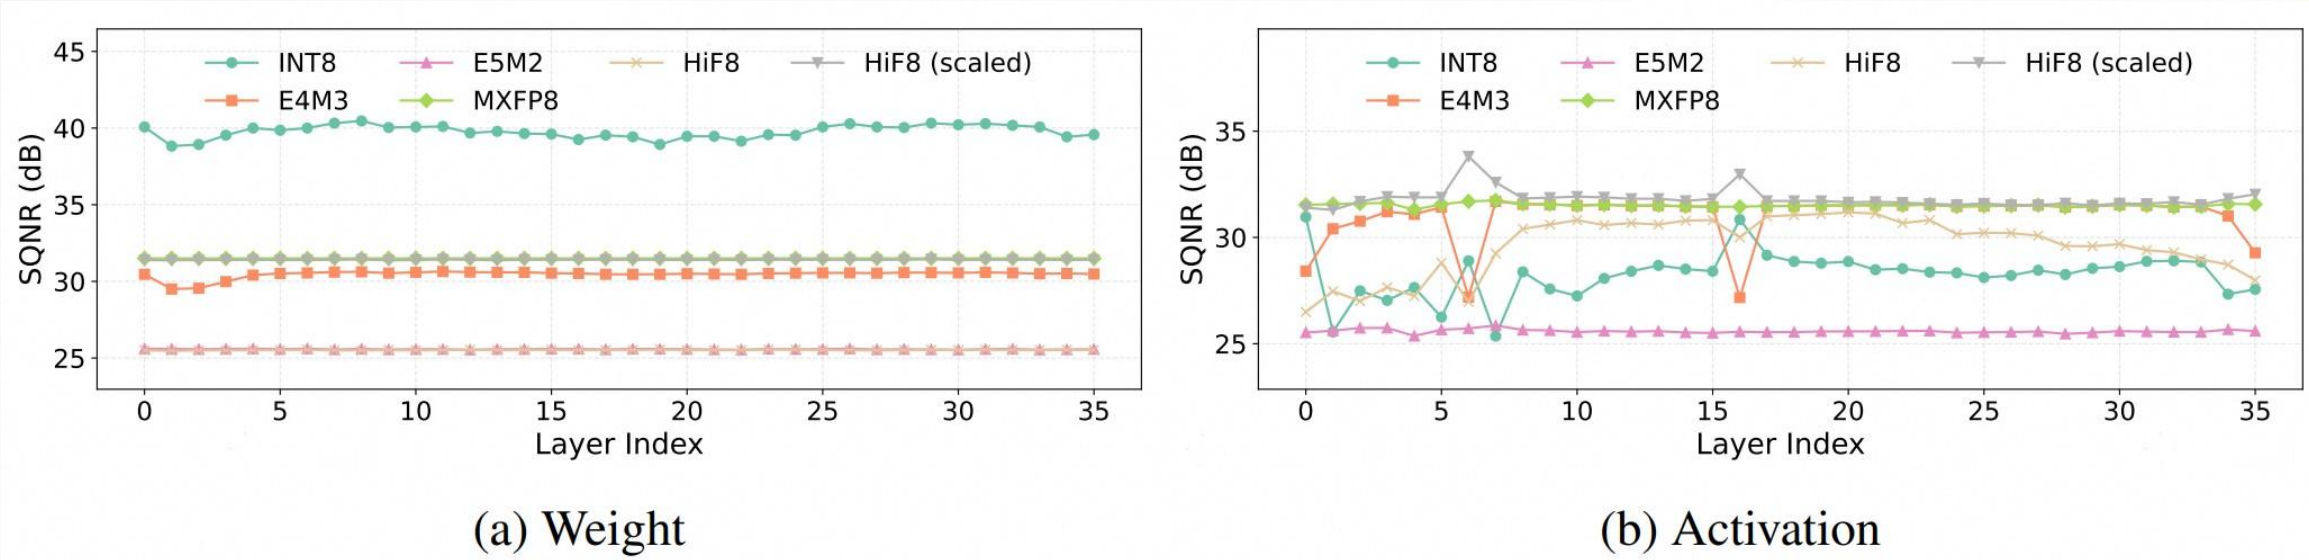

通常简单的A Per-Tensor/W Per-Channel缩放，就能获得很好的推理精度

模型训练的Scaling策略：通过Delayed-Scaling实现8-bit训练性能最大化！

HiF8 Current-Scaling：精度和稳定性优先

$$Scale = \frac{K}{Amax+\varepsilon}$$

$$X_{sclaed} = X \cdot sclae$$

- 权重：Per-Tensor/Per-Channel $K = 2^4$
- 激活/梯度：Per-Tensor $K = 2^4$，2^5, 或 2^6

Delayed-Scaling原理：训练性能优先

$$Scale = \frac{F8max \times 2^{-N_{guard}}}{\overline{Amax} + \varepsilon}$$

$$X_{sclaed} = X \cdot sclae$$

- $F8\max$：8位浮点格式最大幅值，HiF8是2^{15}（E4M3是448）
- N_{guard}：Safety Margin，即保护阶码位个数，防止用历史Amax近似当前Amax的数值波动，引发上溢产生Inf/NaN

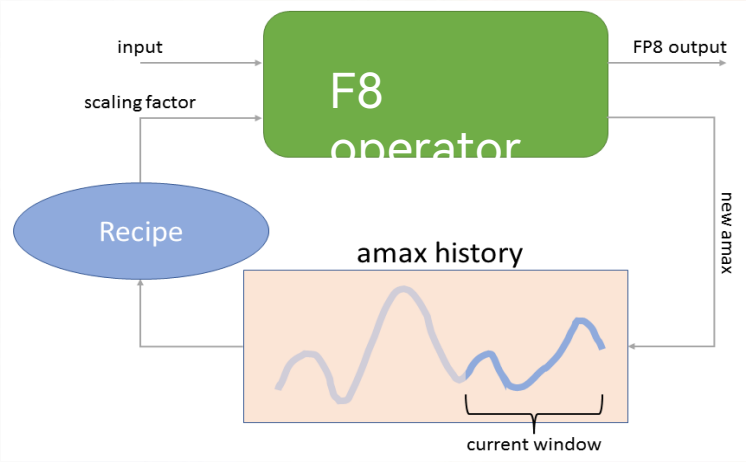

HiF8 Delayed-Scaling：高性能稳定训练建议

- 权重N_{guard}：11或者12，剩余27或者26个阶码表达数据
- 激活/梯度N_{guard}：9，10或者11，剩余29~27个阶码表达数据
- Amax统计频率Interval：5~20次迭代统计一次，默认10
- Amax History Length：64，128或者256
- 训练初始化(重启)：初始化(重启)因为没有Amax History，第一次迭代需要使用Current-Scaling，后续开启Delayed-Scaling。
- 异常处理：如果某次迭代检测出Inf/NaN，停止该步计算，不更新权重，清空History Buffer，不丢弃当前训练步数据，重启Delayed-Scaling训练。

推理场景实践

02

LongCat-Flash Base HiF8 昇腾推理实践

复现longcat-flash精度，采用tp=8，ep=32部署方案，**bf16精度与论文基本持平**，HiF8**直转**与当前bf16精度相当。

Benchmark	BF16格式	HiF8-A8W8直转	ACC.Diff	HiF8-A8W8+W-PCS	ACC.Diff	备注
ARC_c	84.38	82.92	**-1.46**	86.35	+1.97	bs8，0-shot ;单选
ACR_e	86.64	87.40	+0.76	87.61	+0.97	bs8，0-shot; 单选
PIQA	91.46	90.21	**-1.25**	91.73	+0.27	
CEval	72.96	73.70	+0.74	72.44	-0.52	bs 2, 5-shot; 单选
GPQA	42.42	42.42	+0.00	44.44	+2.02	bs 8, 0-shot; 单选
WinoGrande	80.27	79.32	-0.95	79.32	-0.95	bs 8, 5-shot; 选择+填空
均值	76.36	76.0	**-0.36**	76.98	**+0.62**	

推荐方案：w-离线per-channel校准，A-直转或静态per-tensor

对LongCat模型使用HiF8直转或者加上W-PCS 精度可以对齐BF16

LongCat-Flash Base HiF8 昇腾推理实践

复现longcat-flash精度，采用tp=8，ep=32部署方案，**bf16精度与论文基本持平**，HiF8**直转**与当前bf16精度相当。

Benchmark	BF16格式	HiF8-A8W8直转	ACC.Drop	HiF8-A8W8+W-PCS(16)	ACC.Drop	HiF8-A8直转-W-静态PCS-C-静态PTS	Acc. Drop	备注
MMLU-Pro	58.83	58.56	-0.27	58.07	-0.76	57.88	-0.95	bs 8, 5-shot
CMMLU(中)	81.65	82.42	+0.77	81.02	-0.63	83.21	+1.56	bs 8, 5-shot
MATH500	91.60	90.40	**-1.20**	90.8	-0.8	90.60	-1.00	bs 4,5-shot, max_model_len 5120, max_out_len 3072
GSM8K	95.91	96.21	+0.30	96.59	+0.68	95.83	-0.08	bs 4, 0-shot,max_model_len 4096, max_out_len 2560
GQPA-Diamond	42.42	42.42	0.00	45.45	+3.03	46.46	+4.04	bs 8, 0-shot
Humaneval+	75.07	75.16	+0.09	74.15	-0.92	74.54	-0.53	max_model_len 6144, max_out_len 4096
LiveCodeBench	58.77	59.05	+0.28	60.85	+1.08	58.2	-0.57	0shot,bs8 max_len 5120, output_len 2560
均值	72.04	72.03	-0.01	72.42	**+0.38**	72.39	**+0.35**	

推荐方案：w-离线per-channel校准，A-直转或静态per-tensor，C静态per-tensor

对LongCat模型使用KV Cache量化相对BF16基本不掉点

DeepSeek V3.1 HiF8 昇腾推理实践

复现DeepSeek V3.1精度，采用tp=8，ep=64部署方案，bf16精度与论文基本持平，HiF8直转与当前bf16精度相当。

Benchmark	BF16格式	HIF8-A8W8C8-直转	ACC Drop
ARC_c	94.30	94.99	+0.69
ARC_e	97.88	98.01	+0.13
BoolQ	88.01	88.07	+0.06
HellaSwag	86.26	85.83	-0.43
Piqa	94.61	94.34	-0.27
Winogrande	81.14	81.61	0.47
Gsm8K	96.36	96.51	+0.15
MMLU	84.91	84.84	-0.07
CMMLU	86.98	86.92	-0.06

DeepSeek V3.1模型使用全HiF8方案，W8A8C8直转精度可以对齐BF16

LongCat HiF8/FP8量化方案对比

背景痛点：传统MXFP8在DeepSeek/LongCat等网络在对MLA进行量化时存在天然架构局限：若采用细粒度量化，会引入严重的二次量化(Double Quantization)计算开销；若退而求其次使用FP8进行粗粒度(per-tensor)量化以规避该开销，又会导致模型模型精度下降，无法达标。这使得现有attention层的量化陷入“精度与性能无法兼顾”的死局。**HiF8的出现解决了这一难题：per-tensor粗粒度量化的MLA下依然能够保持精度，并能达成高效性能。**

Benchmark	BF16格式	HiF8 MLA	ACC Drop	FP8 MLA	ACC Drop
长COT类型数据集					
Gsm8K	95.91	96.29	+0.38	95.83	-0.08
Livecodebench	58.77	59.05	+0.28	58.20	-0.57
Humanevalx	75.07	75.15	+0.08	73.92	**-1.15**
Math500	91.6	91.20	-0.40	90.6	**-1.00**
AVG.Drop	-	-	**+0.09**	-	**-0.70**
选择题类型数据集					
ARC_c	84.91	83.61	-0.77	84.75	-0.16
ARC_e	86.64	85.81	-0.83	83.21	**-3.43**
Piqa	91.46	91.89	+0.43	92.06	+0.60
Winograde	80.27	79.36	-0.91	79.79	-0.48
AVG.Drop	-	-	**-0.52**	-	**-0.56**

对LongCat, 采用两种量化方案，HiF8 Attention的整网量化方案精度上相比FP8 Attention量化方案优势明显

DeepSeek V3.1 &LongCat 性能分析 950实测

HiF8性能分析, decode-only,即单次decode耗时，deepseek-r1性能分析:

随着输入的tokens长度逐渐增大，attention耗时在decode阶段占比越来越大。HiF8的加速比也越来越明显，整完加速比相比MXFP8在32K有1.5倍的提升。输入长度越长，提升优势越明显。

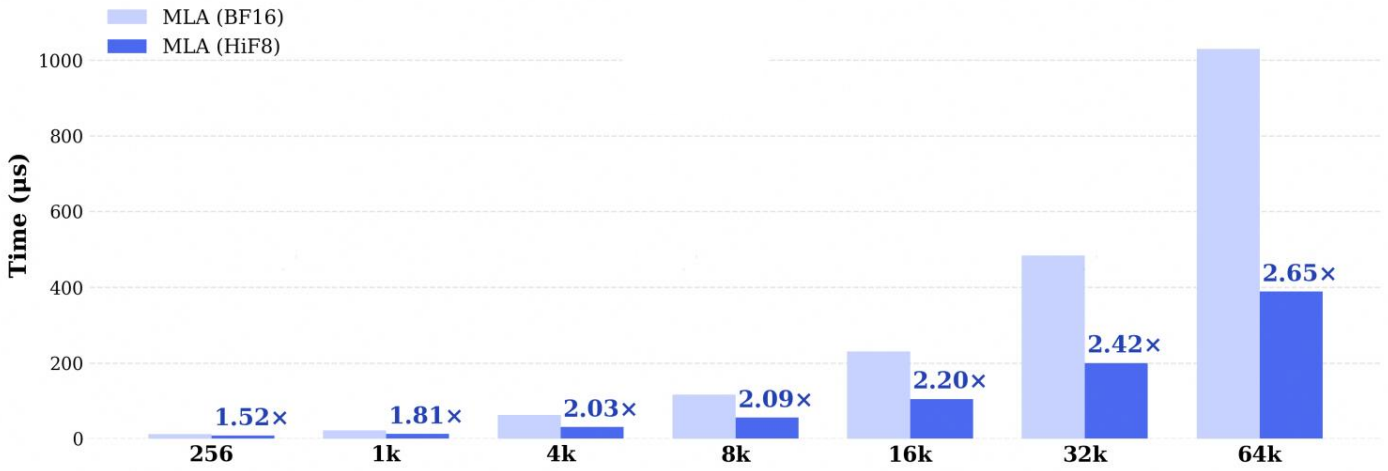

输入长度	推理DeepSeek-V3.1-670B (裁剪32专家)								
	BF16 IFA + HiF8 Linear			BF16 IFA + MXFP8 Linear			HiF8 IFA + HiF8 Linear		
	BF16 IFA耗时(us)	HiF8端到端耗时(us)	IFA占比	BF16 IFA耗时(us)	MXFP8端到端耗时(us)	IFA占比	HiF8IFA耗时(us)	HiF8端到端耗时(us)	**IFA加速比**
512	1601.832	25755.450	6.21%	1604.02	24844.246	6.46%	942.254	25095.872	**~1.70x**
1K	2085.966	24457.132	8.53%	2101.621	26121.859	8.05%	1152.467	23523.633	**~1.81x**
4K	5000.16	28840.129	17.34%	5002.099	30394.927	16.46%	2403.923	26243.892	**~2.08x**
8K	8930.002	32184.824	27.75%	8963.441	33644.258	26.64%	4272.7	27527.522	**~2.09x**
16K	16765.397	38935.846	43.06%	16761.008	41435.946	40.45%	7620.635	29791.084	**~2.20x**
32K	32362.335	57347.884	56.43%	32370.24	57411.061	56.38%	13372.866	38358.410	**~2.42x**
64K	63684.102	88120.884	72.27%	63659.461	87557.365	72.71%	24031.736	48468.518	**~2.65x**

DeepSeek V3.1 &LongCat 性能分析 950实测

HiF8性能分析, decode-only,即单次decode耗时，LongCat性能分析:

随着输入的tokens长度逐渐增大，attention耗时在decode阶段占比越来越大。HiF8的加速比也越来越明显，整完加速比相比MXFP8在64K有1.66倍的提升。输入长度越长，提升优势越明显。

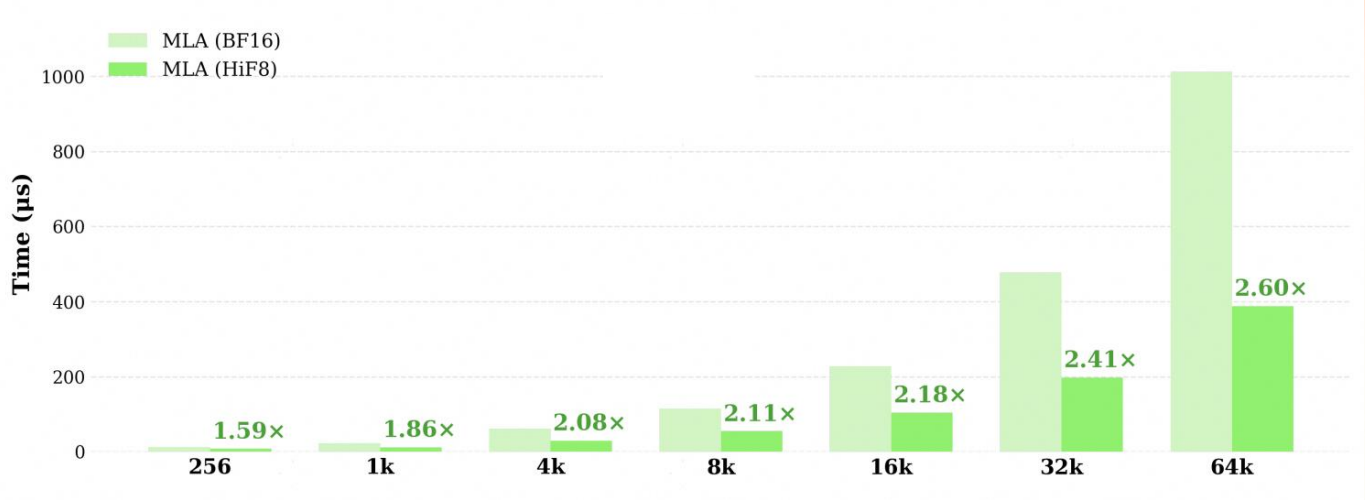

输入长度	推理LongCat-560B (裁剪版 64专家 + 32 zero专家)								
	BF16 IFA + HiF8 Linear			BF16 IFA + MXFP8 Linear			HiF8 IFA + HiF8 Linear		
	BF16 IFA耗时(us)	HiF8端到端耗时(us)	IFA占比	BF16 IFA耗时(us)	MXFP8端到端耗时(us)	IFA占比	HiF8IFA耗时(us)	HiF8端到端耗时(us)	**IFA加速比**
512	1121.405	29156.853	3.85%	1075.520	23895.660	4.50%	659.650	28695.10	**1.70x**
1K	1533.662	28687.377	5.35%	1519.910	26239.801	5.79%	824.549	27978.26	**1.86x**
4K	4294.905	33776.888	12.72%	4312.755	30842.276	13.98%	2064.858	31546.84	**2.08x**
8K	7940.443	38400.177	20.67%	7927.499	32498.165	24.39%	3763.243	3422.980	**2.11x**
16K	15235.745	46448.157	32.80%	15225.646	39394.943	38.65%	6988.874	38201.29	**2.18x**
32K	29824.365	59478.198	50.14%	29819.718	56526.12	52.75%	12375.260	42029.09	**2.41x**
64K	59657.625	92686.979	64.36%	59693.912	89036.737	67.04%	22945.240	55974.59	**2.60x**

训练场景实践

03

基于HiF8的Delayed Scaling训练

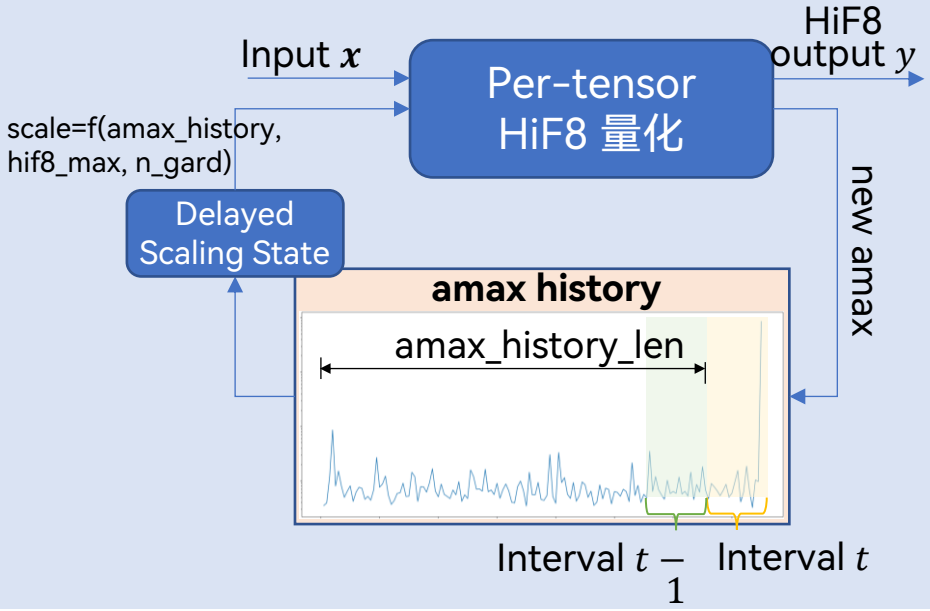

Property	基于HiF8的策略	TransformerEngine
amax_hist_len	1	1024
interval	10 steps	1 step
稳定性	基于HiF8稳定训练	在多个FP8实例中不稳定 [2-4]
稳定训练策略	极端情况下，无损续训	调整架构 (e.g., Smooth-SwiGLU[3], FOG-max[4])以稳定训练

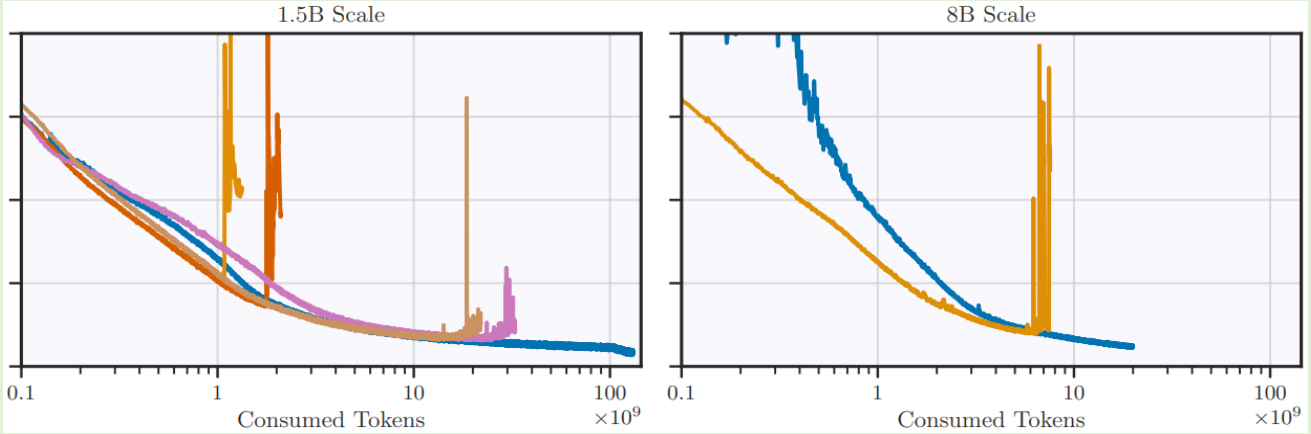

FP8+TE delayed scaling[4]： 除变架构的FOG-max，各模型(390M~8B)均未稳定训练至>20B

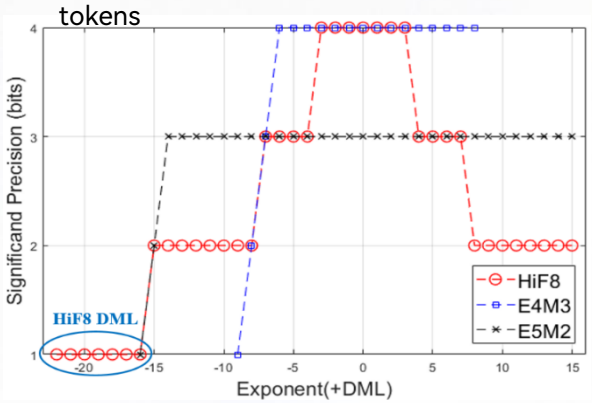

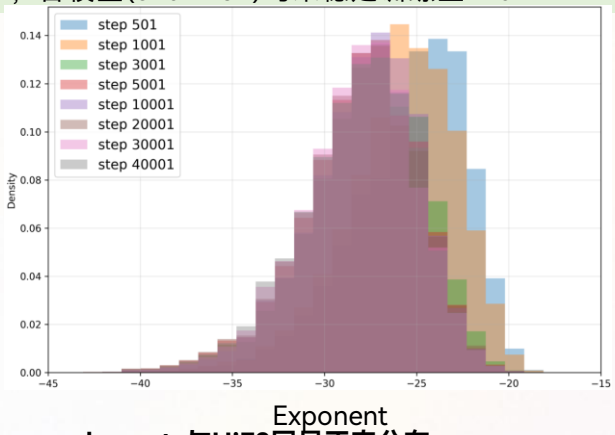

1) HiF8有极大的动态范围；2) 训练中的tensor elements与HiF8同呈正态分布

Buffer	Strategy	HiF8 NaN (DS interval 10)	FP8 NaN (DS interval 10)	FP8 NaN (DS interval 1)
16	DS	7	986	764
128	DS	0	892	646

HiF8的大动态范围使interval > 1稳定训练大语言模型成为可能，充分发挥8-bit training与delayed scaling的性能潜力，权重/激活/梯度均采用per-tensor-scaling

[1] Transformerengine: An efficient library for training transformer models, 2024b.
[2] Fujii, Kazuki, Taishi Nakamura, and Rio Yokota. "Balancing speed and stability: The trade-offs of fp8 vs. bf16 training in llms." arXiv preprint arXiv:2411.08719 (2024).
[3] Fishman, Maxim, et al. **ICLR 2025**. "Scaling fp8 training to trillion-token llms." arXiv preprint arXiv:2409.12517 (2024).
[4] Hernández-Cano, Alejandro, et al. **NeurIPS 2025**. "Towards Fully FP8 GEMM LLM Training at Scale." arXiv preprint arXiv:2505.20524 (2025).

基于HiF8的Delayed Scaling训练: 大语言模型训练loss与下游任务精度

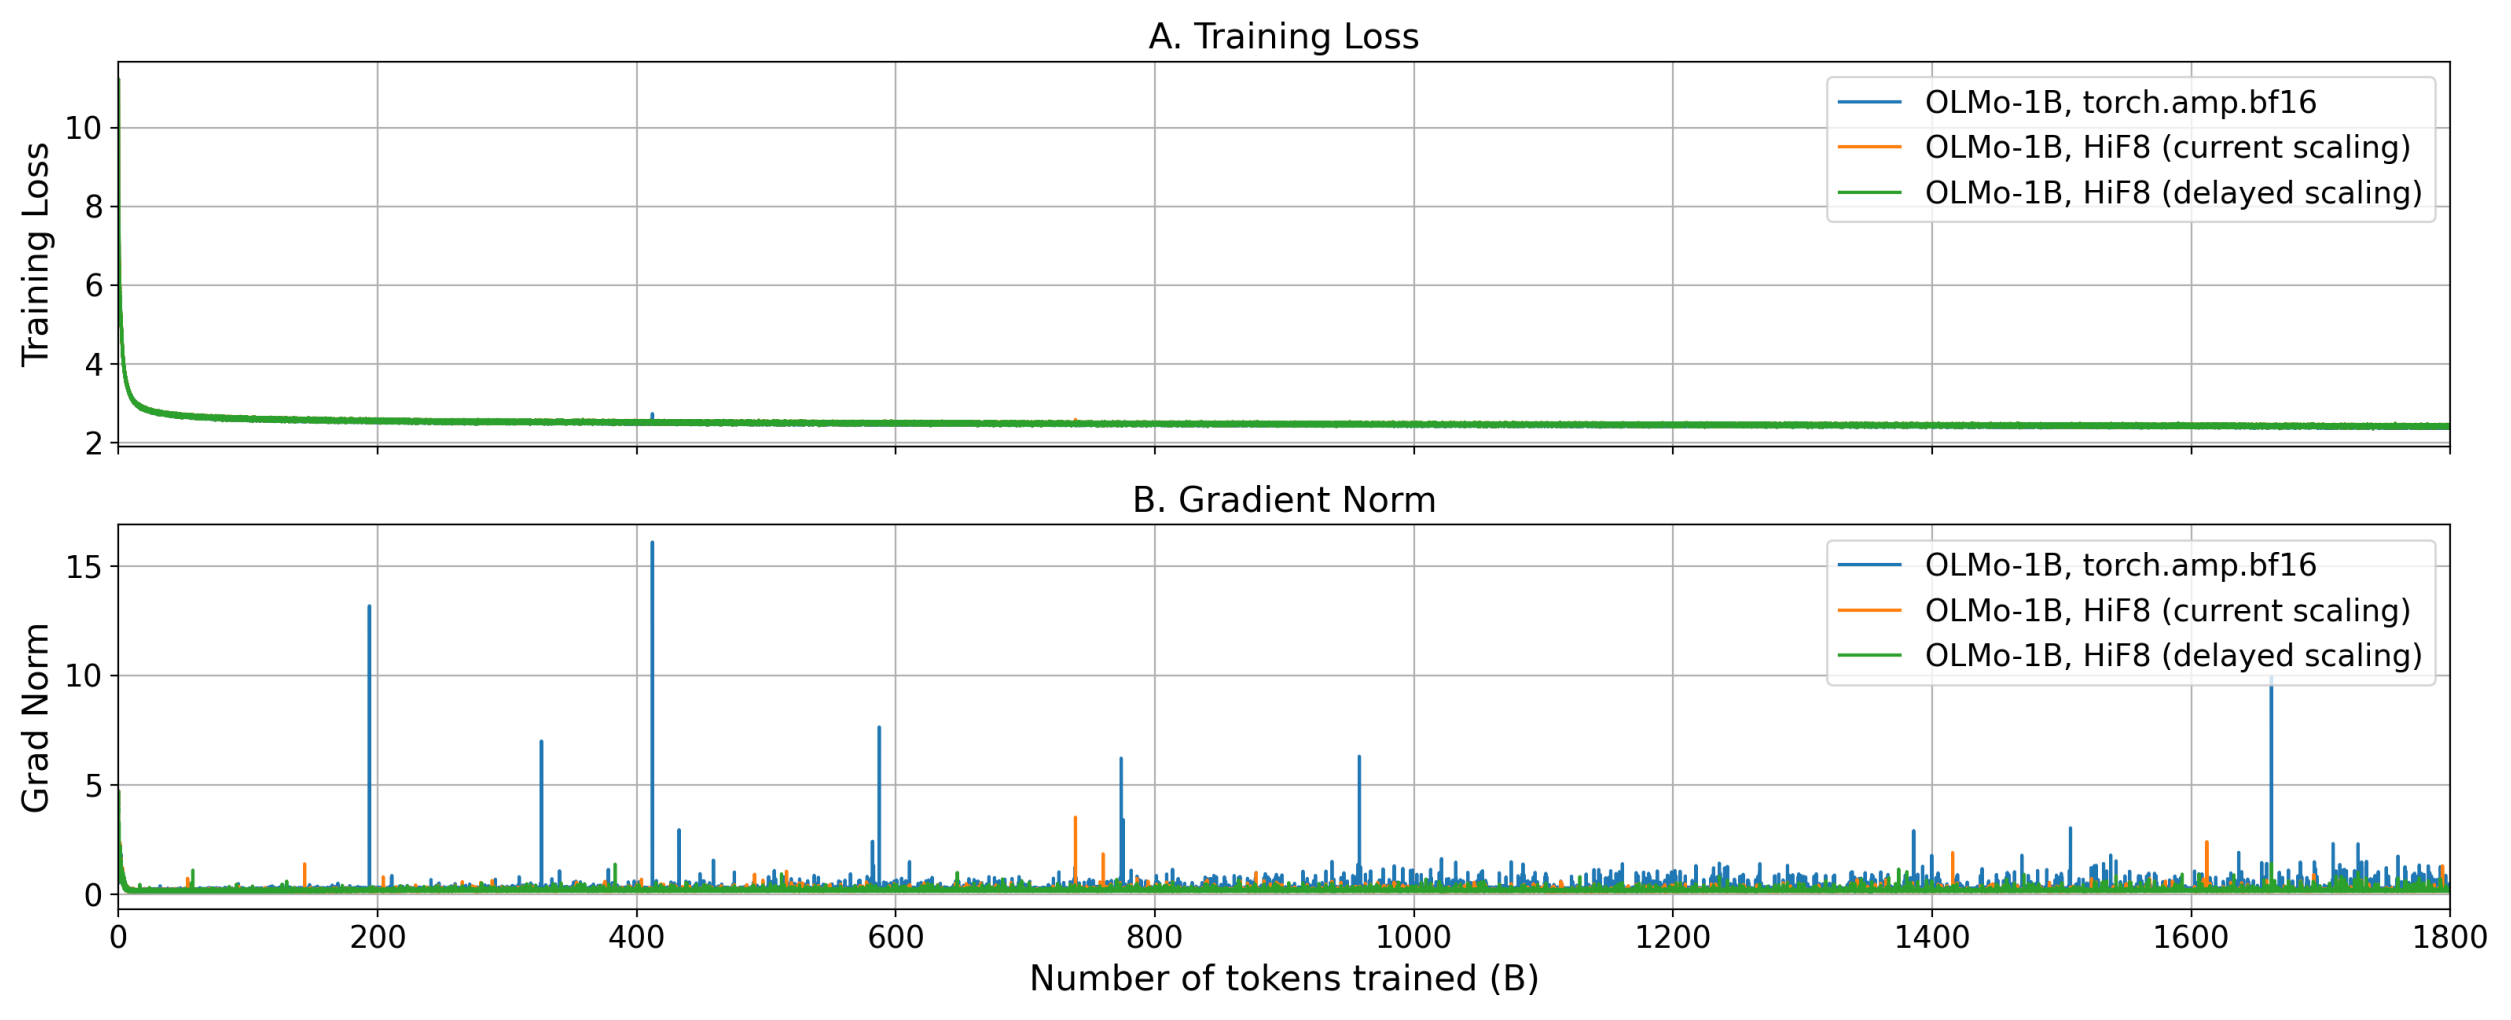

- 从loss、grad_norm看，HiFloat8 CTS/DTS (interval = 5) 的训练稳定收敛，与BF16 baseline保持一致

基于HiF8的Delayed Scaling训练: 训练动态

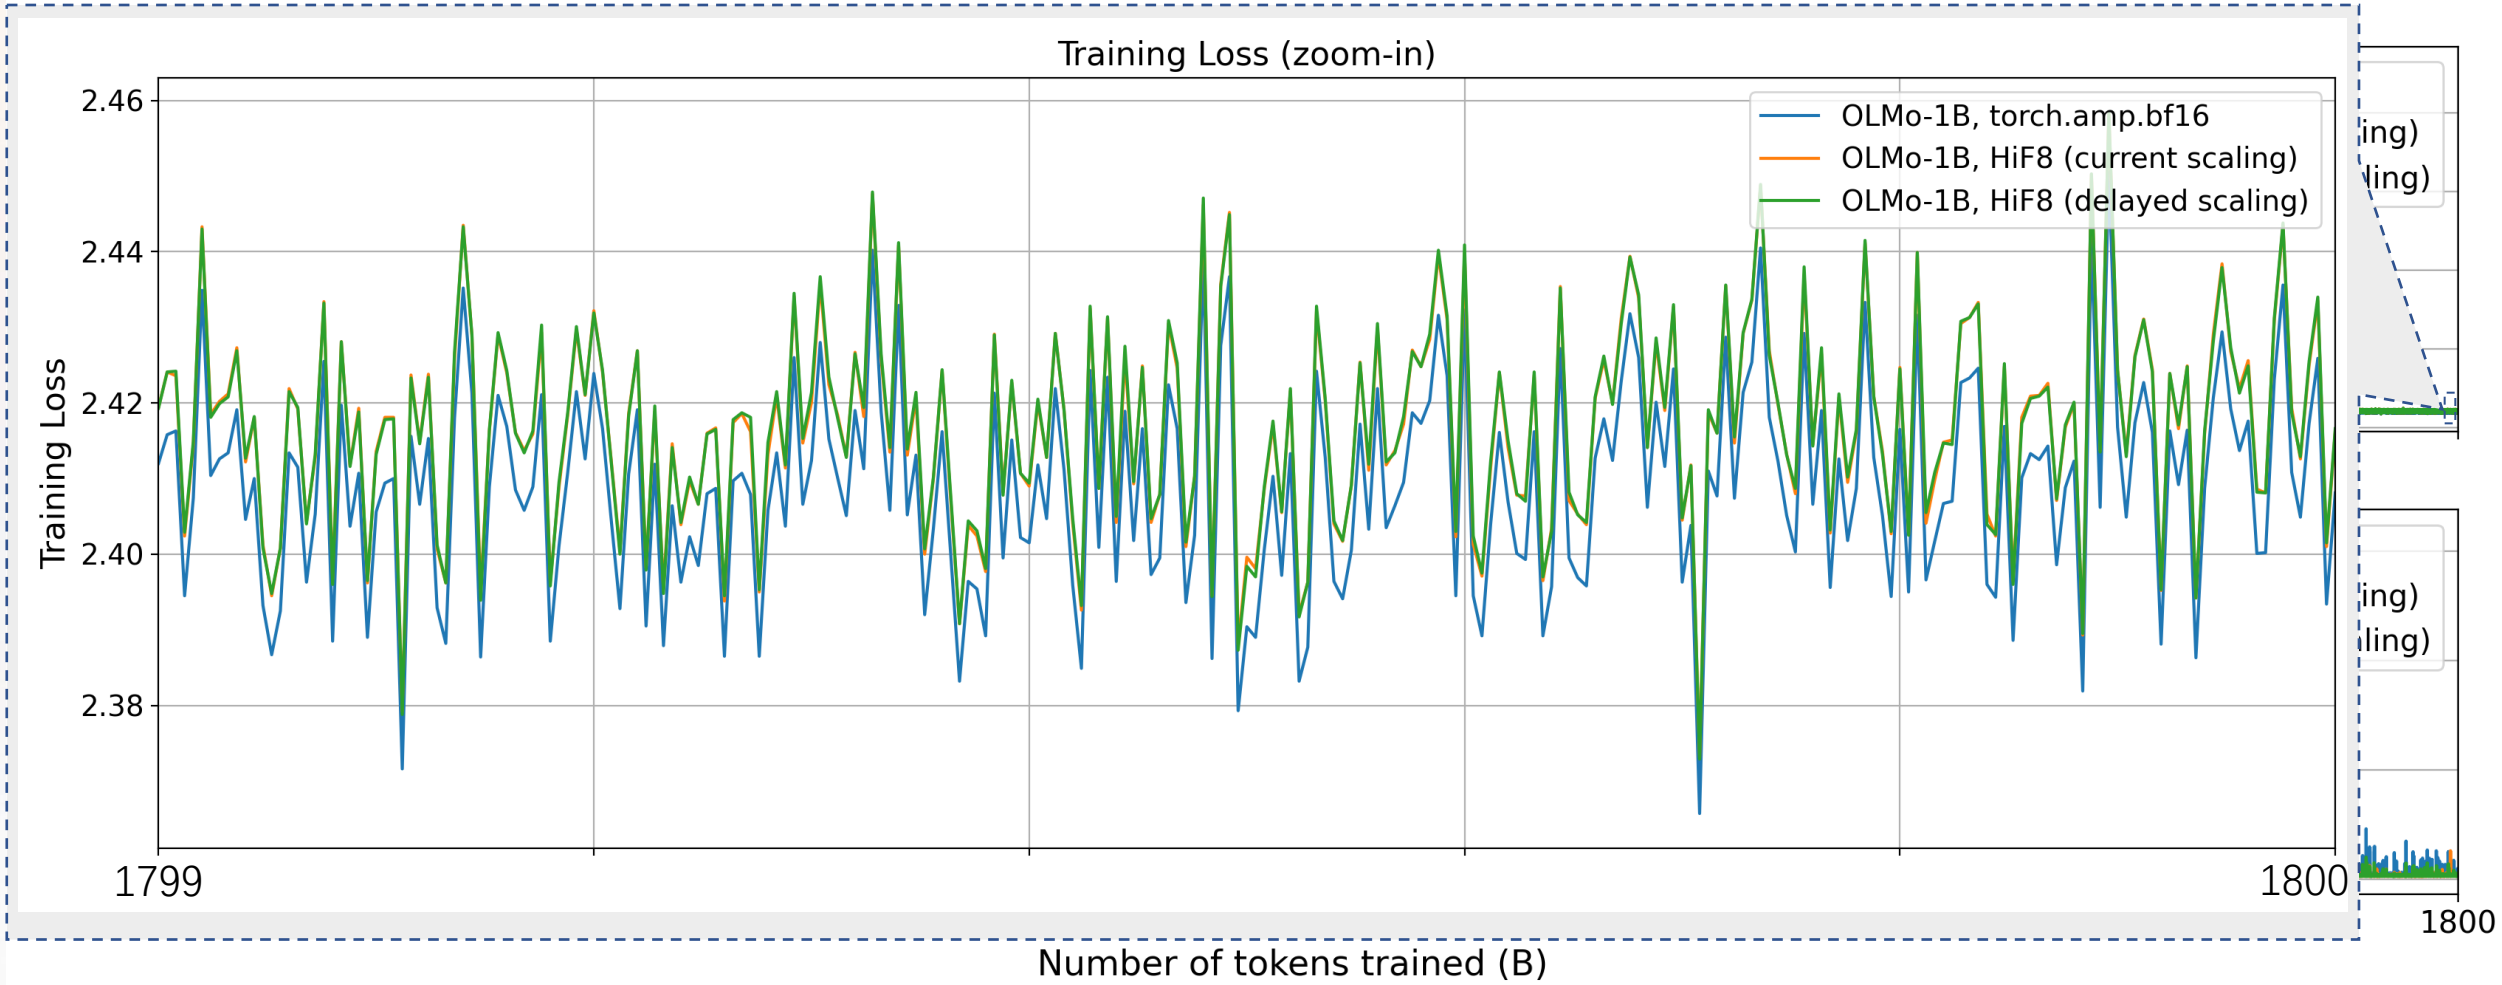

- 从loss、grad_norm看，HiFloat8 CTS/DTS (interval = 5) 的训练稳定收敛，与BF16 baseline保持一致

基于HiF8的Delayed Scaling训练: 训练动态

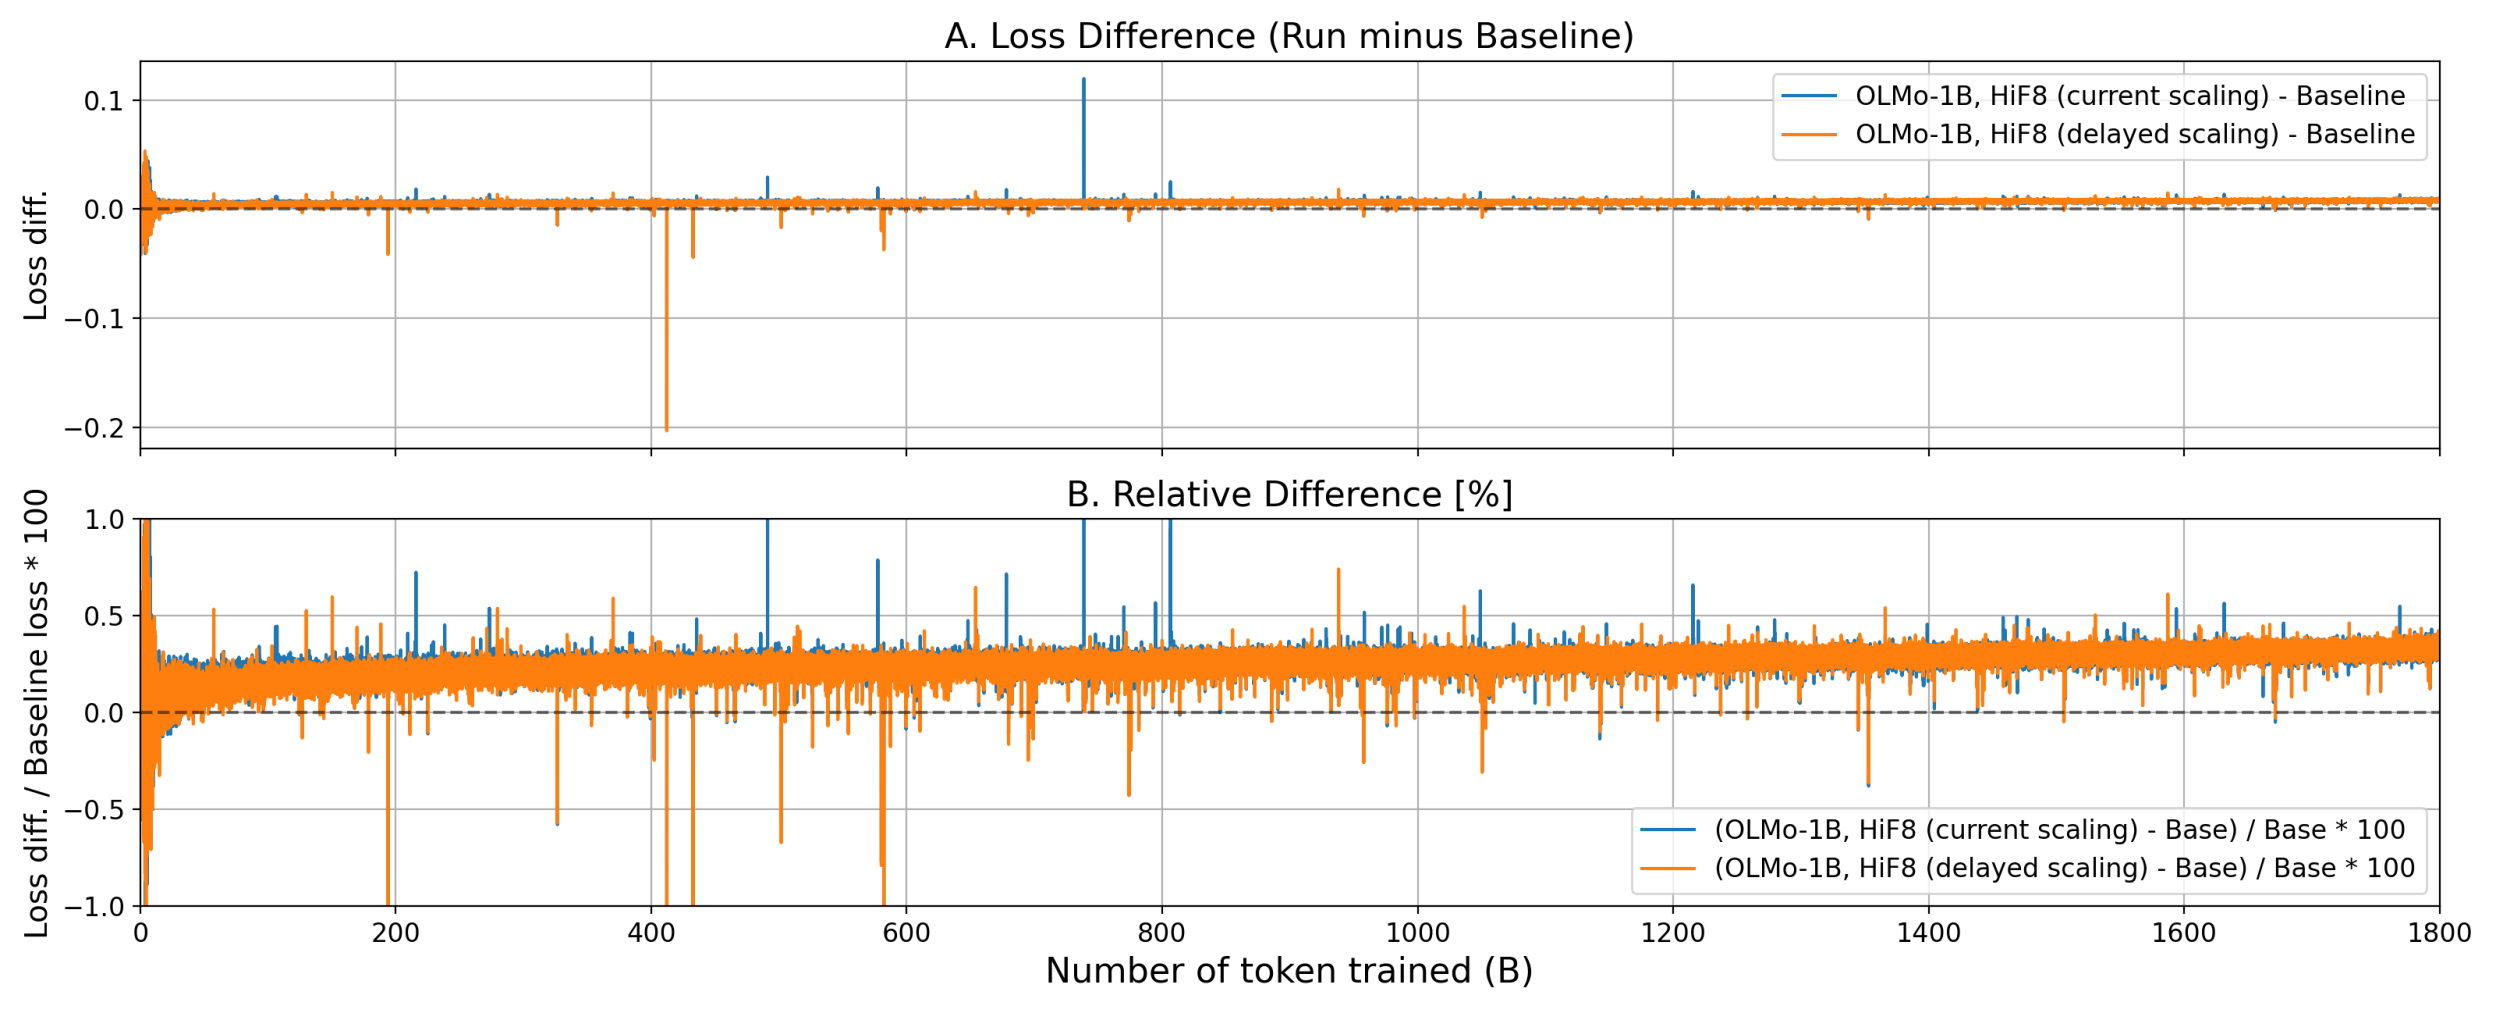

- 从loss、grad_norm看，HiFloat8 CTS/DTS (interval = 5) 的训练稳定收敛，与BF16 baseline保持一致
- 更细致地看，HiFloat8和BF16的training loss在训练中虽然有差异，但相对误差稳定在0.5%以下

基于HiF8的Delayed Scaling训练: 大语言模型训练loss与下游任务精度

Training precision	Scaling Strategy	PIQA	Boolq	ARC_E	SciQ	HellaSwag	Avg. Acc.
HiF8	DTS	75.9%	61.4%	63.0%	86.9%	62.1%	69.86%
	CTS	75.6%	62.2%	63.0%	86.3%	62.3%	69.88%
BF16	复现精度	75.3%	62.1%	63.1%	87.3%	62.6%	70.08%
	官方精度	75.1%	62.2%	63.3%	87.0%	62.9%	70.10%

- 从loss、grad_norm看，HiFloat8 CTS/DTS (interval = 5) 的训练稳定收敛，与BF16 baseline保持一致
- 更细致地看，HiFloat8和BF16的training loss在训练中虽然有差异，但相对误差稳定在0.5%以下
- 当训练至1.8T tokens时，HiFloat8训练得到的模型在几个典型benchmarks上已经达到官网模型水平

基于HiF8的Delayed Scaling训练案例: DS_V3裁剪版网络(950 DT)

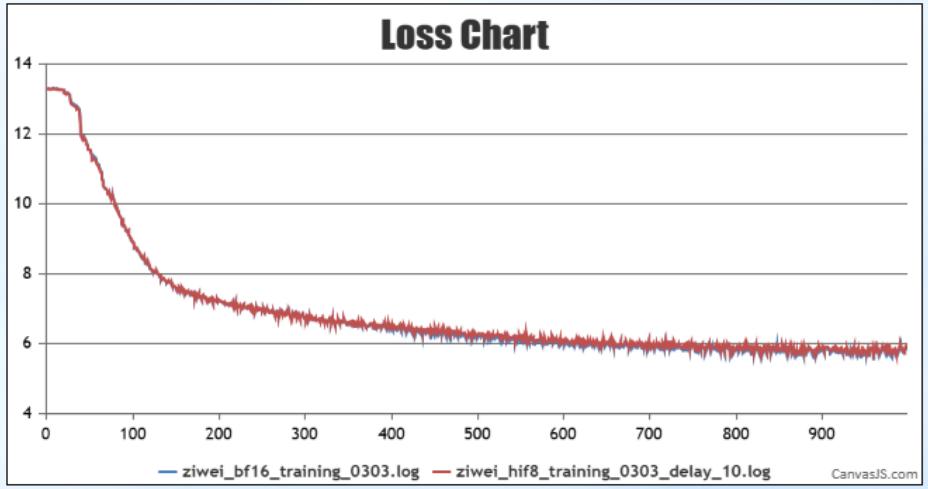

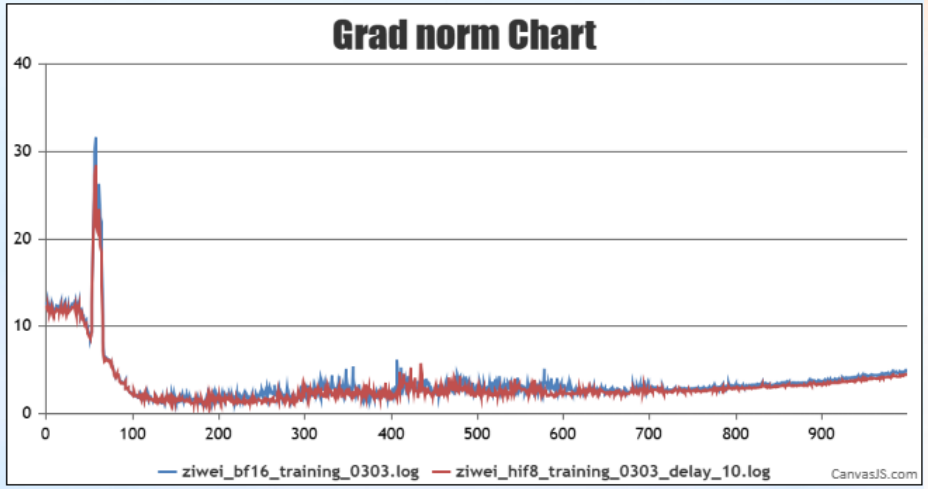

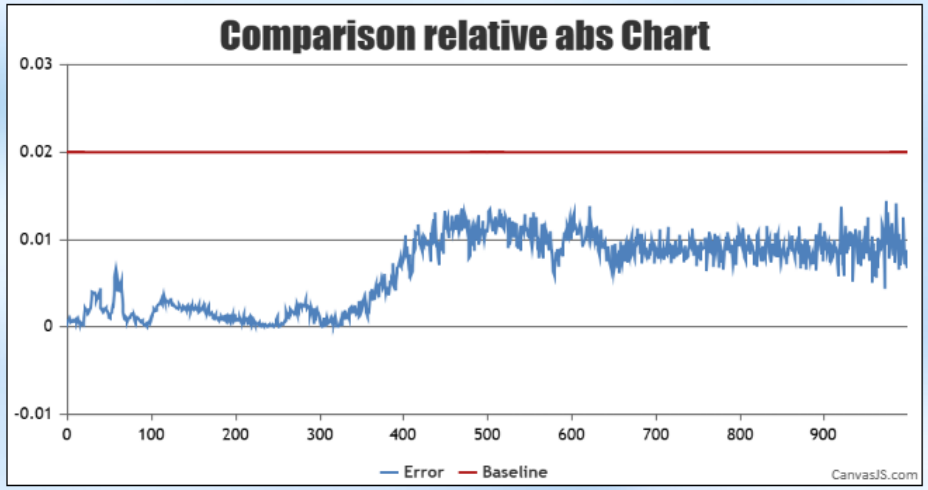

Mean Error:0.006470605579347702, Mean Square Error:0.000058669358343391205

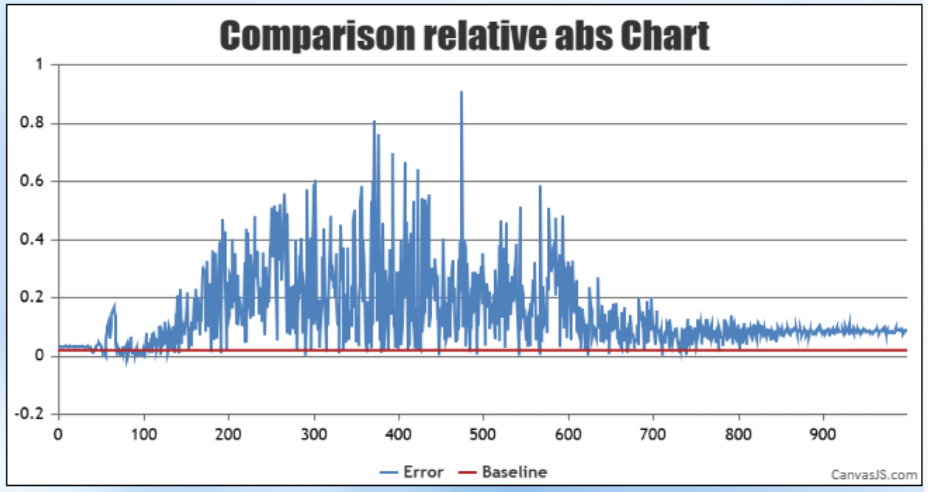

Mean Error:0.14265092630454196, Mean Square Error:0.03703116363521946

HiF8端到端耗时	MXFP8端到端耗时	BF16端到端耗时	HiF8相对MXFP8端到端训练提速	HiF8相对BF16端到端训练提速
2807961.52us	3125265.99us	3636290.95us	x1.113	x1.295

基于HiF8的Delayed Scaling训练案例: 1xB级别多模态生成网络(950 PR 单机8卡)

Seq=7200				
bs=1	单元块	BF16时延(ms)	HiF8时延(ms)	提速比(HiF8/BF16)
计算部分	FA前向+反向	3052.3	1606.5	1.9x
	Linear	1281.8	733.0	1.75x
	Vector	948.0	1148.9	0.83
未遮掩通信部分	all-to-all	426.7	229.4	1.86x
调度		29.4	298.5	0.1
端到端		5738.1	4016.3	1.43x

(a) BF16 Baseline

(b) End to End HiF8 Scheme

Thanks!

访问CANN开源社区

关注昇腾CANN公众号

上述相关工作，后续会相继在CANN-Recipe-Infer仓上开源开放！