




DeepSeek V4 模型特性和 昇腾优化技术 解读

邹楠 昇腾解决方案大模型技术专家



< 鲲鹏昇腾开发者大会2026 >

目录


01 DeepSeek V4 模型解析

02 昇腾-整网优化 解析

03 DeepSeek V4 亲和分析

DeepSeek V4 模型解析

模型演进与趋势变化



越来越高效的KVCache利用，更多更广的专家结构

DeepSeek V4 模型解析

演进趋势概述

DeepSeek V4

- 总参数 1.6TB
 - 61层
 - 1M上下文
- 模型结构
 - Hybrid Attention
 - Win + CSA + HCA
 - MoE 结构
 - 3-hash-routing
 - topK-6(384+1)
 - mHC 结构
- 投机推理
 - MTP 架构

Hybrid Attention结构组合滑窗、稀疏、压缩算法		
整体能力		影响
Win Attn	每层都有，保持最近邻的token的注意力	无需全量cache，保留最近邻token
CSA	4倍压缩 + Indexer 选择高注意力token	无需全量cache，保留4倍压缩历史KVCache
HCA	128倍压缩	无需全量cache，保留128倍压缩历史KVCache
整体影响：大幅压缩KVCache 提升模型可支持长度		
□ Attn内存占用：Flash (6.8GB) / Pro (24GB)		


MoE结构 + mHC		
整体能力		影响
MoE	384专家中选择top6	增多的专家个数，减少的激活参数
	3层hash-routing+全MoE	保持浅层特征稳定性，导向全MoE结构
mHC	扩展传统残差链接	约束信号，提升训练稳定性
整体影响：可部署范围扩大，激活更少 → 提升吞吐		
□ 激活参数：Flash (13B) / Pro (49B)		

DeepSeek V4 模型解析


Attn变化: 更大的Dim, 统一的范式, 压缩的长度

DeepSeek V4


- 更大的Dim:
 - a. Dim=512
 - b. 128个Head * 512Dim的超大隐变量
- Rope融入:
 - a. 不再像MLA需要wk
 - b. Prefill / Decode同构不区分
 - c. KV同构后通过逆Rope还原V的non-rope
- Cache多维度压缩-Hybrid Attn:
 - a. 分层压缩CSA + HCA
 - b. 最近邻 win Attn叠加
 - c. 更大的Dim也不会Cache爆炸



MLA



MQA




CSA

DeepSeek V4 模型解析

Attn结构引导

DeepSeek V4

- Win / MTP 滑窗注意力机制:
 - a. window size 128 的滑窗注意力机制
- CSA 滑窗+压缩4倍+稀疏:
 - a. window size 128 的滑窗注意力机制
 - b. 对原始上下文压缩4倍，压缩时存在overlap，存储压缩后的cache；
 - c. 通过Lightning Indexer稀疏选取top K KV，用于DSA计算（K512 / K1024）
- HCA 滑窗+压缩128倍:
 - a. window size 128 的滑窗注意力机制
 - b. 对原始上下文压缩128倍，压缩时无overlap，不做稀疏；




DeepSeek V4 模型解析

Compressor引导 – CSA & HCA: 不同压缩倍率交织, 大幅降低KV Cache内存占用

DeepSeek V4

- CSA 压缩4倍, 存储压缩后KV:
 - a. 通过overlap, 8token压缩
- HCA 压缩128倍, 存储压缩后KV :
 - a. 无overlap, 高比例直接压缩
- 尾块保留, 暂存等待压缩:
 - a. 不满足压缩长度的token信息暂存在 State Cache 和 Score Cache



目录

01 DeepSeek V4 模型解析


02 昇腾-整网优化 解析

03 DeepSeek V4 亲和分析

昇腾-整网优化解析


Attention

- 针对Attention模块，开源提供高性能融合算子：
 - **SparseAttnSharedKV (SAS)**：一个接口支持多种attention；
 - **Compressor & Compressor Epilog**：支持不同倍率的KV Cache压缩与更新；
 - **LightningIndexer (LI)**：高效筛选TopK稀疏KV；



mHC

- 多种方式共同开源，高效实现mHC
 - 基于AscendC实现 HcPre & HcPost；
 - 基于PyPTO实现 HcPre；
 - 基于TileLang支持DS原生开源的Kernel。



MoE


- 融合算子加速专家计算与通信
 - **MoEGatingTopK**：支持本次模型的hash routing和sqrt_softplus；
 - **GroupedMatmul**：同时处理多专家计算，提升计算效率；
 - **MoE Dispatch & Combine**：加速EP并行下的多卡token通信路由。

昇腾-整网优化解析

A3/A5 体现不同的量化策略：

A3/A5量化策略

- **A3-量化：**
 - a. 支持A8W8量化
 - b. 面向Indexer支持C8量化
- **A5-量化：**
 - a. 支持了原生FP8量化、MoE MXFP4量化
 - b. 支持硬件亲和的MXFP8量化支持A8W8量化



昇腾-整网优化解析

A3/A5 体现不同的量化策略：

Attention CV并行

匹配硬件架构，分核分流同步计算：

- CV并行掩盖
- 合理控制Cube和Vector核数，可以减少计算资源的抢占

其他优化

大EP多流掩盖：



- 共享专家/路由专家CV双流掩盖

Attention Tiling掩盖：

- Aicpu-tiling外置，通过前置预处理掩盖

TODO：

- aclGraph+superkernel / MegaMoE / Prefetch



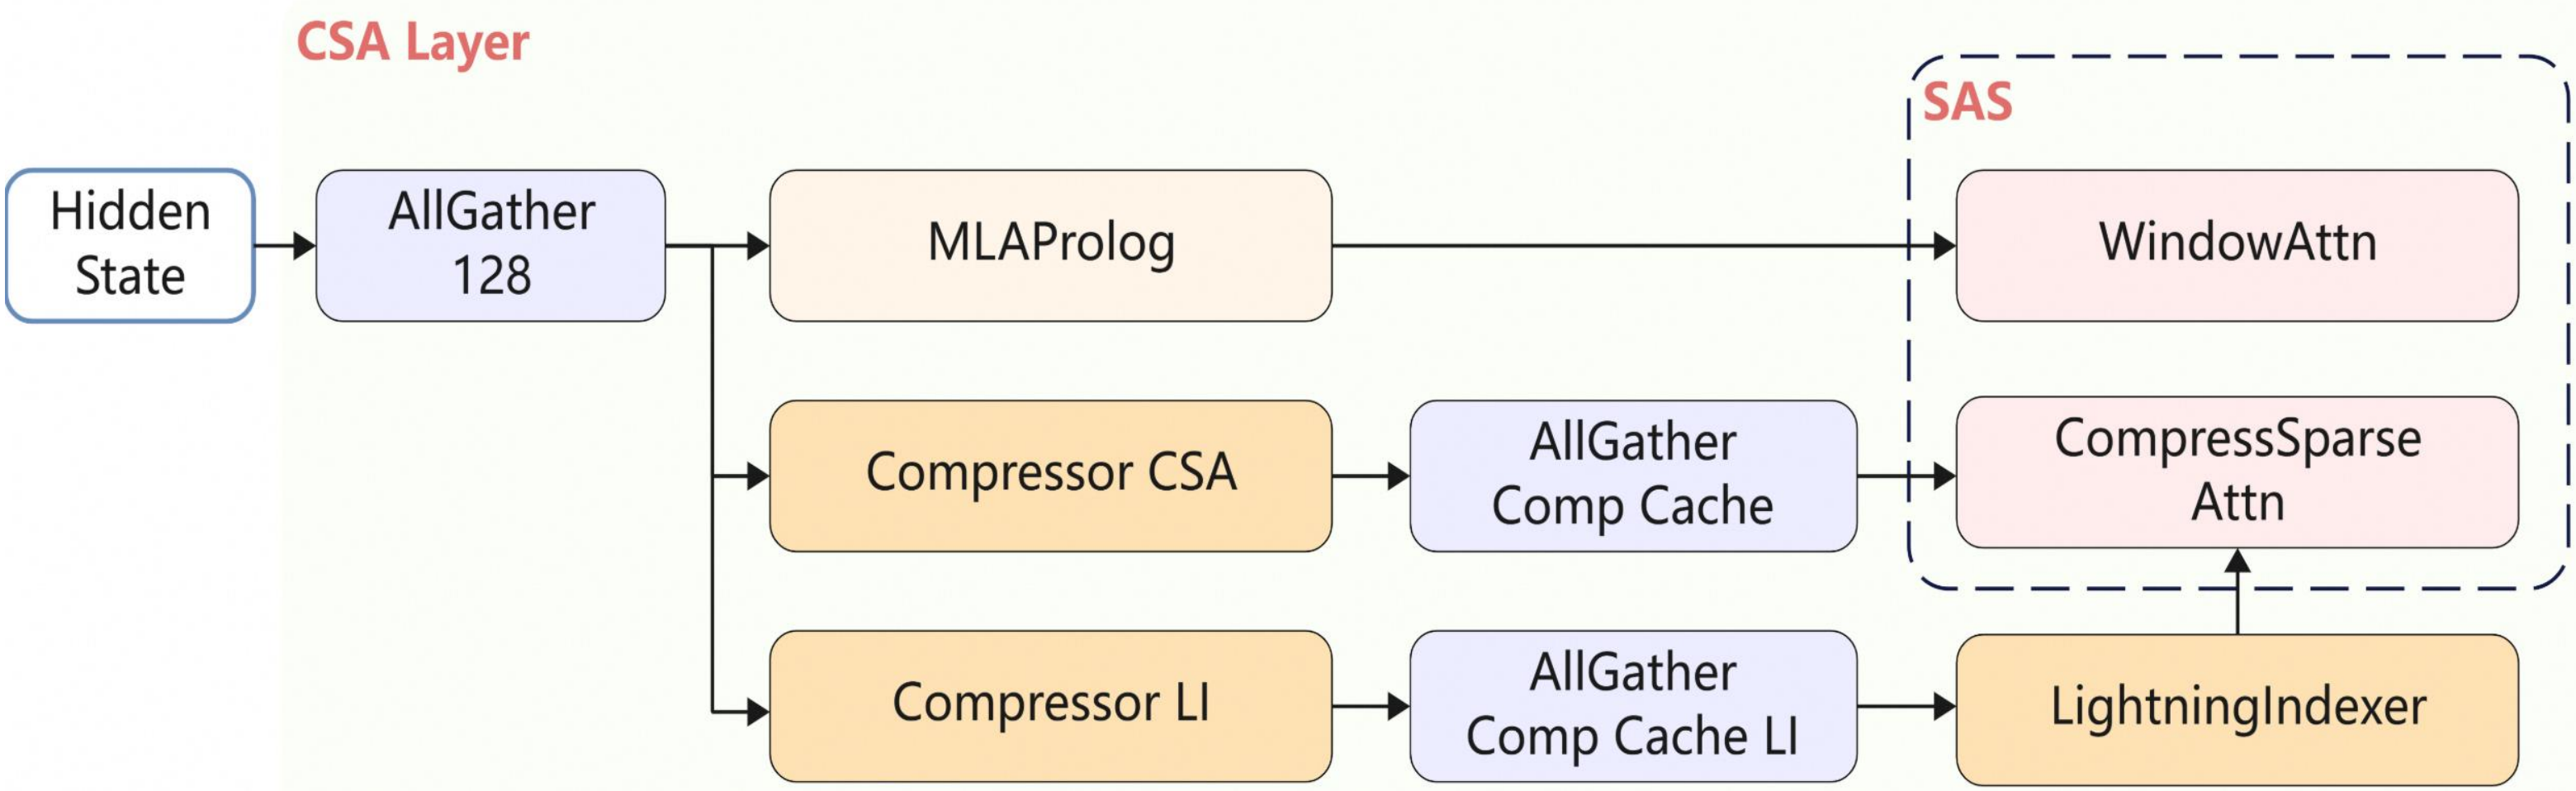
昇腾-整网优化解析

并行策略：Prefill CP+EP / Decode DP+EP

Prefill CP

针对长序列场景，优化TTFT:

- 对Prefill输入沿SeqLength维度切分于不同卡上;
- 通过zig-zag方式部署context chunk可以使卡间计算量相对均衡;
- 针对window cache, CSA和HCA场景，通过AllGather或Send/Receive获取前序token。



Decode DP

DP部署减少通信:

- 部分算子可以局部TP减少HBM占用 (OTP)
- 大EP部署提升整体性能

Decode EP

大EP减少MOE局部计算 & 权重Load:

- 延续A3超节点EP部署方案，充分利用高带宽通信优势

Atlas-A3 Pod Deepseek-V4 Flash Benchmark

Global Batch Size	Chips	MTP	Seq Length	TPOT (ms)	Throughput (Tokens/p/s)
7168	64	1	8192	27.82	4025
8192	64	1	8192	29.17	4388

- * A5依赖超节点，当前仅有16P部署

950DT Deepseek-V4 Flash Benchmark

Global Batch Size	Chips	MTP	DataType	Seq Length	TPOT (ms)	Throughput (Tokens/p/s)
16	16	3	Hybrid MXFP8-MXFP4	8192	6.71	148.96
256	16	3	Hybrid MXFP8-MXFP4	8192	9.84	1625.31
1536	16	1	Hybrid MXFP8-MXFP4	8192	20.33	4722.22

目录

01 DeepSeek V4 模型解析

02 昇腾-整网优化 解析

03 DeepSeek V4 亲和分析

DeepSeek V4 亲和分析

高效压缩，高效计算

Attention

算存比：

Pro对比V3.2: **27%Flops + 10%KV**

- 大幅度减少存储与计算的KVCache长度
- 平衡dim与长度

Flash对比V3.2: **10%Flops + 7%KV**

导向：

减少Cache存储与读取，降低访存压力
依赖灵活存储（异构存储）

更大规模，依赖互联

MoE

集群规模：

Pro: **384专家**

- 支持更大EP集群部署，发挥超节点UB互联优势
- 支持MXFP4量化，发挥算力优势

参考A3实测与A5理论分析：

优先大EP部署