


HIXL CS架构实现KV Cache极速传输



CANN-HIXL：单边通信库，屏蔽硬件差异，提供多方向多链路传输能力

HIXL（Huawei Xfer Library）是CANN通信库中提供点对点数据传输能力的单边通信库，面向超节点及集群场景提供简易、可靠、高效的点对点数据传输能力

- 提供简单的单边通信语义访问接口，支持D2rH/D2rD/H2rH/H2rD等多种单边**零拷贝**数据直传能力
- 对用户屏蔽不同代际芯片差异，支持多种网络/灵衢互联（Device Roce、Device UB、Host UB、Host Roce、Device HCCS等）



引擎初始化/去初始化

Initialize/Finalize

- 自动获取NPU通信资源
- 仅需配置host ip/port作为引擎唯一标识

链路管理

Connect/Disconnect

- 仅需指定对端引擎唯一标识
- 链路异常时支持自动清理
- 动态扩缩容

本地内存注册/注销

RegisterMem/DeregisterMem

远端内存直访

TransferSync

TransferAsync/GetTransferStatus

- 仅需指定对端引擎唯一标识，以及本地、远端读写地址信息

KV Cache池化：价值与规模化挑战

跨节点组织缓存资源，提升推理资源利用率，但规模化落地依赖通信底座能力升级

池化价值

WHY POOLING

将分散在多节点的 KV Cache 组织为共享资源池，使推理服务从“单机显存约束”走向“集群级弹性供给”。

- 1 提升 HBM / Host 内存整体利用率，降低热点节点资源空置与局部不足并存的问题。
- 2 支撑长上下文、多会话和动态负载场景，让缓存容量随集群资源弹性扩展。
- 3 通过跨节点复用缓存块，减少重复计算和频繁换入换出，改善端到端吞吐与稳定性。

池化面临的主要问题

SCALE CHALLENGES

1 链路规模扩容瓶颈

节点间通信链路总量随集群规模急剧增长；当前 HIXL 单设备最大链路数仅 **512** 条，成为横向扩容核心卡点。

2 HBM 内存资源挤占

每条 HIXL 链路内存开销超 **4MB**，大规模建链持续消耗 HBM，挤占模型推理可用空间并反向压缩链路数量。

3 多组网协议统一适配

不同场景覆盖 RDMA 参数面网络、超节点内部 HCCS / UB 等硬件通道，需要多协议单边通信能力与统一接口抽象。

4 池化传输时延深度优化

跨节点 KV Cache 传输时延直接拉高推理延迟，需要零拷贝通路、异步并发调度和小报文 Buffer 专项优化。

KEY CONSTRAINTS

关键约束 归纳

链路上限

单设备链路数仅 **512**，限制池化节点规模。

链路内存

单链路超 **4MB**，大规模连接挤占 HBM。

协议差异


RDMA / HCCS / UB 等多通道需要统一抽象。

时延敏感

KV Cache 跨节点访问要求低时延高吞吐传输。


CANN-HIXL: Client-Server架构

从Mooncake到HIXL Engine最终调用到HIXL CS的架构分层视图



HIXL CS架构升级：解决KV Cache池化关键瓶颈

Client-Server架构解耦通信域，并通过Device资源池化降低单链路的内存开销



KV CACHE POOLING
**关键问题
解决**

1 解决链路规模扩容瓶颈问题
突破链路上限 512 的限制，支撑 KV Cache 池化场景下更大规模的连接与弹性扩容。

2 解决 Device 内存资源挤占问题
通过 **Device 资源池化** 解决 device 内存占用问题，每条链路仅占用 **KB 级别内存**。

HIXL分层API：屏蔽多协议差异

以HIXL Engine承接通用传输能力，以HIXL CS封装Client/Server流程，向Mooncake暴露稳定统一接口

分层 API 使用方式

LAYERED API

Mooncake 接入层

通过编译开关使能 Ascend
HIXL 通路

`cmake .. -DUSE_ASCEND=ON`

使能 HIXL 编译方式

HIXL Engine

提供极致易用的用户友好 API

Initiate: 指定本地 ip:port 与唯一 name**RegisterMem:** 注册 Host / Device 类型地址**Connect:** 指定远端 ip:port 与唯一 name**TransferSync / Async:** 指定远端 name、地址和长度

HIXL CS API

面向单边通信场景的 Client /
Server 模式接口

Server

`HixlCSServerCreate``HixlCSServerRegMem / UnregMem``HixlCSServerListen / Destroy`

Client

`HixlCSClientCreate / Connect``HixlCSClientRegMem / UnregMem``HixlCSClientGetRemoteMem``HixlCSClientBatchPut/Get Sync/Async``HixlCSClientQueryCompleteStatus`

调用流程摘要

ENGINE / CS FLOW

HIXL Engine

Client

- 1 Initiate 本地 name
- 2 RegisterMem Host / Device
- 3 Connect 远端 name
- 4 TransferSync / Async

Server

- 1 Initiate 本地 name
- 2 RegisterMem Host / Device
- 3 等待远端 Connect
- 4 等待传输结束 → DeregMem / Finalize

HIXL CS Client / Server

Client

- 1 ClientCreate → ClientRegMem
- 2 ClientConnect
- 3 ClientGetRemoteMem
- 4 BatchPut/Get Sync/Async

Server

- 1 ServerCreate → ServerRegMem
- 2 ServerListen
- 3 提供远端内存描述
- 4 等待传输 → UnregMem / Destroy

UNIFIED ABSTRACTION

统一接口
抽象

解决上层业务跨协议适配成本高的问题

Mooncake 不直接感知 RDMA / HCCS / UB 等底层差异，统一通过 HIXL Engine 与 HIXL CS API 完成生命周期管理、建链、内存注册、远端内存交换和批量传输；底层协议差异由 HIXL 屏蔽，上层保持稳定调用模型。

A3传输性能优化：调度时延系统化调优

测试总数据量128M，围绕调度时延做系统优化，重点补齐小报文传输短板

优化手段

SCHEDULING LATENCY

- 1 减少过程中间转换**
减少过程开销，缩短调度链路上的软件处理路径。
- 2 优化流水编排**
合理编排任务，增强任务调度和任务传输的流水能力。
- 3 资源池化随取随用**
传输资源提前分配，用时获取，用完即还，降低临界路径等待。
- 4 提升任务队列深度**
不引入 Device 内存占用，减少与底层硬件交互，让硬件一次处理更多任务。

RoCE D2rH 优化前后吞吐量对比

TOTAL DATA 128M



KEY FINDINGS

关键结论

小包场景收益极高

16KiB 从 2.48GB/s 提升到 **21.64GB/s**，加速 **8.7x**。

大包性能无损失

256KiB 及以上基本持平，稳定 **1.0x**，保持硬件满带宽。

核心价值

补齐小报文传输短板，大报文场景保持满带宽能力。

A2传输性能优化：AICPU展开降低调度时延

测试总数据量128M，A2默认使能AICPU展开，面向批量传输任务较少调度开销

优化手段

AICPU EXPAND

1

通用优化继承

减少过程中间转换
优化流水编排
资源池化随取随用
提升任务队列深度


2

AICPU 展开默认使能

批量传输任务通过 AICPU 算子下发至 Device，在 Device 内批量调用硬件下发传输任务，减少 Host 侧逐任务调度和底层硬件交互开销。

RoCE D2rH 重构前后吞吐量对比

PEAK ~21 GB/S



KEY FINDINGS

核心数据说明

小消息场景效果显著

16KiB 从 0.74GB/s 提升到 18.07GB/s，加速 24.35x；
32KiB 达 13.58x。

大消息接近硬件上限

512KiB 及以上稳定在 20.7-21.1GB/s 区间，接近约 21GB/s 上限。

整体性能趋势

重构后 16KiB 已接近硬件上限，小消息吞吐整体远优于重构前。

FUTURE PLAN

围绕传输能力和异构能力持续增强，支撑KV Cache池化规模化落地

传输能力

TRANSPORT CAPABILITY

- ✓ HIXL 支持 UB2.0 及 Host RoCE #37 完成
- ✓ LLM-DataDist 支持 UB2.0 及 Host RoCE #38 完成
- ✓ HIXL 支持自动获取通信资源及多链路自动选择 #181 完成
- ✓ HIXL 构筑并开放 A2/A3 底层 Client-Server 系列接口 #138 完成
- ✓ HIXL 适配 Mooncake Dummy-Real Client 新特性 #99 完成
- ✓ HIXL 支持 Device UBoE #275 完成
- ▶ HIXL 支持 Device UBG #302 进行中
- HIXL 支持读写本地 / 远端存储设备 设计中

异构能力

HETEROGENEOUS CAPABILITY

- ▶ 跨代际能力增强，支持 A2/A3/A5 异构 #138 进行中
- ▶ 支持昇腾与通用服务器的异构 #174 进行中

欢迎体验：<https://gitcode.com/cann/hixl>

THANKS

