

昇腾NPU原生训练的三维重建基础模型与4D世界模型

作者：魔芯科技 纪德益

时间：2026.8

4D世界模型：背景定义

案例：推杯子场景



推一下，
会发生什么？



继续推，
杯子会掉下去吗？



如何避免掉落，
让行为更安全？

人类天生具备心理模拟能力：
能在行动前“**预见**”结果，这正是世界模型的灵感来源。

世界模型的高效闭环



通过“**感知-预演-执行**”的闭环，智能体通过世界模型进行高效学习和行为推演。

世界模型是AI对真实世界运行规律的“**内在模拟器**”，让AI在行动前
预演未来、理解因果、做出更优决策。

世界模型：下一个代际的万亿级机会

LLM智能 2022年 - 2025年

世界模型 2025年 - ∞

核心能力

基于语义理解和生成

模式识别、内容生成、知识推理

层级

认知层/语言层/数字世界

行业产业链

基础
模型

> tokens >




API

>

应用/Agent

Chatbot、客户服务、金融、法律.....

Scaling Law



表达世界 + 理解世界 + 预测世界

空间感知、几何推理、路径规划

与物理世界深度结合和交互

应用

世界
模型

> tokens >

API /
执行
设备

>

具身智能、自动驾驶、4D内容生成、工业数字孪生.....

目前通过scaling law的实现
通用世界理解的范式尚未确定

4D世界模型整体架构

像素生成路线（2D视频）

显式结构路线（3D结构）

隐式结构路线（4D时空）

核心技术

Diffusion Transformer 预测 “下一帧”

NeRF / 3D Gaussian Splatting

纯Transformer前馈网络，学习隐空间中的4D Token

技术架构



优势

可大规模训练

显式结构
精度高

可大规模训练
实时生成
非先验
泛化能力强

劣势

无物理世界的表征
无法弥补的sim-real gap

几何构建难度大，数据难获取
动态交互难度高

随着训练量和参数，精度/准确度
逐步提高

4D世界模型整体架构

4D世界模型：MoWorld- 3D

输入单图



4D世界（高斯表示）




三维重建基础模型

Geometry Estimation

Depth Maps $\{D_i\}_{i=1}^T$


Camera Pose $\{R_i, t_i\}_{i=1}^T$




MoWorld 视频生成式世界模型

输入：文本、图片、相机参数

输出：视频场景



迭代优化



CANN 异构计算架构

加速库

- 算子库：大模型融合算子、神经网络及数学类等基础算子
- 通信库：集合通信算法、分布式通信
- 领域加速库：信号处理等特定领域计算加速
- 图引擎：图编译优化、图执行加速

昇腾NPU和CANN生态

毕昇编译器：异构编译优化 | 指令亲和 | 支持三方编程语言

运行时与驱动

- 运行时：执行控制 | 内存管理 | 任务调度
- 驱动：板级驱动 | 加速器驱动 | 设备管理

产业生态应用：消费娱乐、文旅建设、具身智能、机器人、自动驾驶.....

目录

Part 1 三维重建基础模型

Part 2 MoWorld系列世界模型

Part 3 产业生态应用

三维重建基础模型：AI理解物理空间的基石

3d重建网络




<https://gitcode.com/cann>

CANN

三维重建基础模型：AI理解物理空间的基石

前馈式3d重建网络：VGGT & VGGT- Ω

✓ 基于海量 3D 标注数据训练而成的大型前馈 Transformer 模型，接收多达数百张图像，并在不到一秒的时间内同时预测所有图像的相机参数、点图、深度图及点轨迹，且无需额外处理，其性能往往优于基于优化的同类方法。




三维重建基础模型：AI理解物理空间的基石

前馈式三维重建三大难点

在**真实工业级场景**中，三维感知模型面临的挑战不仅在于精度本身。当输入分辨率提升、场景引入动态变化、数据形式扩展为**视频流**时，传统架构的算力、算法与内存资源将同时承压。


1 无限序列与有限内存的冲突

长视频流导致 KV Cache 线性增长，迅速耗尽显存。




2 动与静的纠缠

动态物体干扰位姿估计，导致背景扭曲、结构坍塌。



3 算力与精度的矛盾


分辨率越高，Token 数爆炸，显存瞬间耗尽。



三维重建基础模型：AI理解物理空间的基石

昇腾NPU原生的前馈式三维重建网络：HD-VGGT- Ω （高精度）

提出 **GREA (Geometry Representation Alignment)**，把高分辨率图像中的局部细节先验先映射到和 VGGT- Ω 几何特征兼容的共享 latent space，再做融合；同时引入高分辨率分支，加入几何骨架上的残差修正，结合频域全局上下文，融合空间分支和频域分支。



昇腾NPU原生的前馈式三维重建网络： HD-VGGT-Ω （高精度）

三

H

KOKONI LAB/HD-VGGT-Omega

🔒

🔍

按下 / 快速开启搜索

🏠 首页 >

🛠️ 工作台

📁 下载历史

📖 浏览历史

🌐 AI社区

🏆 竞赛平台

🛒 应用市场

📁 项目 >

👤 组织 >

⚙️ 偏好设置

📄 代码

🔗 Issues

🔄 Pull Requests

💬 项目讨论

👤 项目成员 16

📊 分析

⚙️ 项目设置

main ▾

🔗 分支 2

🏷️ Tags 0

🔍 搜索文件

+

📁


🔴 jankyee26

clean code ▾

0a206fe9


创建

文件	最后提交记录
📁 training	clean code
📁 vgg_t_omega	clean code
📄 .gitignore	style: ruff lint --fix across entire project - Split multi-statement lin...
📄 CLAUDE.md	clean code
📄 README.md	clean code
📄 batch_inference.py	clean code
📄 demo_gradio.py	clean code
📄 eval_hr.py	clean code
📄 inference.py	clean code
📄 inference_video.py	clean code
📄 pyproject.toml	HD-VGGT2.0: lightweight high-resolution depth refinement for VG...
📄 requirements.txt	HD-VGGT2.0: lightweight high-resolution depth refinement for VG...
📄 requirements_demo.txt	HD-VGGT2.0: lightweight high-resolution depth refinement for VG...
📄 test_hr_v2.py	clean code



三维重建基础模型：AI理解物理空间的基石

昇腾NPU原生的前馈式三维重建网络：4D-VGGT- D（支撑动态场景重建）



三维重建基础模型： AI理解物理空间的基石

昇腾NPU原生的前馈式三维重建网络： 4D-VGGT- D （支撑动态场景重建）

CANN

CANN/cann-recipes-embodied-ai

快速开启搜索

代码

Issues 9

Pull Requests 6

Actions

项目讨论

分析

4D_VGGT merged #111

jankyee26 创建于 1 小时前 · 从 [jankyee26/cann-recipes-embodied-ai: master](#) 合入到 [cann/cann-recipes-embodied-ai: master](#)

已开启 AI Review APP

讨论 5

提交 3

检查 0

文件改动 89

jankyee26 1 小时前

Dynamic-scene 4D reconstruction pipeline built on top of VGGT

👍

👎

+😊

合并受阻 用户无权限

jankyee26 4 分钟前 创建了 pull request, commit [8e0b2185](#)

atomgit-bot 29 分钟前 评论:

正在生成合并请求摘要, 请稍候...

👍

👎


+😊

不准确?



三维重建基础模型：AI理解物理空间的基石

昇腾NPU原生的三维重建基础模型——StreamCacheVGGT（流式推理加速）



昇腾NPU原生的三维重建基础模型——StreamCacheVGGT（流式推理加速）

三

s

KOKONI LAB/StreamcacheVGGT

Q 按

代码

Issues

Pull Requests

讨论

分析

首页

工作台

AI社区

大赛平台

项目

组织

企业

偏好设置

main

分支 1

Tags 0

搜索文件

zyh 更新streamcacheVGGT

文件	最后提交记录
assets	更新streamcacheVGGT
cloud_opt	更新streamcacheVGGT
datasets_preprocess	更新streamcacheVGGT
examples	更新streamcacheVGGT
lib	更新streamcacheVGGT
src	更新streamcacheVGGT
.gitignore	更新streamcacheVGGT
README.md	更新streamcacheVGGT



目录

Part 1 三维重建基础模型

Part 2 MoWorld系列世界模型

Part 3 产业生态应用

世界模型：背景定义

定义

世界模型（World Model）以推演未来世界为核心，具备可交互性、物理一致性、流式生成等核心能力。

三大特点

➤ 可交互性

支持外部信号干预和驱动

➤ 物理一致性

告别“幻觉”，遵循物理规律

➤ 流式生成

可无限推演并预测未来

与其他模型的对比

➤ 大语言模型

缺乏对物理过程与环境动态的显式建模

➤ 视频生成模型

缺乏动作交互与物理一致性

➤ 常规具身模型

缺乏未来推演和模拟能力

核心功能

➤ 降低试错成本

在“想象”中预测结果、优化策略，减少真实交互成本

➤ 提升安全可控性

在动作执行前预估潜在风险

➤ 支持长期决策

推演未来状态演化，支撑长时、全局性的决策



✓ **闪速世界模型：**能够以 30 FPS（每秒帧数）或更高速度持续生成、从而支持对动态环境进行响应式交互的实时世界模型。在计算机图形学与交互媒体领域，30 FPS 通常被视为实现实时渲染与流畅交互体验、从而进一步实现商业化落地的最低门槛。

✓ 然后在截止MoWorld发布以来，主流的世界模型的均很难满足30FPS这一条件；而MoWorld可以支持50FPS，受益于昇腾生态。

MoWorld: 首个完全基于NPU生态的闪速世界模型

完全基于昇腾NPU生态全链路闭环的世界模型研发体系

✓ **预训练层**: 基于高低噪双MOE模型，升级为**具备相机可控与长时程生成能力**的教师模型；**自回归少步对齐**: 将多步双向注意力模型**极致压缩**为少步推理的自回归学生模型；**推理层**: 实施**底层优化**，全面打通实时视频交互链路，**实现最高50FPS**。








CANN

MoWorld: 首个完全基于NPU生态的闪速世界模型


完全基于昇腾NPU生态全链路闭环的世界模型研发体系

基于昇腾NPU和CANN生态构建的三层
(算子层、并行层、流水线层) **推理框架**
架，实现了高推理速度与低推理成本



MoWorld-3D: 4D生成式世界模型

4D世界模型: MoWorld- 3D



产业生态应用: 消费娱乐、文旅建设、具身智能、机器人、自动驾驶.....

4D世界模型：MoWorld- 3D

不只是生成一张图，而是同时理解相机、几何、语义和场景之间的空间关系。

输入：模型看到什么


单张 / 多视角 RGB 图像




视频序列



文本描述 / 目标视点




内部能力：模型理解什么




- 估计相机位姿
- 恢复深度与几何结构
- 建立 3D 对应关系
- 理解语义与动态变化
- 保持跨视角一致性

输出：模型能给什么

相机参数




深度



点云



3D 对应点




3D 语义




补全场景



新视点合成



动态场景理解



输入多模态

支持图像、视频、文本和目标视点等多种输入形式。

中间学空间

在 3D / 4D 空间中统一理解几何、语义与动态。

输出可计算

提供结构化的 3D / 4D 表示与多种可计算结果。