

HIXL协同Mooncake实现KV Cache池化技术实践分享

作者：赵智慧

时间：2026-05-29

目录

Part 1 Mooncake池化介绍

Part 2 HIXL池化场景优化方案

背景：显存不足已成为AI推理主要瓶颈

核心挑战



显存占用线性增长

LLM推理中，KV Cache的显存占用随序列长度的增加呈线性增长趋势。



长上下文场景压力巨大

128K tokens及以上的超长上下文下，单请求KV Cache占用可高达数十GB。



吞吐量受限

有限显存限制了Batch Size，严重影响系统整体吞吐量。



资源调度困难

Prefill与Decode阶段需求差异大，统一调度难度高。

显存占用估算 (以 LLaMA-70B 模型为例)


模型	序列长度	KV Cache / 请求
LLaMA-70B	4K tokens	~1.3 GB
LLaMA-70B	32K tokens	~10.2 GB
LLaMA-70B	128K tokens	~41 GB



关键洞察

在128K长序列下，单张80GB 片上内存高端显卡仅能服务1-2个并发请求，导致大量宝贵的算力资源被闲置浪费。

解决思路：KV Cache池化



技术路径



识别瓶颈

NPU显存空间持续紧张



核心操作

卸载KV Cache至独立资源池



资源利用

利用CPU DRAM/SSD等空闲资源



目标达成

NPU专注计算，显著提升吞吐量

预期收益

3-6 倍

有效 Batch Size 提升

大幅提升模型并行处理能力

84% ↓

首字延迟 (TTFT) 降低

基于缓存命中场景下的优化数据

~100%

NPU 算力利用率



释放显存压力，专注核心计算

弹性扩缩容

架构解耦优势

实现 Prefill 与 Decode 阶段分离

KV Cache池化方案：CANN-HIXL接入Mooncake开源社区，实现池化能力



- CANN-HIXL通过Ascend HIXL Transport接入Mooncake社区，支持多种网络/灵渠互联（Device UB、Device Roce、Host UB、Host Roce等，对上屏蔽业务复杂性）


https://github.com/kvcache-ai/Mooncake/blob/main/docs/source/design/transfer-engine/ascend_direct_transport.md

- CANN-HIXL当前已开源，为Ascend芯片提供高效的多链路的D2rD/D2rH/rH2D/H2rH等单边通信能力

<https://gitcode.com/cann/hixl>

- CANN-HIXL与Mooncake社区保持深度技术联动，每周一常态化例会，同步技术进展并规划下一阶段任务

典型应用场景: KV Cache池化管理




- **零拷贝、高带宽利用:** 由 Transfer Engine 提供支持, 数据链路零拷贝, 实现高速数据读写;
- **动态资源伸缩:** 支持动态添加和删除节点, 灵活应对系统负载变化, 实现资源的弹性管理;
- **分级缓存:** 支持将 片上内存中缓存数据卸载到 DDR 中, 以进一步实现成本与性能间的平衡, 提升存储系统的效率;

★ HIXL需要支持数据在NPU 片上内存、CPU DRAM之间的高效流转

CANN-HIXL: 单边通信库, 屏蔽硬件差异, 提供多方向多链路传输能力

HIXL (Huawei Xfer Library) 是CANN通信库中提供点对点数据传输能力的单边通信库, 面向超节点及集群场景提供简易、可靠、高效的点对点数据传输能力

- 提供简单的单边通信语义访问接口, 支持D2rH/D2rD/H2rH/H2rD等多种单边**零拷贝**数据直传能力
- 对用户屏蔽不同代际芯片差异, 支持多种网络/灵衢互联 (Device Roce、Device UB、Host UB、Host Roce、Device HCCS等)



引擎初始化/去初始化

Initialize/Finalize

- 自动获取NPU通信资源
- 仅需配置host ip/port作为引擎唯一标识

链路管理

Connect/Disconnect

- 仅需指定对端引擎唯一标识
- 链路异常时支持自动清理
- 动态扩缩容

本地内存注册/注销

RegisterMem/DeregisterMem

远端内存直访

TransferSync

TransferAsync/GetTransferStatus

- 仅需指定对端引擎唯一标识, 以及本地、远端读写地址信息

目录

Part 1 Mooncake池化介绍

Part 2 HIXL池化场景优化方案

池化场景面临的主要问题

链路规模限制

随着池化节点规模的增加，节点间的通信链路数量呈指数级增长。这种非线性的扩张特性，使得连接管理成为系统扩展的关键瓶颈。

核心技术挑战

HIXL 单边通信库的单设备链路数上限成为集群扩容核心瓶颈。当前单硬件设备最大链路并发数限制为 512 条，链路承载容量不足，直接约束分布式集群的横向扩展能力。

Device 内存占用

通信链路对内存的过度占用会直接挤压模型推理的有效空间。这不仅会降低单卡的有效吞吐量，更可能引发内存溢出错误。

核心技术挑战

HIXL 单边通信单链路硬件内存开销达 2MB 以上，海量建链会持续挤占 Device 片上存储资源。片上内存资源紧张进一步收紧链路数量上限，形成双重限制。

多协议支持适配

不同行业与场景的基础设施组网差异巨大，包含高性能 RDMA 参数面网络，以及超节点内HCCS或者UB组网。

核心技术挑战

HIXL单边通信库需要灵活支持 RDMA、HCCS 等主流协议池化能力，同时在保证高性能的前提下，提供统一的上层抽象，以降低业务层的适配与迁移成本。


池化传输耗时优化

在大规模池化场景中，KV Cache的跨节点传输耗时成为影响端到端延迟的关键因素。

核心技术挑战

需要在保证高带宽的同时，尽可能降低传输延迟。这要求底层通信库具备高效的零拷贝机制、异步并发能力以及对小块数据传输的优化。

CANN-HIXL: Client-Server架构重构



链路解耦通信域

去除单卡 512条链路 限制
支持超大规模集群弹性互联

建链内存优化

2M+ / 链路 → KB 级别
Device 内存占用大幅降低

建链耗时优化

秒级 → 几十 ms
建链速度提升数十倍

多协议支持

RoCE HCCS UB UBoE UBG

Device资源池化管理

传输时按需分配，合理利用资源

可注册Host内存扩容

~30GB → ~1TB
Host注册内存容量大幅提升

● Mooncake 使能配置


```
# 环境变量
export ASCEND_LOCAL_COMM_RES="{ \"version\": \"1.3\" }"

# 编译
cmake .. -DUSE_ASCEND=ON
https://gitcode.com/cann
```

CANN-HIXL: Client-Server接口




CANN-HIXL: Client-Server A2性能表现



A2场景优化前后性能数据



CANN-HIXL: Client-Server A3性能表现



A3场景优化前后性能数据



CANN-HIXL: 超节点内支持Fabric Mem



本地进程

调用[aclrtMallocPhysical](#)
申请本地物理内存

① 地址交换 ⇌ ② 远端映射

建链时基于CANN VMM将远端物理地址
直接映射到本地进程虚拟地址空间



远端进程

调用[aclrtMallocPhysical](#)
申请本地物理内存

三大核心优势



全局统一编址

跨节点内存统一映射，
如本地般访问。



SDMA 硬件直访


硬件DMA引擎直接操控，
传输效率极高。



零 CPU 开销：远端进程无需参与传输，无中断。

HIXL ADDRESS MAPPING

HIXL 0 Virtual Address Space Maps to Physical Addresses of All Instances
■ Virtual Address ■ Physical Address ■ Seg 0 ~ HIXL 0 ■ Seg 1 ~ HIXL 1 ■ Seg 2 ~ HIXL 2




CANN-HIXL: Fabric Mem使用介绍




CANN-HIXL: Fabric Mem性能表现

(一个key count数据为:61*(16K + 128K))



A3场景get性能数据



A3场景put性能数据

CANN-HIXL：路标规划

⚡ 传输能力

- ✓ HIXL 支持 UB2.0 及 Host RoCE #37 完成
- ✓ LLM-DataDist 支持 UB2.0 及 Host RoCE #38 完成
- ✓ HIXL 支持自动获取通信资源及多链路自动选择 #181 完成
- ✓ HIXL 构筑并开放 A2/A3 底层 Client-Server 系列接口 #138 完成
- ✓ HIXL 适配 Mooncake Dummy-Real Client 新特性 #99 完成
- ✓ HIXL 支持 Device UBoE #275 完成
- ▶ HIXL 支持 Device UBG #302 进行中
- HIXL 支持读写本地/远端存储设备 设计中

◆ 异构能力

- ▶ 跨代际能力增强，支持 A2/A3/A5 异构 #138 进行中
- ▶ 支持昇腾与通用服务器的异构 #174 进行中



Thank you.

社区愿景：打造开放易用、技术领先的AI算力新生态

社区使命：使能开发者基于CANN社区自主研究创新，构筑根深叶茂、跨产业协同共享共赢的CANN生态

Vision: Building an Open, Easy-to-Use, and Technology-leading AI Computing Ecosystem

Mission: Enable developers to independently research and innovate based on the CANN community and build a win-win CANN ecosystem with deep roots and cross-industry collaboration and sharing.



上CANN社区获取干货



关注CANN公众号获取资讯